基于众包接收报告的短波链路名义信噪比残差预测与持续学习系统

摘要：本文研究 WSPR 与 PSKReporter 已成功上报链路的名义信噪比（SNR），结合 VOACAP 物理基线、残差学习与周期性模型准入。历史 WSPR 数据共 93 500 条，其中 18 700 条时间留出记录参与 −120 dB 基线下限选择，故混合模型与 VOACAP 的 RMSE（8.21 dB 与 34.69 dB）属于开发阶段比较，不是独立测试估计。其余 74 800 条构成初始训练池。开发阶段 12 折结果显示，支撑自适应时间邻域正则化使 RMSE 改善 0.41%–0.61%；五条预设路径的网格相邻评分变化指标下降 12.3%–51.6%，但尚未验证其与连续实测或用户决策的关系。低容量回退在 10 000–14 000 km 段使汇总 RMSE 改善 1.28%。早期 PSKReporter 条件切片的 RMSE 比较值降低 14.63%，历史子集则上升 0.08%；该结果不能区分传播信息增益与来源适配。频率平滑及部分长路径设置出现劣化。上述发现限于既定数据与运行规则下的开发和系统评估。

关键词：短波传播预测，电离层传播，残差学习，众包观测，持续学习

RESIDUAL PREDICTION OF REPORTED HF LINK SNR AND A CONTINUAL LEARNING SYSTEM USING CROWDSOURCED DIGITAL-MODE OBSERVATIONS

Abstract: This study predicts nominal signal-to-noise ratio (SNR) conditional on successful WSPR and PSKReporter reception reports, combining a VOACAP baseline with residual learning and periodic model admission. The historical WSPR dataset contains 93,500 records; 18,700 time-holdout records informed selection of the −120 dB baseline floor, so the hybrid-versus-VOACAP RMSE comparison (8.21 versus 34.69 dB) is development-stage evidence, not an independent test estimate. The remaining 74,800 records formed the initial training pool. In development-stage 12-fold evaluation, support-adaptive temporal regularisation improved RMSE by 0.41%–0.61%. A grid-adjacency score fell by 12.3%–51.6% on five predefined paths, but has not been validated against continuous measurements or user decisions. Low-capacity fallback improved aggregated RMSE by 1.28% in the 10,000–14,000 km segment. An early PSKReporter slice showed a 14.63% lower RMSE while the historical subset worsened by 0.08%; this comparison cannot separate propagation information gain from source adaptation. Frequency smoothing and some long-path settings deteriorated. These findings are limited to development and system evaluation under the stated data and operating rules.

Key words: HF propagation prediction, ionospheric propagation, residual learning, crowdsourced observations, continual learning

目录

第一章 绪论与相关研究 ..... （1）
1.1 研究背景..... （1）
1.2 问题提出..... （1）
1.3 研究目标..... （2）
1.4 研究问题..... （2）
1.5 研究方法..... （2）
1.6 研究思路与技术路线..... （2）
1.7 本文工作与主要贡献..... （3）
1.8 论文组织..... （4）
1.9 文献综述..... （4）
1.10 方法依据与可检验假设..... （10）
1.11 研究问题与可检验命题的对应关系..... （10）
1.12 本文的研究对象与工程对象..... （11）
1.13 使用情境决定预测时间尺度..... （11）
1.14 相关研究比较的统一坐标..... （12）
1.15 文献结论向本任务迁移的条件..... （13）
第二章 观测数据与质量控制 ..... （15）
2.1 观测来源与数据集构成..... （15）
2.2 物理基线计算与口径一致性..... （16）
2.3 特征构建、空间天气与数据质量控制..... （19）
2.4 观测生成机制与覆盖审计..... （21）
2.5 名义 SNR 测量、来源差异与特征可得性..... （24）
2.6 清洗决策与样本选择..... （26）
2.7 数据版本、观测机会与有效信息量..... （27）
2.8 覆盖报告与清洗规则代价..... （30）
第三章 混合预测模型与稀疏区稳健化 ..... （32）
3.1 总体架构..... （32）
3.2 残差回归模型..... （33）
3.3 可靠度评分的定义..... （34）

3.4 阈值选择数据上的时间留出比较.....（34）
3.5 稀疏观测下的预测稳健性.....（35）
3.6 历史观测覆盖与代表性场景的错配.....（37）
3.7 支撑度自适应的邻域正则化.....（38）
3.8 稀疏区的回退目标：为什么不能是物理基线.....（41）
3.9 可靠度评分的尺度.....（44）
3.10 综合效果.....（44）
3.11 评价协议与残差模型边界.....（45）
3.12 支撑度定义与邻域算子边界.....（47）
3.13 回退策略与评分解释.....（49）
3.14 方法组件、平滑与混合条件.....（51）
3.15 多维支撑与稀疏区风险.....（52）
3.16 评分映射与物理基线贡献.....（54）
3.17 查询应用与频率边界.....（55）
3.18 本章小结与局限.....（57）
第四章 离线实验与方法学检验 .....（59）
4.1 评估协议.....（59）
4.2 主模型性能与特征分析.....（63）
4.3 负面结果.....（65）
4.4 计算开销.....（66）
4.5 估计量、数据处理与评价选择.....（67）
4.6 稀疏区对照与负面结果约束.....（69）
4.7 复现性、选择风险与折结果再分析.....（71）
4.8 成对差值与稀疏压力测试.....（74）
4.9 复现链条、应用评价与工程稳定性.....（75）
4.10 本章小结.....（77）
第五章 众包持续学习系统与运行验证 .....（78）
5.1 总体流程.....（78）
5.2 观测来源与空间覆盖.....（78）
5.3 开放上报的风险与可信度分层.....（81）
5.4 与模型准入门槛解耦的标定量.....（83）

5.5 运行状态与实际效果.....（83）
5.6 面向用户的透明度.....（87）
5.7 闭环状态机与必须维持的不变量.....（88）
5.8 来源可信、记录可信与模型可信的区别.....（89）
5.9 运行数字的解释与样本独立性.....（89）
5.10 预先冻结的纵向评价方案.....（90）
5.11 模型版本、缓存与用户所见结果.....（91）
5.12 用户贡献的价值与约束.....（92）
5.13 上线决策的证据账本.....（93）
5.14 故障恢复与性能结论之间的隔离.....（93）
5.15 数据贡献、准入权与评估权的分离.....（94）
第六章 讨论与后续研究 .....（96）
6.1 数据层面的局限.....（96）
6.2 建模与评估层面的局限.....（96）
6.3 系统层面的局限.....（97）
6.4 后续工作.....（100）
6.5 后续验证的优先级与终止条件.....（102）
第七章 结论 .....（104）
参考文献： .....（105）
谢辞 .....（108）
英文论文大摘要 .....（109）

第一章 绪论与相关研究

1.1 研究背景

短波（高频，HF，3–30 MHz）可经电离层传播至地平线以外，因此在没有地面中继或卫星转发的条件下仍能建立远距离链路。业余无线电、海事和航空通信持续使用短波；当地面网络受损时，它也可提供一条独立于本地基础设施的通信路径。本文研究给定收发位置、时刻与频率后的链路信噪比预测，评价对象为已记录的接收链路。

太阳活动周期、季节和昼夜转换持续改变电离层状态，数分钟至数小时的突发扰动又叠加其上。同一路径的传播条件随时段和波段改变。预测模型既要提供跨区域的物理约束，也要解释具体设备与观测环境造成的链路偏差；两种要求在观测稀疏处尤其难以同时满足。

1.2 问题提出

现有方法提供了两类不同的信息。经验—物理模型以电离层统计规律覆盖任意地理路径；接收报告训练出的统计模型则从已经发生的链路中学习偏差。本文关心的是两类信息在同一个预测目标下怎样结合，以及其误差在稀疏区域怎样被发现和约束。

经验—物理模型。 VOACAP（Voice of America Coverage Analysis Program，源于美国 NTIA 的 IONCAP[1]）和国际电信联盟建议书 ITU-R P.533[2] 是其中的代表。这类方法用数十年的电离层探测数据拟合电子密度剖面，继而通过射线追踪和链路预算估计可用频率范围、信号强度与可靠度。这类模型无需实时观测即可预测任意路径，但历史统计参数难以描述天线、地形、本地噪声和设备的个体差异，输出绝对量值可能明显偏离实际接收系统。第 2 章的实测值给出了这种差距的量级：VOACAP 输出信噪比与业余数字模式实测值之间的中位偏差，会随路径长度从 -30.9 dB 变化到 $+18.3$ dB。

数据驱动方法。 WSPRnet[3]、PSKReporter[4] 和 Reverse Beacon Network 等网络保存的接收记录，可用于估计物理模型的链路偏差。记录的地域分布与业余无线电人口分布有关：欧洲、北美和东亚占比较大，海洋和低人口密度区域的记录较少。

链路之间既有物理模型偏差的差异，也有机会式采样支撑程度的差异。总体 RMSE 汇总了这些链路的误差，却不能说明某条链路上的校正是否可靠，或波段—时段网格是否发生局部跳变。研究设计需要同时检验链路误差、局部输出形态和新增数据进入系统后的准入行为。

1.3 研究目标

本文以 VOACAP 的物理估计为起点，用众包数字模式接收报告估计链路校正量，并在固定实验中检查预测误差和稀疏区输出的稳定性。线上系统负责采集、重训和可信准入，保存每次模型替换的时间及依据。方法在所定义测试分布上是否有效，由离线实验判断；系统是否按规则执行，则通过运行记录核查。

1.4 研究问题

本文把链路误差、稀疏区输出和持续学习准入放在一起考察，形成四个可检验问题：（1）在当前残差目标下，物理基线与统计校正的组合能否降低链路预测误差，其证据能够支持到何种归因强度？（2）历史观测分布与代表性跨洲查询不一致时，平均误差遗漏哪些输出失稳？（3）局部支撑下降后，邻域正则化和低容量回退能否同时约束跳变与误差，回退目标应如何选择？（4）开放上报参与训练时，怎样把拟合样本与模型准入证据分开，并如实解释运行期的上线记录？

1.5 研究方法

历史 WSPR 与新采 PSKReporter 记录经校验后用于残差建模，梯度提升树拟合实测 SNR 与 VOACAP 基线的差值。时间留出、留一（年，月）交叉验证、空间留区和受控抽稀分别检查预测误差与稀疏条件；生产候选的早停验证仅使用可信来源样本，并经可信测试集准入。

1.6 研究思路与技术路线

从质量审查到空间天气标注、物理基线计算的先后关系，见图 1-1 的观测处理流程。离线实验以固定数据和配对协议比较方法，运行系统则对每轮候选和在役模型作当轮可信测试集比较。数据集和测试集随时间增长时，跨轮 RMSE 轨迹只记录运行状态，不能直接解释为模型质量的纵向变化。

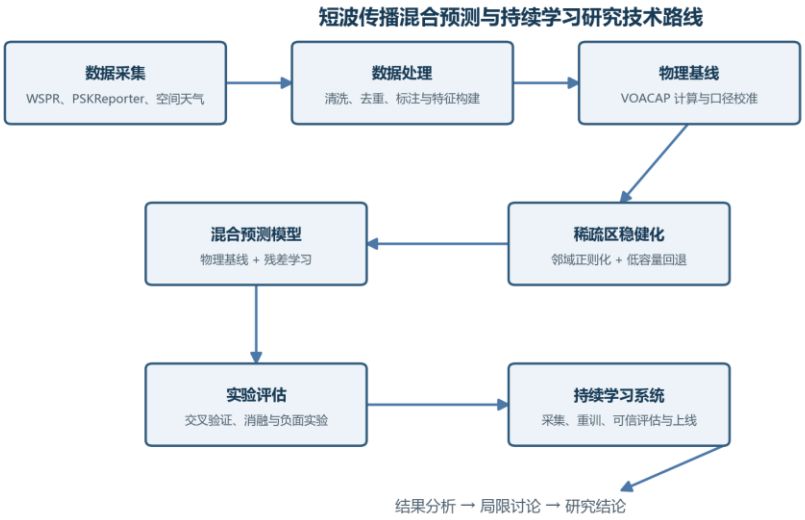


图 1-1 短波传播混合预测与持续学习技术路线

1.7 本文工作与主要贡献

文中以业余无线电弱信号数字模式的全球众包接收报告为观测源，建立”物理基线 + 机器学习残差校正”的短波传播混合预测方法，并将它接入众包持续学习系统。主要工作如下。

（1）当前残差架构对 VOACAP 派生组高度敏感。 在维持输入维度不变并保持残差目标不变的条件下，将 VOACAP 派生特征组置零后，RMSE 上升 131.6 %，12 折均劣化。由于目标本身定义为实测 SNR 与 VOACAP 之差，该结果反映当前架构对派生输入的依赖，不单独证明物理基线的因果贡献。

（2）诊断平均误差未覆盖的局部输出形态。五条预设路径的（波段 × 小时）网格中，低观测支撑的两端场景通常有更大的相邻单元评分变化。短路径占历史观测的 27.1 %，模型变化指标为 6.39，与 VOACAP 的 5.75 接近；超长路径占比为 0.1 %，指标为 8.40，而 VOACAP 将该路径全部波段和时段判为闭合，无法提供可读单元作比较。该指标衡量特定查询网格的数值粗糙度，不等于相对于真实传播轨迹的误差，也未验证其对通联决策的效用；中间路径变化并不严格单调。

总体 RMSE 难以反映这类局部失效。留出集延续了历史观测的距离分布，稀疏区在测试集中仍然样本很少，其误差会被数量占优的密集区样本稀释。文中预设的跨洲 DX 代表场景多落入低支撑区，由此暴露出历史观测覆盖与目标场景之间的错配。

（3）构造随数据支撑调节的正则化方法。 观测支撑决定邻域核宽，核内不同时刻和频率的校正量随后加权合并。支撑继续下降时，回退机制逐步提高低容量模型在预测中的权重。沿时间维正则化后，12 折交叉验证的精度均提高，幅度为 0.41 %–0.61 %，五条参考路径的跳变下降 12.3 %–51.6 %。低支撑的两端总体干预更强、降

幅更大，低容量回退在 10 000–14 000 km 段提高精度 1.28 %，各距离段的跨折汇总均值未劣化。但 14 000–20 100 km 段仅有 8/12 折改善，对该段收益的证据较弱。

受控实验还表明，在文中选取的两个目标距离段及六种受控抽稀设置内，低容量的**数据驱动模型**比物理基线更适宜当作回退目标。即使目标区间只保留 5 条训练样本，前者的误差仍比纯物理基线低 7.3 倍；这一结论不外推到未检验的距离段与稀疏形态。

（4）实现众包持续学习系统与可信度分层机制。用户记录可进入候选拟合集，早停验证和模型准入使用可信来源样本。早期 PSKReporter 条件切片的 RMSE 比较值降低 14.63 %，但历史子集上升 0.08 %；该比较不能区分传播信息增益与来源适配。

1.8 论文组织

研究问题与相关工作置于第 1 章；第 2 章交代观测来源、质量控制、物理基线及特征。第 3 章给出残差模型与稀疏区稳健化方法，同时报告构造方法所需的诊断实验。第 4 章在固定协议下集中比较主模型、特征组和负面结果。第 5 章描述持续学习系统与实际运行记录。第 6 章综合讨论证据边界、局限和研究结论。

1.9 文献综述

1.9.1 短波传播的经验—物理预测模型

短波传播的工程预测长期依托经验—物理模型。这类模型从太阳活动指数（太阳黑子数 SSN 或 10.7 cm 射电流量 F10.7）、地理位置、季节和时刻出发，估计电离层各层的临界频率与高度剖面。射线追踪随后判定跳数、反射高度等传播模式，链路预算再将发射功率、天线增益、自由空间损耗、电离层吸收和背景噪声[5] 纳入计算，输出最高可用频率（MUF）、中值信噪比与链路可靠度。

IONCAP 与 VOACAP。 美国国家电信和信息管理局开发的 IONCAP（Ionospheric Communications Analysis and Prediction Program）[1] 是该领域应用最广的实现之一。VOACAP 在此基础上针对广播覆盖分析作了改进，由于公开可得，已广泛用于业余无线电和短波广播。本文选用它的 Python 移植版 dvoacap 计算物理基线。

ITU-R P.533。 国际电信联盟无线电通信部门发布的该建议书[2] 规范了短波传播预测方法。它与 IONCAP 家族共享方法论源头，但在具体经验公式上存在差异，可视为相应的国际标准化方案。

国际参考电离层（IRI）。 COSPAR 与 URSI 联合维护的 IRI[6] 是电离层经验标准模型，它给出电子密度、温度和离子成分的气候学描述，常被用作传播模型的电离层输入。

这些模型的经验参数来自历史探测数据的**统计平均**，描述的是气候学意义上的典型状态，难以复现链路个体特征或跟踪实时扰动。第 2 章将用实测数据量化这项偏差，并观察它随路径长度的系统性变化。

1.9.2 众包观测网络

业余无线电社群在近十余年搭建的全球观测网络，持续积累了大规模短波链路实测记录。

WSPR 与 WSPRnet。 WSPR（Weak Signal Propagation Reporter）[3] 专为传播探测设计，以极低功率发射包含呼号、网格和功率的固定格式信标；接收端完成解码后，将结果和信噪比上报至 WSPRnet 数据库。固定协议、已知发射功率和统一参考带宽使 WSPR 记录具有较好的可比性，本文的历史数据集即取自该网络。

PSKReporter。 该网络实时汇聚 FT8、FT4、JS8 等主流数字模式的解码结果[4]。它的数据量远大于 WSPR，模式与功率却更为异质。本文以此作为持续采集的实时观测源。

Reverse Beacon Network（RBN）。 RBN 是面向 CW（等幅报）和 RTTY 的自动接收网络。文中未使用该数据，但它可为后续扩展模式覆盖提供数据来源。

三类网络都属于**机会式采样**：观测点随业余无线电人口密度而分布，并非由科学采样方案预先布设。这些网络在扩大观测规模的同时保留了空间覆盖不均，第 3 章将检验这种不均衡对模型的影响。

1.9.3 机器学习在电离层与传播预测中的应用

电离层与传播预测中的机器学习方法主要分为三类。

（1）预测电离层参数。 这类方法用神经网络或支持向量机估计 foF2、TEC（总电子含量）等电离层量，再把估计值送入传统传播模型。改变的是模型的输入条件，原有物理模型结构仍被保留。

（2）端到端预测链路可用性。 这类模型不借助物理模型，直接从观测数据预测链路是否可通或其信噪比。在数据充分的区域，这种做法可获得较好表现；进入观测稀疏区后，1.2 节所述的约束不足便会显现。

（3）物理引导的机器学习与残差学习。 物理输出在这条路线中被作为特征或基线，机器学习估计其观测偏差。气象模式输出统计后处理为这一思路提供了较早实例[7]，物理引导机器学习的综述讨论了更广泛的模型结合方式[8]。

直接面向短波链路的机器学习研究已探索不同的数据—模型组合。Taylor 基于八个地理分散站点的一个月 WSPR 数据评估 FIIPL 路径损耗模型[9]；Buckley 与 Furman 将 VOACAP 预测与近实时、类似 WSPR 的 SNR 报告及空间天气参数用于 HF 预测，并讨论与自动链路建立系统的结合[10]。Zhu 等使用多年全球实测数据比较 REC533、ICEPAC 与 VOACAP 的接收场强预测[11]。Wang 等以机器学习预测亚洲区域长期可用频率[12]；Yu 等研究面向中国 HF 通信的可迁移实时 MUF 预测[13]。Zhang 等基于实时斜向探测数据建立最大可用频率（MUF）预报模型[14]。该研究预测频率上限而非名义 SNR，两类任务的误差指标不能直接排序。这些研究的预测目标、数据覆盖与评价协议彼此不同：路径损耗、MUF 或场强结果不能与本文条件于成功上报记录的名义 SNR 直接按 RMSE 排序。本文据此将贡献限定为对该条件 SNR 目标的残差校正、稀疏查询输出诊断及运行期准入流程评估。 表 1-1 对比了相关工作的观测来源、预测时域与评价边界。

表 1-1 HF 预测研究的目标与评价边界

研究	观测来源与预测时域	预测目标	评价基线与可比性
Zhang 等（2025）[14]	8 条斜向探测链路；2024-04-23 至 2024-05-20；近实时	MUF；以实测最高观测频率评价	与 ITU、VOACAP 比较；预测频率上限，不输出本文定义的名义 SNR
Yu 等（2026）[13]	斜向探测；用此前 24 h 观测预测随后 24 h，并评估跨链路迁移	MUF	与 REC533、VOACAP 比较；时域和目标均不同，RMSE 不宜与本文直接比较
本文	WSPR 与 PSKReporter 的成功接收报告；按查询时刻条件估计，不设固定未来预报时域	名义接收 SNR	以 VOACAP 为物理基线并评估残差模型；时间留出参与阈值选择，报告为开发阶段比较

本文选用第三条路线，并检验其中两个前提。固定维度置零实验表明，当前残差架构对物理基线派生组高度敏感：RMSE 上升 131.6 %，12/12 折均变差。在本任务中，数据稀疏时回退至物理模型未必可靠。第 3.8 节的受控实验只覆盖两个目标距离段和六种稀疏设置，在这一范围内，纯物理基线的 RMSE 均高于数据驱动模型，更合适的回退目标是低容量残差模型。

1.9.4 梯度提升树

残差回归采用梯度提升决策树，其依据是 Friedman 的梯度提升框架[15]，XGBoost[16] 和 LightGBM[17] 等实现适于训练结构化数据。本文使用 19 个结构化特征，物理量可直接输入树模型，无需尺度归一化。持续学习数据扩展到 269.6 万条可训练

样本时，包含读取、训练与分来源评估的完整试运行在本机耗时 96.2 s（4.4 节），该耗时满足第 5 章周期性增量重训的需要。

梯度提升树的输出是**分段常数函数**；相邻输入一旦落入不同叶节点，预测值就可能发生跳变。在文中五条预设路径上，历史观测支撑较弱的两端场景总体呈现更明显的跳变，但中间路径并不严格单调；第 3 章将给出量化结果与适用边界。

1.9.5 持续学习与众包数据的可信度

持续到达的数据要求系统同时管理模型更新与数据可信度。

（1）新数据到来时，分布变化要求模型更新，也要求检查既有分布上的能力是否仍被保留[18]。增量更新中的新旧知识干扰和灾难性遗忘，已被持续学习研究反复讨论[19]。工业系统常采用”影子评估—灰度—上线”的模型替换流程，在同一测试集上确认候选模型更优后，才允许它进入生产环境。本文以准入门槛实现这一流程的简化形式。

（2）开放上报既会引入误报，也给恶意构造样本留下入口。系统因而将候选训练资料与决定上线的评价资料分开：通过格式校验的多来源数据可进入训练候选池，用户上报不进入准入测试集；准入测试只使用历史 WSPR 和后端自采 PSKReporter 记录。

1.9.6 研究空白与本文定位

已有物理模型提供可计算的传播基线，众包网络提供持续到达的链路观测，残差学习和持续学习分别提供校正与更新的技术路径。本文关注这些路径相接时尚需检验的问题：观测稀疏时，逐链路 RMSE 与用户所见的波段—时段网格可能给出不同的稳定性判断；当新数据进入训练后，系统能否公平裁决模型又取决于来源切分、早停和可信测试集是否彼此独立。

本文据此限定贡献：检验当前残差架构和稳健化策略在所测数据上的表现，报告数据清洗与评估协议改变结论的实例，并实现可追溯的运行准入流程。第 2 至第 5 章分别给出对应的数据、实验与运行证据。

1.9.7 不同预测对象之间不能直接替换的证据

“传播预测”可以指向几种并不相同的目标。电离层参数预测关心某位置和时刻的电子密度、临界频率或总电子含量；路径预测关心给定两端位置能否形成某种传播模式；链路预算进一步要求发射功率、天线和噪声假设；接收事件预测则要回答指定接收站是否真正解码。前一层通常是后一层的输入，却不是后一层的实测标签。即使

一个模型把 foF2 或 MUF 预测得很准，也不能仅凭该结果推出实际接收信噪比的误差；中间还隔着传播损耗、天线指向、设备增益、干扰和解码算法。本文把目标限定为“已被网络记录的接收链路的名义 SNR”，正是为了避免在一个指标下混用不同研究对象。

这种限定也决定了评价的分母。若研究“给定发射是否被接收”，分母必须包含已经发射而未被接收的时隙；若研究“已接收记录的 SNR”，分母则只是成功上报的链路。WSPR 和 PSKReporter 的数据库主要提供后者。对这些成功样本训练的回归器，可以学习成功接收条件下的 SNR，却不能从相同资料直接估计无条件接收概率。第 3.3 节因此将用户界面中的可靠度解释为工程评分，而不宣称其为经过校准的概率。

物理模型也有目标不一致的问题。VOACAP 在给定统计电离层条件、天线和噪声假设后计算的是工程链路量；众包接收报告由大量个人设备产生，其天线、接收机及噪声环境通常不可得。两者之间的残差既可能包括可学习的传播偏差，也可能包括源端、接收端和报告机制的差异。残差模型误差下降说明在当前观测分布上存在可利用的信息，不能自动解释为电离层参数本身得到更准确的物理估计。本文不以“纠正了电离层”描述模型结果，而是把结论约束在所定义的链路 SNR 目标内。

1.9.8 成功接收报告的选择机制

机会式网络记录到一条链路，至少需要发射端在该频率和时刻工作、接收端同时在线并守听、信号经过传播到达接收端、接收软件成功解码，而且上报路径没有中断。数据库中的缺席可能来自上述任一环节。它既不能直接标为传播失败，也不能无条件当作负样本。把“未上报”当作失败会将台站活动规律混入传播规律：欧洲夜间缺少某条远程记录，可能是路径闭合，也可能是收发任一端没有工作。第 6 章提出构造负样本的方案时，要求独立确认发射时隙和接收站在线状态，正是针对这一识别问题。

众包网络的观测密度由操作者位置、兴趣、设备配置和活动时间共同决定，而预设网格监测网按设计布设。样本密集区有利于降低条件均值估计的方差。若直接按历史样本比例计算总体 RMSE，密集区也会获得更大权重；这种口径适合评价“随机抽取历史记录”的误差，难以单独反映地图上指定远程路径的查询表现。因此，本文分别报告总体留出误差、距离段误差和预设路径的输出形态，对应样本分布、稀疏子群和查询表面三个评价对象。

选择偏差还会改变模型从观测中学到的条件关系。例如高频段只有在传播条件较好时才产生较多远程接收报告，数据中看到的高频长链路因而可能集中于有利时段。如果模型只观察成功上报记录，未见到同条件下未成功的尝试，就容易把“被记录的

条件”误当作“该频率总是可用”。这个问题不是简单增加样本数即可解决；当新增样本沿相同选择机制积累，原有盲区依然存在。本文的持续学习系统将采集吞吐量与覆盖率分开评价，并把新增记录的来源、模式和时段作为数据审计对象。

1.9.9 时间、空间与来源切分各自检验什么

随机划分训练与测试记录时，同一发射站、接收站、路径和相邻时刻可能同时进入两侧。模型即使没有显式的呼号特征，也可能通过坐标、时刻和频率的组合识别重复场景，因而得到对未来或陌生路径过于乐观的误差。按时间留出能缓解相邻记录泄漏，并检验较晚时段的表现，却不一定能检验新地理区域；空间留区则改变地理组合，但其测试集可能同时具有不同的距离、波段和站点活跃度。二者所得 RMSE 不应在不核对样本构成时直接排序。对于有时间、空间或群组结构的数据，交叉验证划分应匹配目标外推对象；这一原则也得到相关交叉验证方法学文献的支持[20]。

留一（年，月）协议仅检验 2021、2022、2024 年已采样的 3、6、9、12 月之间的迁移，不覆盖其他月份、2023 年或下一太阳周期。空间留区也改变路径长度和频率构成，结论限于该协议。生产系统按来源分层，并将用户上报排除在准入测试之外；各协议分别报告，不合并为单一泛化评分。

时间序列方法学也提醒我们，存在自相关并不意味着任何形式的时间交叉验证都有效或无效。结论取决于目标过程、预测时可得信息以及切分后训练与测试的依赖结构[21]。短波传播观测同时包含周期变化、太阳活动阶段和台站活动，不能把所有相关性归为单一时间趋势。本文记录各折的年、月构成，并在解释折间差异时先检查物理基线和残差目标的数值口径，再讨论太阳活动和时间覆盖。第 4.1 节的哨兵值案例表明，如果先把算法误差归因于“某年更难”，就会错过由目标编码造成的假差异。

1.9.10 持续学习中的分布变化与评价权

持续学习至少包含两个不同的动作：用新观测改变候选模型，以及决定候选能否替代在役模型。第一个动作是拟合问题，第二个动作是评价与治理问题。概念漂移研究强调数据生成规律可能随时间变化[18]；持续学习研究讨论新知识与旧能力的干扰[19]。在本文系统中，两类变化同时可能存在：电离层环境和太阳活动可改变真实传播条件，站点和模式的加入也可改变记录被上报的机会。仅观察历史 RMSE 上升，无法判断哪个过程起作用，更不能在测试集构成改变时把两轮 RMSE 之差当成模型的退化量。

开放上报还增加有意或无意的错误记录。已有数据投毒研究表明，攻击者可通过训练样本影响模型[22]，但其具体攻击模型不能直接套到本文系统。本文的分层措施只解决一个明确问题：不让用户自报样本同时成为其影响候选模型的训练材料和决定该候选上线的测试证据。它不保证训练集无污染，也不能抵御控制大量真实上报节点的攻击。第 5 章进一步区分字段格式校验、来源路径可信和观测事实可信三个层次。

在运行评价中，还必须区分“当轮配对比较”和“跨轮趋势比较”。候选和在役模型在同一轮、同一可信测试集上计算误差，门槛判定具有可比基础；不同轮之间，测试集会随着新数据增加而改变，横向连接这些点形成的曲线只是运营日志。一个后来模型在较难测试集上的 RMSE 更高，不能单独证明它不如先前模型。文中的晋升次数表示规则被触发的次数，不是固定测试集上的累计收益。

1.10 方法依据与可检验假设

本文的方法依据是物理模型提供可计算基线、统计模型拟合成功接收报告中的条件残差。可检验假设分别是：该组合在指定历史分布上降低 SNR 误差；时间邻域约束在所测设置下改善误差并降低网格相邻评分变化；低容量模型在所测稀疏距离段适合作为回退目标。本文所称“持续学习”指系统层面的持续采集、周期性重训和候选准入，不提出新的算法级持续学习方法。

1.11 研究问题与可检验命题的对应关系

四个研究问题不能靠同一张总体误差表回答。第一个问题要求明确“混合模型比什么模型好、在什么样本上好”。VOACAP 是工程物理基线，在历史时间留出集上可与混合模型配对比较；特征组置零只表明当前架构对某组输入敏感，不能代替一个重新训练的端到端模型对照。若删除物理派生组后性能仍保持不变，本文关于架构依赖的判断便会被削弱；若未来在相同容量、相同切分和相同可得信息下训练的端到端模型达到或超过混合模型，则“物理基线降低样本需求”的更强主张不能成立。本文在第 4 章只提出由现有对照支持的较窄结论。

第二个研究问题以波段—小时网格的相邻单元为对象，检验局部跳变。相邻格点的变化可能反映真实日变化，跳变指标因而须结合误差和物理参照判断；它目前只是界面可读性的代理量。五条预设路径呈现的是特定查询的输出形态。

第三个问题包含两个可分开检验的假设。其一，时间邻域正则化在低支撑处应减小不必要的局部波动，而不以明显的 RMSE 代价换取光滑；其二，主模型在低支撑条件下回退的目标应由实验结果确定。受控抽稀实验固定训练与测试行集，仅改变目

标距离段可供训练的记录数，因此可检验回退目标对样本稀缺程度的相对反应。第 3.8 节的结论限定于所测距离段与抽稀设置。

用户上报按来源和时间切分，可进入候选拟合；早停验证仅从可信来源样本中切出，准入测试也只使用历史 WSPR 与后端自采 PSKReporter 等可信样本。

四个问题所需证据并不相同：代码检查验证训练、验证与推理的基线口径，固定数据实验比较方法差异，运行快照核查系统实际执行过程；跨季节或跨太阳周期的可靠性需要新的冻结验证集。

1.12 本文的研究对象与工程对象

论文同时讨论预测方法和运行系统，二者的对象需要区分。方法对象是一条由收发坐标、时刻、频率、太阳条件和名义发射功率描述的链路；评价量是该条记录的实测 SNR 与模型输出之差。工程对象是一套持续收集成功接收报告、定期训练候选、执行准入规则并向用户展示结果的服务。方法上的某个改进，只有在相同预处理和模型产物被部署时才会体现在服务中；服务中的采集增长，也只有进入经过控制的实验协议才会成为方法效果证据。文中把代码路径、数据快照和图表的口径对应起来，是为了避免这两种对象在表述上互相替代。

实际查询只提供部分传播条件。用户能够指定两端位置、波段和计划时刻，却通常无法准确提供双方天线方向图、本地噪声、接收机状态及未来地磁扰动。模型使用的特征因此是可得条件的压缩表示，不是完整传播状态。即使在测试集中误差较低，一条尚未发生的具体通信也可能因局部设备和环境而大幅偏离预测。界面若把点估计呈现为确定性承诺，便会隐藏数据本身无法支持的精度。第 5.6 节的透明度设计将基线与校正、低支撑标记和模型版本同时展示，使使用者知道哪些内容来自计算，哪些内容只是待校准的评分。

本文先评价混合残差模型和稀疏区约束，再检查数据口径、评价泄漏及持续学习准入。接收概率校准需要失败接收记录，跨周期效果需要长期冻结测试窗。

1.13 使用情境决定预测时间尺度

短波传播模型可以服务于三种时间尺度。长期规划关心季节、太阳周期和典型路径的可用窗口，适合使用气候学物理模型和稳健的统计基线；近期预报关心未来数小时的频段选择，需要当时可获得的空间天气预报和最新观测；回顾分析则可以利用事件发生后的完整观测，解释某次链路为何成功或失败。本文系统提供按指定月份、时刻和太阳指数生成的路径预测，又通过持续采集改进模型产物，但并未完成实时电离

层状态同化。把它称为“实时精确预报”会把数据更新频率误认为状态估计能力。模型可在未来条件被正确指定时给出预测，却不会自动知道未来地磁暴或接收站是否在线。

不同时间尺度也要求不同的验证方式。长期规划若以月份平均可用性为目标，短时间留出集并不足够；近期预报应遵守信息发布时间，不能用事后公布的指数或报告；回顾分析可以使用更多事后信息，却不能把回顾性误差当成前瞻性能。本文核心实验使用历史成功接收报告的时间留出和交叉验证，生产系统记录当轮的准入表现。因此，它主要验证模型对已定义记录分布的误差以及系统更新机制。对完整太阳周期、突发扰动和真实通信任务的性能还需要独立研究。这个定位让论文既能讨论工程用途，也不把现有样本能回答的问题扩大成所有使用场景。

用户选择频段时，模型输出还会与其他决策因素一起作用。操作员可能优先考虑台站许可频段、可用天线、干扰水平、目标站活动、发射功率限制和通信模式。即使某一格点的预测 SNR 高于另一格点，也不意味着实际选择应只看模型排序。

1.14 相关研究比较的统一坐标

物理模型、纯数据模型和混合残差模型的文献若只比较一个 RMSE 排名，很容易把任务差异当成算法差异。较稳妥的比较需要至少写清六个坐标：预测对象是电离层参数、成功事件还是名义 SNR；频率和模式是否一致；输入是否在预测时可得；训练与测试的空间、时间和来源如何切分；是否包含未接收尝试；结果按什么样本分布和损失函数汇总。本文选用这些坐标解释第 1.9 节的相关工作，并在第 4 章只进行同一数据与协议内部的直接数值比较。其他论文即使报告更小的绝对 dB 误差，若使用不同信噪比参考带宽、不同台站选择或随机行切分，也不能直接据此判定其方法优于本文。

物理引导学习也存在多条技术路线。把物理方程放入损失函数、把物理模拟输出作为输入特征、在物理预测上训练残差、以及在两个模型之间按条件混合，都可称为“结合物理与数据”[8]。这些做法施加约束的位置不同。本文先以 VOACAP 输出定义残差，再把同一物理输出放入特征，并在稀疏处混合低容量数据模型。本文属于模型输出统计校正路线，与气象领域的 MOS 思路具有形式上的相似性[7]；传播链路与接收报告的选择机制决定了该方法仍需在本任务数据上验证。

机会式报告增多时，已活跃区域的条件分布会得到更细的刻画，训练目标也可能进一步偏向这些区域。众包网络的样本量因而需要结合覆盖分布解释。样本选择偏差研究说明，训练分布与部署目标不一致时，即使模型在训练分布上拟合得更准，也不

必在目标分布上更准[23]。空间分块交叉验证的方法文献提供了构造地理分离测试折的工具[20]，也有针对空间或环境分块的具体实现[24]。本文采取留一发射端经度区作粗粒度诊断，是对现有 93 500 条样本和极不均匀台站分布的折中；它没有提供严格的台站级隔离，不能把“六区误差相近”写成“所有陌生地区都有效”。

运行误差变化后，先区分传播条件、报告分布与系统口径的变化，再选择重训、重新加权、修复数据管道或调整评估协议。本文曾将折间难度变化归因于数据分布，后发现主要原因是 VOACAP 哨兵值。将各类变化笼统称为“概念漂移”无法说明具体原因，因此保留了各次归因及其反例。

1.15 文献结论向本任务迁移的条件

第一类迁移来自传播标准。IONCAP 与 ITU-R P.533 为短波电路计算提供物理和经验框架[1] [2]；P.372 提供无线电噪声的参考[5]。这些文献确立了频率、距离、电离层与噪声是链路预测必须考虑的因素，但其典型输出和工程假设与众包软件记录的名义 SNR 并非天然同义。若把标准计算值与众包报告直接相减，差值同时包含模型误差和设备口径差。本文保留 VOACAP 的条件输入与输出，并在第 2 章核对功率、哨兵值和字段单位，正是为使这种迁移成为明确的统计任务。

第二类迁移来自机器学习方法。梯度提升树与高效实现提供了拟合非线性条件关系的工具[15] [16] [17]，但算法论文通常不规定业余无线电报告何时出现、失败事件如何缺席、地理簇如何划分。把模型类从其他领域搬来，只解决函数拟合步骤，不解决目标定义和测试分布。物理引导学习综述说明有多种注入先验的位置[8]；已有可运行的物理基线和有限的成功报告，使残差校正成为可检验的结构选择。

第三类迁移来自评价方法。时空结构数据中的分块交叉验证提醒研究者，邻近记录常有相关性[20]；时间序列交叉验证又依赖具体的数据生成和预报任务假设[21]。本文既要面对不同年份和月份，又要面对相近接收站及路径重复，因此单一随机切分不足以回答所有外推问题。但分块越严格，样本越少且测试条件可能离训练目标更远。12 折留一（年，月）与发射端经度留区分别观察不同外推维度，二者不能相互替代。文献提供设计原则，适用性仍由本文数据的 12 个历史时间块和非均匀站点覆盖决定。

概念漂移研究讨论数据分布随时间变化[18]，投毒研究关注开放训练输入遭操纵的风险[22]。候选上线需经独立裁决，用户贡献不进入评价自身的测试集。现有权限和退化护栏便于审计，但不证明可抵御任意攻击。

物理标准、机器学习、评价方法与持续学习研究分别提供基线结构、可训练校正、比较规则及分布权限的分析视角。论文将这些视角用于同一条 SNR 预测链。本文的

新增价值在于把四者落到同一条可追溯的 SNR 预测链上，并如实检验它在已掌握数据中的收益与失败。文献为研究设计提供依据；跨太阳周期、跨模式和实际通信成功率由后续独立实验检验。

第二章 观测数据与质量控制

2.1 观测来源与数据集构成

固定协议下的训练和评估使用历史 WSPR 样本，运行期更新则另外纳入新获取的 PSKReporter 报告。两种来源的功率、模式、参考带宽和上报机制并不相同。因此，后续分析保留来源标记，将历史实验结果与运行期比较分别报告。

WSPR 历史数据（训练集主体）。 数据由 wspr.live 的公开查询接口[25] 获取。WSPR[3] 协议固定传输呼号、Maidenhead 网格与发射功率，链路两端的位置和发射功率由此成为已知量。其信噪比按统一的 2500 Hz 参考带宽报告，可在不同站点之间比较。WSPR 发射功率通常只有毫瓦至数瓦，链路接近解调门限，对传播条件变化较为敏感。

PSKReporter 实时上报（持续采集）。 PSKReporter 汇集 FT8、FT4、CW、JS8、VARAC 等模式的解码结果[4]，数据量大且到达及时，用于支撑第 5 章的持续学习闭环。采集链保留接收软件上报的名义 SNR（dB）；不同模式和客户端的检测带宽、解码门限与实现并未逐项校准，故该字段不能假定已经与 WSPR 严格统一到 2500 Hz 参考带宽。PSKReporter 也不提供发射功率，本文只能统一按常见值 50 W 处理。模式差异与功率近似会引入来源偏差，模型能否校正这类偏差仍需实验检验。受控消融中，移除 tx_power_dbm 等具有来源辨识力的特征后，历史分布上的误差反而增大（见 5.5.4 节）。

2.1.1 数据集构成

历史数据集按年份和月份分层采样，以纳入不同太阳活动水平与季节条件的组合。数据构成列于表 2-1。

表 2-1 历史链路数据集构成（2021、2022、2024；n=93 500）

项目	取值
链路总数	93 500
年份	2021、2022、2024
月份	3、6、9、12
波段	80m、40m、30m、20m、17m、15m、10m
太阳黑子数范围	17.0 – 157.1
路径长度	300 – 19 503 km（中位 1 655 km）
实测信噪比	−99 – +36 dB

表 2-2 历史样本与可还原分析子集的纳入流程

项目	记录数与说明
历史 WSPR 数据集	93 500；时间留出和历史总体分析的基数
通过经度反演及天顶角校验	93 137；用于可还原子集上的 12 折实验
经差反演无实数解（反余弦参数 > 1）	363（0.39 %）；按存储的两端纬度与距离反演；未进入后续天顶角校验

历史样本来自第 25 太阳活动周上升段：2021 年接近活动极小（SSN 最低 17.0），2024 年趋近极大（最高 157.1）。

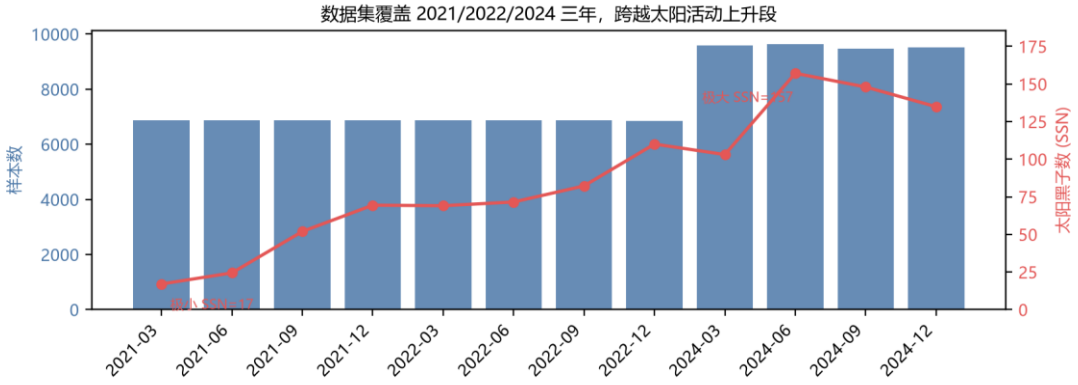


图 2-1 历史数据集的时间覆盖与太阳活动水平（2021、2022、2024）：蓝色柱表示各（年，月）组样本数（条），红色折线表示该组平均太阳黑子数 SSN（无量纲）

路径长度上的分布并不均衡。57.2 % 的链路短于 2 000 km，超过 14 000 km 的链路则只占 1.7 %。这一结构与机会式采样、台站地理集中、活跃时段和采集策略共同相关；现有数据不足以把它归因于单一人口分布因素。第 3 章据此检验低支撑距离段中的输出稳定性。

2.2 物理基线计算与口径一致性

每条链路都按其**实际频率**和**实际时刻**，结合两端坐标与当月太阳指数调用 VOACAP 引擎[1]。计算保留中值信噪比 SNR_{VOACAP} 与路径最高可用频率 f_{MUF}，回归目标则定义为实测信噪比与物理基线之差：

$$r = SNR_{\text{实测}} - SNR_{\mathrm{VOACAP}} \tag{2-1}$$

第 3 章以此残差作为回归目标。图 2-2 中，VOACAP 输出与实测值的分布几乎不重叠，误差更接近**可供模型学习的系统性偏移**，而非无结构的随机噪声。

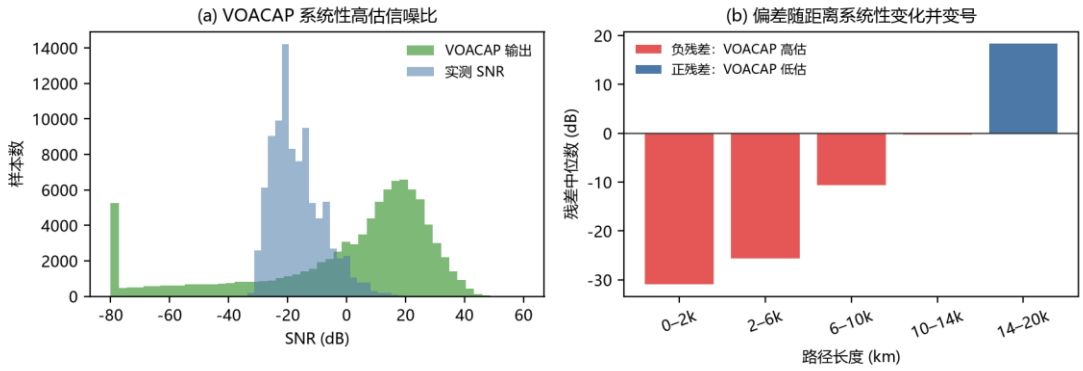


图 2-2 VOACAP 基线与实测信噪比的偏差特征（统一施加 SNR_floor = −120 dB）：(a) VOACAP 输出与实测 SNR 的分布（横轴：SNR，dB；纵轴：样本数，条）；(b) 各路径长度分段的残差中位数（横轴：路径长度，km；纵轴：实测 SNR − VOACAP SNR，dB）。红色柱表示负残差（VOACAP 高估），蓝色柱表示正残差（VOACAP 低估）

训练与用户端输出必须保持相同的基线计算口径。用户端输出以”波段 × 整点小时”给出，容易据此选用**波段代表频率**（如 20 m 取 14.1 MHz）和**整点小时**调用 VOACAP。训练数据却按每条链路的**实际频率**（如 14.0756 MHz）和**小数小时**计算。持续采集若按波段代表频率计算基线，而历史数据沿用实际频率，SNR_{VOACAP} 就会随数据来源产生偏移。残差以该列为基准，这种偏移会形成与来源相关的伪信号，且难以被常规检查发现。

为消除实现路径造成的口径分叉，历史建库与持续采集复用同一单点基线计算函数。早期采集程序曾对全部波段误用 20 m 参数，导致该批观测的残差相对历史训练分布偏移约 20 dB。修正后，历史 WSPR 训练集的残差中位数为 −26.13 dB（93 500 条），持续采集的 PSKReporter 观测为 −26.07 dB（2 888 307 条；数据截止 2026-09-12 08:17 UTC），按未四舍五入值计算相差 0.055 dB。

两组中位数没有相等的理论预期。PSKReporter 缺少发射功率字段，本文按 50 W 统一赋值（2.1 节）；WSPR 则使用实报功率。中位数差由约 20 dB 降至 0.055 dB，可用于核查错误基线口径造成的数量级偏移已经消失，不能据此证明两种观测机制同分布。模式、参考带宽、接收设备和上报选择仍可能造成来源相关误差。

VOACAP 的名义工程适用范围为 2–30 MHz，而持续采集的 PSKReporter 数据还包含 6 m（50 MHz）甚至 2 m（144 MHz）的上报。远离上限后，计算会返回 −1000 dB 量级的非物理基线，实测曾出现 −1169 dB；少量此类记录即可扭曲残差分布。采集端因而排除 6 m、2 m 等 VHF 记录，只保留 160 m 至 10 m。

2.2.1 闭合链路哨兵值及其处理

筛除远超适用上限的 VHF 记录后，数据中仍有前述 160 m 临界外推及闭合链路异常。VOACAP 为闭合链路返回极端负值，历史数据中的最低值为 -2838 dB，持续采集数据中为 -1773 dB。下表展示三条实测记录。

表 2-3 VOACAP 闭合链路哨兵值的实测样例（频率：MHz；距离：km；SNR 与残差：dB）

波段	频率	距离	SNR_{VOACAP}	实测 SNR	残差
20 m	14.07 MHz	18 689 km	-1772.8	-14.0	$+1758.8$
10 m	28.10 MHz	14 823 km	-344.6	-14.0	$+330.6$
10 m	28.10 MHz	1 644 km	-102.7	-26.0	$+76.7$

表中远低于可解释信噪比范围的极端负值，是 VOACAP 对闭合链路的编码输出，不能把 -1772 dB 等数值当作经过标定的接收信噪比。WSPR 在 2500 Hz 参考带宽下的典型解调门限约为 -30 dB，但该工程门限也不能直接代替逐链路传播判据。

这项异常会直接传入回归目标。 残差以 VOACAP 基线为基准，一条哨兵值因而可产生 $+1758$ dB 量级的目标。此类样本随路径长度增加而集中。

表 2-4 不同距离段中极端残差样本的占比（残差阈值：|r|>200 dB）

距离段	$\lvert r\rvert > 200$ dB 的占比
0 – 2 000 km	0.00 %
6 000 – 10 000 km	0.83 %
10 000 – 14 000 km	1.99 %
14 000 – 20 100 km	6.71 %

直接后果是，**超长路径段在指标上显得”极难预测”，但这在很大程度上是哨兵值制造的假象**。历史数据集中，14 000–20 100 km 段的残差 RMSE 高达 184.8 dB；将基线截断至物理下限后，该值降为 32.1 dB，降幅 83 %。被截断的样本却只占该距离段的 16 %。

这些记录保留在数据集中，仅把物理基线截断至 SNRfloor=-120 dB。物理模型判为闭合的链路仍可能出现实际接收，删除记录会使学习器看不到这类偏差。表 2-5 对不处理、剔除和截断三种策略进行同协议比较。

表 2-5 VOACAP 哨兵值处理对预测误差的影响（参与阈值选择的时间留出集；RMSE 与 SNR 误差单位：dB）

处理	干净子集 RMSE	失效链路上的信噪比误差
不处理	8.38	84.5 dB
剔除该类样本	8.21	214.8 dB
截断至 -120 dB	8.20	8.1 dB

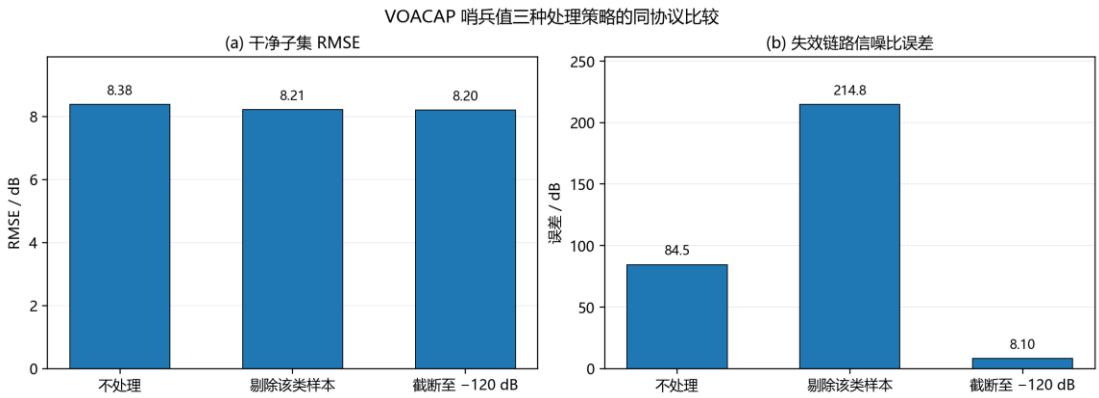


图 2-3 VOACAP 哨兵值三种处理策略的同协议比较：左图为干净子集 RMSE，右图为失效链路上的信噪比误差，数值与表 2-5 相同。−120 dB 截断在保留闭合链路样本的同时，将失效链路误差控制在 8.1 dB；该下限是本文受控扫描得到的工程取值，不表示通用接收门限

闭合链路的 VOACAP 输出在训练、评价和在线推理中必须采用同一处理规则。表 2-5 所示的失效链路误差从 84.5 dB 增至 214.8 dB，原因是在线 VOACAP 返回极端负值，而训练中没有出现过相应输入及残差。截断因此同时施加于训练目标、特征和推理，使三处使用同一个物理基线定义。

受控扫描支持以 −120 dB 为截断下限。失效链路的误差在各截断点间变化很小，维持在 8.1–8.3 dB；干净子集的表现随截断点加深而单调改善，−30 dB 时为 11.65，−60 dB 时为 8.72，−120 dB 时为 8.20。过浅的截断会把仍含传播信息的弱信号基线同时压平。所选下限只影响 1.7 % 的样本。

该扫描使用表 2-5 所列历史时间留出集比较阈值，因此 −120 dB 是由开发数据选出的工程处理值；该留出集不再构成这一阈值的独立确认集。

2.3 特征构建、空间天气与数据质量控制

年份、具体日期和目标链路的实测信噪比均未进入特征集，以维持训练与推理的定义一致；未来时刻的预测仍需指定太阳活动等外生条件。最终保留的 19 维特征列于表 2-6。

表 2-6 19 维在线可得预测特征及其物理含义

类别	特征	说明
几何	distance_km, mid_lat, mid_lon, abs_mid_lat, tx_lat, rx_lat	大圆距离、路径中点、两端纬度
时刻	sin_hour, cos_hour	UTC 小时的周期编码
季节	sin_month, cos_month	月份的周期编码
频率	freq_mhz	实际工作频率
太阳活动	ssn	平滑太阳黑子数
发射	tx_power_dbm	发射功率
物理基线	voacap_snr, voacap_muf, freq_over_muf	VOACAP 输出及工作频率相对 MUF 的位置
日照几何	zenith_mid, zenith_tx, zenith_rx	路径中点与两端的太阳天顶角

表中若干特征的处理方式需要进一步说明。

（1） **周期量采用正余弦对编码**，以消除 23 时与 0 时在数值上相距最远的伪断点。

（2） f/f_{MUF} **作为显式特征提供**，使模型直接获得工作频率相对于最高可用频率的位置。

（3） **太阳天顶角**由月份和时刻解析计算，可用作 D 层吸收与 F 层电离强度的代理量。

（4） 模型必须依靠 ssn 感知太阳活动，如果转而学习年份，就无法在未来时间推算。

低容量模型（见 3.8.4 节）从中保留 5 维输入：distance_km、freq_mhz、voacap_snr、freq_over_muf 和 zenith_mid。

2.3.1 数据的空间天气标注

持续采集的观测在入库时，还会附带太阳黑子数、10.7 cm 射电流量和地磁 Kp 指数等空间天气状态。NOAA SWPC 公开接口只保留近一日数据，无法回填历史 Kp。历史训练集因此缺少地磁扰动信息，而地磁暴对高纬短波路径的影响不可忽略。

第 5 章的持续采集在入库时为新观测写入 Kp 字段；该值不可得时，系统会以 2.0 当作回退填充值。后续特征实验只能使用带有有效时间匹配 Kp 的记录，并在其覆盖足以支撑独立验证后开展。

2.3.2 数据质量控制与审计口径

WSPR 与 PSKReporter 都属于机会式观测。质量控制识别可复算字段、隔离已知编码异常，并为训练与评价保留清楚的来源边界。本文把检查分布在入库、特征构造和数据切分三个位置；任何只在训练端执行、却没有同步到推理端的修正，都会改变残差的定义。

表 2-7 观测数据的主要质量风险、审计处理与残余限制

风险来源	审计处理	进入模型的口径	尚存限制
字段缺失或越界	统一解析时刻、坐标和频率；剔除 160 m 至 10 m 以外的记录	只保留能够复算 VOACAP 与几何特征的链路	格式校验无法识别上游客户端填报错误
来源间功率与模式差异	WSPR 使用实报功率；PSKReporter 按 50 W 处理并保留来源、模式	不假定两类来源的参考带宽与解码门限已经统一	功率缺失和接收软件差异仍可能形成来源偏移
VOACAP 闭合链路哨兵值	入库、训练和推理均将物理基线下限设为 −120 dB	残差仍定义为实测 SNR 减去截断后的基线	该下限是扫描确定的工程边界，并非逐链路解调门限
重复记录与相关样本	按 ts、tx_call、rx_call、freq_mhz 组成的键去重	重复键只保留一条记录	同一链路的连续上报仍可能存在时间相关性
开放上报造成评价污染	后端自采记录标记为可信；用户上报可参与训练，但不进入准入测试	早停与准入测试只读取可信来源，异常贡献按稳健规则处理	来源可信只表示采集路径可控，不等于单条观测必然正确
历史 Kp 无法回填	不把覆盖不完整的 Kp 混入当前 19 维核心特征	新观测保留 Kp，覆盖充分后再单独验证	强地磁扰动下的误差仍缺少固定协议检验

数据清洗后，表 2-6 所示来源差异仍然存在。PSKReporter 的名义功率、模式和客户端条件可能成为来源判别依据。本文所称“可信来源”仅指采集过程由后端控制；用户上报可进入训练候选池，准入裁决使用后端自采等可信来源数据。闭合链路记录仍予保留，用于比较实际接收与物理基线的偏差。

2.4 观测生成机制与覆盖审计

对成功接收报告作统计分析之前，需要弄清楚哪些事件有机会留下记录。一条报告的产生通常经历五步：发射端按某一功率、模式和频率工作；信号沿路径传播；接收端在相应频段守听；接收软件完成解码并形成名义 SNR；客户端把结果提交给网络。数据库只保存最后一步可见的结果。任何一步未发生或未成功，都可能导致没有记录。

这种缺席并不是一条数值为零的 SNR，也不是确定的“传播不可用”。本文的回归目标严格条件化在已上报的记录上，不把未记录的尝试补为负样本。

报告数量随活跃台站密度增加，记录密度因此不能直接解释为传播概率。欧洲和北美有较多活跃站点及接收端；即便传播条件相同，其报告数量也可能更高。相反，海上和无人区可能并非不能传播，而是没有足够的发射与守听机会。在训练中，常见场景获得更大的样本权重，模型自然更擅长拟合这些场景。增加总样本量若主要来自原本密集的台站，能进一步降低这些区域的统计波动，却未必改善少见的地理组合。

发射端和接收端的行为还造成时段偏差。业余台站的活动不是均匀的随机过程：本地工作时间、比赛、自动信标排程和夜间守听都会影响记录出现的时刻。模型输入采用 UTC 小时及太阳天顶角，能表达部分昼夜变化；但如果某地区在某一时段极少有接收站在线，训练资料依然无法区分“传播弱”和“没有观测机会”。对未来小时的预测因此具有条件性：它反映在历史成功报告所覆盖的设备与活动分布上学到的关系，而不是对任意潜在通信者的无条件保证。

解码与报告层也可能改变名义 SNR 的含义。WSPR 依固定窄带弱信号协议生成信标，发射功率包含在报文中；PSKReporter 可以汇聚 FT8、FT4、CW 和其他模式，发射功率通常缺失。不同模式的解码阈值、窗口长度和客户端实现不完全相同。即使字段都名为 SNR，数值也不必是统一物理带宽下测得的同一种量。本文将来源标记保留到入库和评估环节，并把跨来源残差中位数的一致性检查仅用作发现数量级错误的诊断，不把它当成仪器校准。

同一实际发射还可能被多个接收站记录；同一接收站也可能在短时间内反复上报同一路径。按 ts、发射呼号、接收呼号和频率去重，能够移除明显的重复键，却不能让剩余记录统计独立。若多个相邻报告共享相同电离层条件和硬件状态，随机行切分会把高度相关的观测放到训练与测试两侧。本文的时间块与空间留区协议用于减弱这种问题，但也不能消除所有站点层级相关性。下一轮实验若要给出严格置信区间，应明确以日期、站点或路径作为重采样单元，而不是把每条报告视为一个独立伯努利试验。

2.4.1 冻结数据的覆盖与集中度审计

覆盖审计使用两份冻结输入：93 500 条历史 WSPR 数据，以及截至 2026-09-12 08:17 UTC 的运行观测快照。补充材料列出两份输入的冻结行数和 SHA-256 摘要；原始观测及个人日志不随包提供。本段数字仅描述对应文件的构成，不能代表全球短波通信总体分布或模型效果。

历史表的 93 500 条记录来自 2021、2022、2024 年，对应数量分别为 27 552、27 552、38 396 条；固定样本未收入 2023 年记录。月份只有 3、6、9、12 月，各月约 2.3 万条。这四个月份锚点覆盖不同太阳活动水平，时间轴仍不是连续的逐月序列。留一（年，月）交叉验证据此只能检验 12 个已采样时间块之间的迁移；若要评价 1、2 月等未出现月份，必须另采固定测试集，不能把现有折间平均值解释为全年表现。历史表各 UTC 小时约有 3 746 至 3 920 条，小时维较均衡，这主要反映建库时的采样设计，并不意味着全球台站的活动本来均匀。

距离分布更明显地偏向短链路：短于 2 000 km 的记录为 53 479 条，占 57.197 %；2 000 至不足 5 000 km 为 25 003 条，占 26.741 %；5 000 至不足 10 000 km 为 11 335 条，占 12.123 %；10 000 至不足 14 000 km 只有 2 094 条，占 2.240 %；14 000 km 及以上仅 1 589 条，占 1.699 %。七个历史波段各有约 1.3 万条，因此波段数量的表面均衡并没有抵消距离维的稀疏。一个跨洲查询虽然选择的是常见波段，却仍可能落在该波段的少数长路径组合中。模型在总体留出集上表现良好，不能推出对这类组合具有同等误差。

运行快照的观测表有 2 889 356 条，时间覆盖 2026-08-03 08:32:47 至 2026-09-12 08:17:44 UTC。8 月占 2 711 762 条，9 月仅 177 594 条；它在样本量上远大于历史表，在年份和月份维却更窄。来源中，后端自采 PSKReporter 有 2 888 307 条，用户上报 1 049 条。模式以 FT8 为主，共 2 786 190 条，约占 96.4 %；FT4 为 68 241 条，CW 为 19 843 条，其他模式更少。新增数据的快速增长因此主要提高了某一来源和某一模式在近时段的密度，不能把“多了近三百万条”直接读成所有季节和通信模式都已被覆盖。

新采距离结构与历史样本也不同：短于 2 000 km 占 46.987 %，5 000 至不足 10 000 km 占 23.853 %，14 000 km 及以上仍只占 1.620 %。新采表有 34 177 个非空接收呼号，但按记录数排序最活跃的 342 个呼号，即约 1 %，贡献了 34.339 % 的全部记录；前十个呼号贡献 6.131 %。呼号不必等于独立人员或设备，因此这只是报告集中度，而非参与人数或地理覆盖的精确计数。集中度说明：大量记录可能来自少数持续在线接收端，行数增长不能按独立样本数线性解释。

描述性审计发现，历史表中有 1 544 条 VOACAP 输出不高于 −120 dB，运行快照中有 46 291 条；前者约占 1.65 %，后者约占 1.60 %。两套资料均包含需要处理的极端基线编码。新采表的 Kp 字段没有缺失值，但 2.3.1 节所述的 2.0 回退填充也会产生

非空记录。将来使用 Kp 建模时，应分别标记独立时间匹配的观测值与回退值，并检验两类记录的影响。

这组审计把数据规模、时间覆盖、模式构成、距离分布和接收端集中度分开报告。它支持两个较弱而明确的判断：固定历史资料在短距离和四个采样月份上更密集，运行快照在近时段 FT8 与少数活跃接收端上更密集。它不证明哪种模型更好，也不证明任何来源必然存在恶意数据。第 3 章据此定义低支撑情境，第 4 章采用分块和分段评价，第 5 章解释新采训练的收益与外推限制。

2.5 名义 SNR 测量、来源差异与特征可得性

将两类网络的 SNR 放入同一回归表时，需要说明这个数值承载了什么。一个简化的链路预算可写为“接收信号功率减去所采用带宽内的噪声功率”，而接收信号功率又取决于发射功率、传播损耗和两端天线增益。众包记录中的名义 SNR 不是对上述每个量的独立测量；它由特定解码软件和接收环境计算。令 Y 为被报告的 SNR，B 为 VOACAP 在给定工程假设下的输出，则回归目标 $Y - B$ 同时含传播模型误差、未记录的天线和噪声差异、软件的测量口径差异及随机扰动。残差模型能拟合这些成分与已知特征的统计相关性，却不能从一条记录分离其物理来源。

发射功率提供了一个具体例子。WSPR 报文含功率，历史数据可按报告值转换为 dBm；PSKReporter 不提供同等字段，系统统一写入 50 W，约为 46.99 dBm。这个常数满足 VOACAP 调用所需的输入完整性，却不表示每一台 FT8 电台真的使用 50 W。若实际功率较低，基线相对实测值可能系统性偏高，残差也随之偏负；若实际功率较高，方向可能相反。模型若把固定的 46.99 dBm 与来源、波段和时刻一起利用，可能在平均意义上补偿该假设，却无法恢复未提供的逐条真实功率。第 5 章讨论的来源分层因此不仅是安全措施，也是避免把不同测量口径盲目合并的统计措施。

噪声参考带宽也影响数值解释。若同一噪声谱密度在两个带宽 B_1、B_2 内积分，理想白噪声模型下的噪声功率差为 $10\log_{10}(B_2/B_1)$ dB。这个关系说明不同参考带宽下的名义 SNR 不能直接按同一个数字比较；但它不能作为本文对 PSKReporter 记录进行逐条转换的公式，因为其客户端模式、滤波和报告定义未被完整核实。强行套用一个理论带宽修正值，可能制造比原差异更大的错误。本文保留来源分片结果，并把跨源绝对 SNR 的一致性列为尚未解决的测量问题。

“接收成功”还会截断观测到的 SNR 分布。信号弱到软件不能解码时，记录通常不会出现，因此样本中的低 SNR 尾部受模式阈值和接收站配置共同决定。若模式 A 比模式 B 能在更低的 SNR 解码，两类成功报告的均值差异既可能反映传播条件，

也可能只是检测门槛差异。单纯对成功样本的 SNR 做均值校正无法辨别两者。后续若要估计链路可用概率，必须有发射排程、在线接收站和未解码事件的配对记录，且要明确概率对应的模式、带宽和设备条件。

2.5.1 特征可得性与因果解释边界

一个变量能否作为预测输入，首先取决于未来查询时能否以相同方式取得它。距离和路径中点可由两端坐标计算，小时和月份来自目标时刻，太阳天顶角由位置与时间解析计算；太阳活动指标需要指定或引用预测值，VOACAP 输出和 MUF 再由这些条件及模型假设求得。实测 SNR 要等目标链路事件发生并上报后才可知，因此不进入预测输入。年份虽在历史训练中已知，但用它标记场景可能使模型记住“2024 年对应的平均偏差”，这一关系无法直接用于尚未出现的年份。当前设计显式输入太阳活动状态，以避免依靠年份记忆场景。

有限历史样本中，太阳黑子数可能与年份、季节及地理活动分布相关；树模型依据 ssn 分裂时会同时利用这些信息。路径中点和两端纬度描述几何位置，也可能帮助树模型识别常见台站簇。物理基线由距离、频率、时间和太阳活动共同计算，与原始特征天然相关。因此，特征重要性和置零消融描述的是给定训练分布与模型结构中的信息利用；第 4.2 节将其解释为“架构依赖”，不据此识别自然过程的独立因果效应。

对空间天气字段尤其应遵守这一原则。运行表中的 Kp 非空，并不意味着未来时刻的 Kp 一定可在预测前获得，也不意味着历史训练集中的 Kp 可以可靠重建。若用事件发生后才发布的真实 Kp 去预测同一事件，就可能获得不适用于未来预报的回顾性效果。严格实验至少需要记录指标的发布时间、预测发起时刻和当时可得的预报值。当前核心模型不引入 Kp，避免用不一致的可得性换取表面精度；第 6 章将其列为需要新数据和新协议的后续研究。

各特征的单位在输入管道中逐项确定。频率以 MHz 输入，距离以 km 输入，功率以 dBm 输入，SNR 以 dB 输入。freq_over_muf 为无量纲比值，若 MUF 计算失败或接近零，应由特征管道按既定规则处理，不能让无穷大进入模型。周期编码中的正余弦值处于 $[-1,1]$，表示 UTC 小时或月份在圆周上的位置；它们让 23 时与 0 时靠近，却不会自动补充没有观测的中间月份。单位与异常值处理决定训练、离线评估和用户查询三处的输入定义能否一致。

2.6 清洗决策与样本选择

哨兵值处理会改变监督目标，因此需比较各备选方案。闭合链路哨兵值可以原样保留、删除对应记录，或截断物理基线。原样保留时，少数极端编码值主导平方误差。删除记录虽去掉异常目标，也会失去“物理判闭合但实际收到”的反例和推理时的同类支持。截断保留这些记录，并以扫描选出的工程下限约束编码异常。表 2-5 比较了三种方案。在当前任务和受测阈值中，-120 dB 截断更符合预测目标，其取值不具有普遍接收门限的含义。

长路径 RMSE 曾先后被归因于数据量和时间覆盖不足；逐条核对误差与物理输出后，才定位到 VOACAP 哨兵值污染。这个排错过程提示：遇到折间难度或长路径误差异常，应先检查标签和基线编码，再判断样本规模与模型容量。

这种审计顺序并不保证找到所有问题。PSKReporter 的逐条真实功率、接收噪声、天线方向图和软件内部 SNR 算法依然不可得；来源可信只表示系统控制采集路径。论文据此把清洗结果称为“已识别异常的控制”，不称为“获得无偏真值”。以这个边界进入后续实验，才可能解释为何历史集与新增来源的误差方向不完全相同，也为未来的数据协议改进留下明确目标。

2.6.1 目标分布与重新加权条件

选择偏差研究通常区分训练样本的产生机制与目标部署人群或场景的分布[23]。在本文任务中，历史 WSPR 记录分布、近时段 PSKReporter 记录分布和用户可能提出的查询分布都不同。设 $q(x)$ 表示某一目标查询条件的频率，$p(x \mid D=1)$ 表示成功上报记录的条件分布；若想把在后者上测得的误差换算为前者的平均误差，需要知道或估计两者的相对权重，还需要目标查询条件在训练数据支持范围内有足够覆盖。当前系统没有完整的用户查询日志，也缺少未上报通信尝试的分母，因此无法为“所有潜在短波链路”构造可信的 $q(x)$。本文不使用一个想象出来的均匀地理分布去重新加权主结果。

这个限制不意味着加权评价永远不可行。可以先定义一个较窄且可观测的目标，例如已授权保存的真实用户查询，或由研究者预先列出的固定路径、波段与小时网格。然后检查目标条件与历史成功报告在距离、纬度、频率和太阳活动上的重叠程度。若某些目标格点附近没有训练记录，任何重要性权重都会非常大，少数样本会支配估计；此时应报告“无支持”，而不是对每个格点强行给出高精度平均误差。若存在足够重叠，可在冻结测试集上比较未加权与加权指标，并记录权重截断规则及有效样本量。

本文的五条参考路径是预先选定的诊断场景，尚不是经过用户分布抽样得到的加权总体。

来源分层的生产测试集也有类似权重问题。早期可信测试集中，历史 WSPR 占约 81 %，新采 PSKReporter 占约 19 %；整体 RMSE 因而更多反映历史记录。随着新采积累，来源比例会变化，整体误差的解释也会随之变化。固定来源权重可以构造一个跨轮可比较的汇总指标，但只有在各来源内部测试条件也被固定时才有效；如果 PSKReporter 内部月份和站点组成同时变化，单一权重无法恢复可比性。更稳妥的做法是在预先冻结的数据上分别报告来源指标，并把整体权重作为明确的决策选择，而不是隐藏在当前行数之中。

数据选择还影响模型训练目标。若以平方损失直接拟合 93 500 条历史成功记录，短于 2 000 km 的链路贡献超过一半行级损失，14 000 km 以上只有约 1.7 %。人为对长路径过采样可能改善该段，却也可能增加噪声、伤害短路径或改变概率解释。本文当前的稀疏区策略没有用训练重加权来制造均衡，而是在输出端按可用支撑调节正则化与回退。未来若比较过采样、加权损失和局部回退，应让三者共享原始测试分布和相同分段报告，否则训练分布改变会与评价分布改变纠缠，无法判断哪种机制有效。

2.7 数据版本、观测机会与有效信息量

上游返回的观测先写入 JSONL 缓冲，批量处理时补充空间天气、计算 VOACAP 与残差，再合并到主 parquet 文件，随后才可能进入新一轮训练、验证和测试切分。各阶段均有时间戳与版本记录。表 5-2 的运行数字同时列明截止时刻、上游来源、处理代码及文件摘要；本次覆盖审计还为两份固定输入计算 SHA-256，并给出 UTC 起止时间，供复算时核对是否使用同一字节内容。

字段血缘同样重要。distance_km 来自两端坐标的几何计算；band 从频率映射；ssn、sfi 与 kp 来自空间天气服务或回退值；voacap_snr 与 voacap_muf 来自物理引擎；residual 必须由同一条记录的实测 SNR 减去经过下限处理的物理基线。若某项字段在历史建库和持续采集中由两段不一致的代码生成，模型可能学到“来源”而不是传播条件。早期把各波段误按 20 m 参数计算的事件，正是字段血缘不一致造成的实证例子。用同一单点基线函数复用处理路径，比事后仅对两个残差分布做中位数对齐更能控制这类错误。

动态字段还必须区分事件时间和处理时间。PSKReporter 分组接口缺少逐条事件时刻时，系统以采样时刻记录，10 分钟回溯窗口带来相应的时间误差上界；这会影响由时间计算的太阳天顶角，也可能影响空间天气匹配。数据库中的 ts 因而不总是毫

秒级真实发射时间。扩展模型若引入快速变化的地磁指数或日出边界，应先提高事件时间精度，否则新增特征可能只是把时间误差转化为更复杂的噪声。论文现阶段用小时和月份等较粗特征，仍需在用户端解释近边界时段的外推风险。

字段审计还要照顾产物回溯。一个上线模型对应当时的训练池、特征顺序、物理基线下限、早停验证集、测试集和偏差常数；将来重跑同样文件名的脚本，若上游数据已经增长，产物不必相同。保存模型元数据、输入摘要和训练报告，可让一次预测追溯到使用哪个版本的假设。本文的论文表格用固定截止点描述系统，不把最新页面数值静默覆盖旧快照；若定稿时刷新，应同步更新摘要、表、图注及讨论中的时间范围，而不能只改观测总数。

复核材料包括聚合分布、处理脚本和输入文件哈希。正文不列公开报告中的逐条呼号和网格，以免暴露台站活动规律；复算者应按上游数据条款获取原始记录，并用摘要核对版本。用户主动提交的个人日志比公开接收报告更敏感，应与浏览器回传分别授权和处理。

2.7.1 观测机会与缺席记录的识别问题

成功报告是一个带选择机制的观测，而不是一次随机抽取的链路试验。为了说明这一点，可把一条潜在记录拆为三个事件：发射确实发生，接收端有机会观察，接收软件成功解码。数据库里的正样本要求三者同时成立，还要求客户端成功上报。若数据库中找不到某条链路，至少有四种解释：无人发射、无人守听、信号未达到解码条件、报告链路故障。仅有成功记录时，这些解释没有可识别的分母。把每个未见到的时空网格直接标为失败，将大面积无人活动区误写为传播失败；把缺席完全忽略，又不能回答通信可用率。本文选择后一种有限目标，即预测已经发生并被报告的接收事件的名义 SNR，同时明确不估计所有计划通信的成功概率。

这种目标限定也影响论文用词。回归模型在某一小时给出的数值，是在历史成功报告的设备和活动条件下，条件 SNR 的点预测；它不能保证用户按任意功率、任意天线发射后会收到该 SNR。尤其当查询位置远离活跃台站，模型可能在形式上仍能输出数值，而相应条件在训练资料中的支持很弱。界面可靠度评分可以提醒这种外推，却不能因数值落在 0 至 1 之间便被解释为接收概率。第 3.13 节的区分从数据生成机制出发，而不是仅由界面术语决定。

若未来要建立可检验的负样本协议，可以从固定时隙的发射计划开始。每个时隙应记录发射呼号、地理位置、频率、模式、功率和实际发射确认；对每个目标接收站，应记录它在该时隙是否在线、是否监听相应频段、软件是否工作、是否有成功解码及

上报。只有前两个事件经独立确认，未解码才有资格成为传播与接收系统共同作用下的失败事件。即便如此，该负样本仍包含接收机和本地噪声影响，不是对电离层单独判负。若某站在线状态只能由“它有报告”反推，失败时在线状态不可见，分母仍然缺失。

受控发射也要防止发射排程与测试条件共变。若只在预期好的波段发射，负样本比例会被策略本身改变；若接收端在收到信号后才记录在线，就会发生结果依赖的纳入。更严格的设计应在事前固定路径、小时和波段网格，保存没有报告的完整时隙，按设备和日期汇总成簇，并把网络中断单独编码为不可判定。这样的资料可支持接收事件概率、不同阈值的校准和对运营策略的评价；它和本文现有成功报告表不是同一种数据对象，不能只通过给旧表补零得到。

2.7.2 重复、相关性与有效信息量

第二个容易被行数掩盖的问题是同一物理条件下的多重记录。一台发射机在一个时隙发出的信号可能被许多接收机同时解码；这些记录共享发射功率、空间天气和部分传播环境，却有不同终点设备与噪声。一台自动接收站又可能每隔数分钟记录近似路径，形成连续序列。按完整键去重只能防止字面重复，无法把相关观测变成独立实验。运行快照约 289 万行的数量，因而不能直接与 289 万次独立链路试验画等号。

相似报告在训练时改变样本权重，在评价时改变测试难度，两种影响需要分别看待。常见路径反复出现时，它在平方损失中的权重上升，模型对该路径的估计方差可能下降；少见路径未必得到同样改善。评价阶段，若训练和测试同时包含同一台站、相邻时间及相似频率，测试误差可能主要反映对熟悉簇的插值。时间块留出改变了日期条件，空间留区改变了地理位置条件，二者都比随机行切分更能触及外推；然而两种留出仍可能共享发射端、硬件类型或长期活跃的接收网络。它们分别是更严格的测试，并非完全消除相关性的证明。

若为模型差值建立不确定区间，重采样单元应与研究问题相配。研究“未来日期”的稳定性时，先按日期或连续天气过程形成块，再重采样这些块；研究“新接收区域”的稳定性时，应以地理区域或站点簇为单位；研究“新路径”时，以发射端和接收端组合形成簇。对每个重采样副本，两个模型必须在同一行集上配对计算误差差值，不能各自抽样后再比较。不同分组方案对应不同外推总体，应同时报告其定义，而不是挑选使置信区间最窄的一种。

接收端集中度审计提示必须检查记录间的关联，但尚不能据此计算有效样本量。前 1 % 呼号贡献 34.339 % 记录，说明单个站点的活动权重可能很高；但一个呼号也

可能对应共享设备或移动位置，相同设备可能更换呼号。由呼号计数推断独立设备数，仍需核验标识的稳定性。对无法识别的关联结构，可以先报告按呼号、日期和地理网格分别聚合后的误差敏感性，把差异作为稳健性诊断。只有在这些聚合尺度下结论方向保持一致，才有较强理由称结果不依赖某一小组高活跃节点。

2.8 覆盖报告与清洗规则代价

“覆盖广”可能指已经出现的记录遍布多个大洲，也可能指每个目标查询格点都能找到相邻记录，二者差别很大。本文在第 2.4.1 节报告年份、月份、距离和波段的边际分布；这些边际充足并不保证交叉单元充足。例如某波段总体超过一万条，可能主要集中在近距离和少数地区；某一月份总体均衡，特定长链路仍可能只有个位数。要评价稀疏区方法的适用范围，需把路径距离、地理区域、波段、时段和太阳活动状态合并考察，并在合并后仍保留每个单元的样本分母。

交叉单元不能无限细分。若每个维度都按十档切分，维数相乘会产生大量空格；空格可以表示“本次没有观测”，却不能自动表示传播不可用。合适的审计顺序是先声明决策关心的单元，再选择与样本量相称的分辨率，并同时给出空单元比例和有记录单元的样本分布。对预测用的连续输入，硬分箱仅是报告工具，不能被误当作模型的真实决策边界。第 3 章使用距离支撑函数，是因为在现有历史资料中，距离维稀疏有明确证据且可稳定计算；这不表示距离足以概括所有联合覆盖。

对数据增长的评价同样要有固定分母。若前一次快照只有 8 月，后一次快照新增 9 月，比较总记录数当然上升，但真正的问题是哪些预设单元由无记录转为有记录、哪些低支撑单元的有效簇数增加，以及新增记录是否来自新的接收端。一个可复算的覆盖报表应固定分箱、固定目标路径集和时间截止点，分别列出行数、独立日期数、发射端数和接收端数。本文的冻结审计已经建立文件摘要与基本分布；联合覆盖和有效簇数尚未计算，故本节仅给出方法要求，不把这些未生成的指标写成结果。

若未来把用户查询分布作为目标，覆盖分母还需要保护隐私。系统可在获得授权后按较粗的区域、频段和时间桶聚合查询，避免保存可还原个人行动的逐次精确坐标。聚合后仍应检查少数桶是否能识别个体；若不能取得可信且合规的目标分布，则应维持“在观测成功记录分布上评价”的限定。覆盖的统计目标、数据许可和用户可见的可靠度提示应使用同一套定义，否则论文称为低支撑的区域可能与界面标记的区域不一致。

2.8.1 清洗规则改变目标总体的代价

每条清洗规则都会在“减少错误记录”和“改变可研究总体”之间作选择。对重复键去重可防止同一报告在训练中被多次计权，但若两条记录使用相同时间、呼号和频率而来自不同接收链路或不同网络转发，简单去重也可能误删有效信息。对残差异常值使用固定阈值能减轻平方损失被极端记录支配，却可能删除真正罕见的跨洲传播。对模式或距离设定黑名单能得到较整齐的数据表，却使论文结论只适用于剩余子集。因而“清洗后 RMSE 更低”不一定表示模型更能服务原本要预测的全部场景，它也可能表示困难记录被排除。

物理哨兵值被截断，整条链路记录仍予保留，包括物理模型判为闭合而实际接收成功的情况。−120 dB 下限处理的是数值编码，不作为删除难例的依据。若未来发现在某些模式或地区截断后的特征大量堆积于同一个下限，模型可能无法区分不同程度的物理失败；应报告堆积比例，并在固定测试集上比较不同基线编码或显式的闭合标志。当前覆盖审计已给出两份文件低于下限的记录数，尚未按路径、模式和时段交叉审计这些记录，因此不能推断某一子群是否被集中影响。

清洗规则的敏感性实验应先冻结原始行集，然后对同一测试身份重复生成不同处理版本。处理 A 与 B 若改变了训练行，但测试行和目标定义仍相同，可以比较它们对同一任务的预测；若连测试行也不同，则先报告各版本保留率和被排除样本特征，再分别解释指标。对被排除的记录尤其要保存原因编码，如解析失败、坐标非法、基线非数值、重复键或来源权限，而不是统一写成“质量差”。在一个持续系统里，拒绝率若突然升高可能来自上游接口变化，不能仅解释为观测网络恶化。

评估清洗效果还应有负面控制。若某规则声称修复 VOACAP 特有的哨兵值，它在没有哨兵值的记录上不应产生相同数量级的变化；若声称提高长距离预测，应检查短距离和不同来源是否受到副作用。负面控制不能证明因果识别，但能暴露规则作用范围与解释不符。本文历史实验对哨兵值问题做了多处入口一致性检查，并保留整体和长距离段的前后数值；其他清洗规则尚未建立同样完整的反事实表，故不在论文中归因其独立收益。

重建残差目标需要锁定输入版本，并保留原始字段、变换程序及删行依据。只发布训练后的数据文件或模型产物，无法区分网络原值、解析错误与清洗决策。补充材料提供代码、字段处理说明及不含原始日志的复现清单；受数据访问限制的步骤仍需研究者依法取得相应输入后复算。用户日志的保留期限、删除流程、访问权限和二次用途规则尚未制定，因此本文不将逐次上传确认表述为完整的数据治理制度。

第三章 混合预测模型与稀疏区稳健化

3.1 总体架构

传播预测由物理估计与残差校正组成。待预测链路记为 **x**，其状态由两端坐标、频率、时刻、月份及太阳活动指数共同确定，模型输出为：

$$\widehat{SNR}(\mathbf{x}) = SNR_{\mathrm{VOACAP}}(\mathbf{x}) + \hat{r}(\boldsymbol{\phi}(\mathbf{x})) + b_{val} \qquad (3\text{-}1)$$

式中，$\boldsymbol{\phi}(\cdot)$ 表示第 2.3 节定义的特征构造函数，$\hat{r}$ 为残差回归器，b_{val} 则是仅凭独立验证集估计的常数偏差校准量（3.2 节）。各变量在模型中的传递关系见图 3-1。

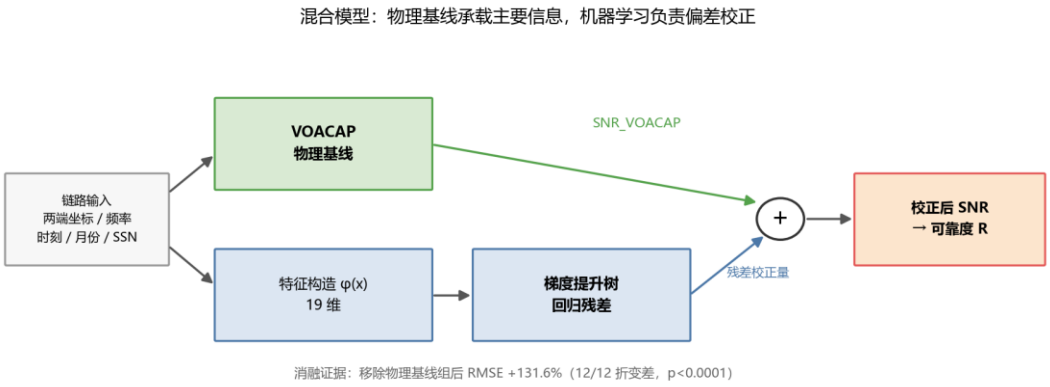


图 3-1 混合预测模型架构与变量流：VOACAP SNR、MUF 等物理基线特征与 19 维输入共同进入梯度提升树残差回归器，输出校正后 SNR 与可靠度 R；绿色表示物理基线通路，蓝色表示数据驱动通路，橙色表示最终输出

以残差为学习目标的依据如下：

（1） **残差建模动机。** 回归器拟合的是实测值相对物理估计的差额；物理估计先由距离、频率和电离层条件算出。因此，物理输出参与定义了回归目标；样本效率由后续同数据、同容量的端到端对照检验。

（2） **稀疏区的可退化性。** 将校正量设为零会使输出等于纯物理估计。由于实验中这种回退效果较差，实际方案改用低容量模型。

（3） **可解释性与可诊断性。** 校正量对应给定条件下物理估计与观测的差距。校正量的幅度与分布标出需要大幅修正的条件，也为误差追踪提供入口。

置零后 RMSE 上升 131.6 %，12 折均劣化；该方向一致性作为开发阶段的描述性结果，不作独立确认性推断。

该 12 折比较属于方法开发评估，所列名义检验概率不构成独立确认性证据；其解释还受折数有限及特征组置零未重新训练模型的约束。

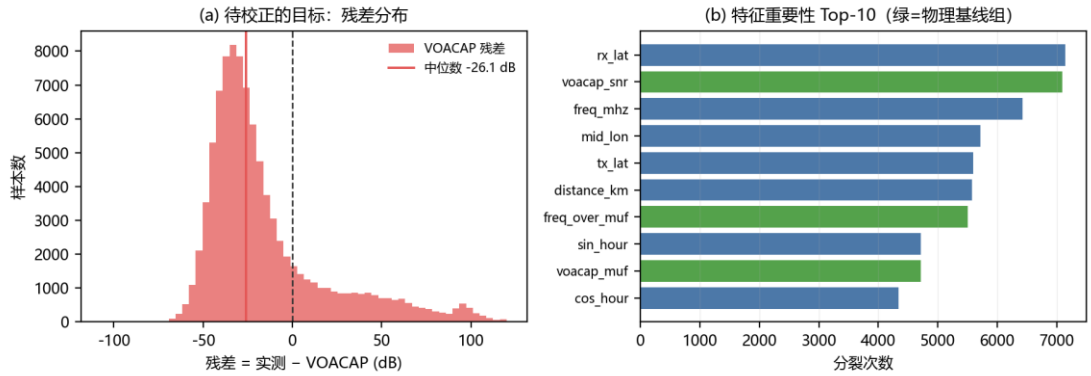


图 3-2 残差校正目标与特征重要性（历史数据集；LightGBM 分裂次数）：(a) 残差 = 实测 SNR − VOACAP SNR 的分布（横轴：残差，dB；纵轴：样本数，条）；(b) 前十特征的分裂次数（横轴：分裂次数，次；纵轴：特征名）。绿色表示 VOACAP 基线特征，蓝色表示其他特征

3.2 残差回归模型

残差由梯度提升决策树[15]拟合，具体采用 LightGBM 实现[17]。实验与生产环境使用的主要超参数列于表 3-1。

表 3-1 梯度提升树模型超参数及实验/生产口径

参数	第 3、4 章固定实验	2026-08-30 模型	生产快照 说明
提升轮数上限	1 500	1 500	由早停实际决定；2026-08-30 在役产物快照为 1 311 轮
学习率	0.05	0.05	—
叶节点数	63	63	—
行采样	未启用	未启用	LightGBM 只有采样频率大于 0 时才启用；早期写作曾误把配置中的 0.9 当作已生效
列采样比例	0.9	0.9	—
L2 正则 λ	0	5	后续生产优化；其独立收益不稳定，不能据此改写离线结论
早停轮数	50	50	监控独立验证集，不得使用测试集（见 4.1.3 节）

2026-08-30 的在役产物快照在 1 311 轮触发早停，较早一次基于生产切分的对照则收敛于 598 轮。把轮数上限提高至 5 000 后，两次计算的结果仍逐位相同；原设的 1 500 轮上限没有实际约束早停。第 4 章交叉验证脚本实际运行 1 026–1 500 轮，轮数偏高与验证集构造有关：该脚本从训练数据中作随机 i.i.d. 划分，而生产对照使用时间尾部。各自协议内部的对照组仍共享相同设置，因此组内比较有效；轮数和绝对 RMSE 则不能跨协议直接对照（见 4.1.3 节）。

冷启动与生产增量重训使用同一套超参数。第 3、4 章的离线交叉验证固定采用表 3-1 左列设置，生产调参不会改变该设置。离线方法验证与生产改进按各自实际配置复算和报告。

加入持续观测后，树模型仍有约 0.7 dB 的近似常数偏差。校准只用独立验证集估计该偏差，不读取测试信息：

$$b_{val} = \frac{1}{n_{val}} \sum_{i \in val} (r_i - \hat{r}(\boldsymbol{\phi}_i)), \tag{3-2}$$

该量随模型产物一并保存，训练、准入评估和在线推理均调用同一偏移；缺少该字段的旧产物按 0 处理。校准既不接触测试集，也没有增加随输入变化的模型容量。在固定生产切分上复核三个随机种子时，可信测试集含 83 842 条记录。只加入这一偏移，RMSE 改进 0.381 %–0.425 %，偏差由 0.756–0.799 dB 收窄至 0.087–0.126 dB，代价是 MAE 均略有劣化。将其与 $\lambda = 5$ 组合后，RMSE 改进为 0.337 %–0.481 %；L2 单独造成的变化却分别为 -0.083%、$+0.003\%$、$+0.053\%$，方向不一致。稳定收益只能归于验证集偏差校准，**不能把组合收益归因于 L2 正则本身**。

3.3 可靠度评分的定义

为辅助通联安排，系统用 logistic 函数将校正后的信噪比映射为 0—1 的可靠度评分：

$$R = [1 + \exp(-(\widehat{SNR} - c)/\sigma_R)]^{-1} \tag{3-3}$$

中心 c 取训练集校正后信噪比的中位数；它并非实际通信方式的解调门限。尺度 σ_R 用在役模型在可信测试集上的 RMSE 设定，采用 $\sigma_R \approx \sigma_{\text{model}}/1.7$ 的形状近似。这里以群体 RMSE 代替未知的单链路误差标准差，不能解释为逐链路不确定度估计。为使本章图表可复现，计算采用表 3-2 的历史留出值 8.21 dB，得到 $\sigma_R = 4.83$ dB；线上尺度按在役模型的评估结果更新（见 3.9 节和 5.4 节）。

WSPR 与 PSKReporter 只记录成功接收事件，没有相应的“已经发射但未被接收”负样本。因此 R 是模型假设下的排序评分，不能解释为经过实测校准的链路可用概率，也无法据现有数据计算可靠度图或 Brier 分数（见 6.2 节）。

3.4 阈值选择数据上的时间留出比较

表 3-2 汇总参与 VOACAP 截断阈值选择的历史时间留出集上的开发阶段比较。该集合取时间序列末 20 %，共 18 700 条记录，因此不构成 -120 dB 阈值或模型选择的独立测试估计。

表 3-2 参与阈值选择的单一时间留出集（末 20 %；n=18 700）的开发阶段性能比较（RMSE、MAE、偏差；单位：dB）

模型	RMSE（dB）	MAE（dB）	偏差 (dB)
VOACAP	34.69	31.13	−23.22
混合模型	8.21	6.45	+1.16
相对改进	76.3 %	79.3 %	—

RMSE 降低 76.3 %；系统性偏差由−23.22 dB 收窄至+1.16 dB，幅度缩小超过一个数量级。残差学习减小了物理估计与实测值的系统偏移，传播机理是否得到充分描述仍需独立检验。

参与阈值选择的单一开发留出集仅用于描述该历史分布上的误差量级；本文内部的方法比较采用第 4 章的 12 折交叉验证，按折配对检验。在该协议下，混合模型与 VOACAP 的平均 RMSE 分别为 7.86 dB 和 37.90 dB，与表 3-2 接近。两组数值的差别主要来自测试覆盖范围和早停验证集的切分方式（见 4.1.3 节末）。清洗数据后，各折难度相差 1.15 倍。

3.5 稀疏观测下的预测稳健性

第 3 章留出集的 RMSE 从 VOACAP 的 34.69 dB 降至 8.21 dB，但多条预设远距离 DX 路径的热力图仍有异常输出。逐链路误差不能显示这一局部失效，稀疏区稳定性因而需要单独检验。

3.5.1 问题的提出：精度指标看不见的失效

3.5.1.1 输出形态与评价指标的错配

训练与评价均以**单条链路**为单位：模型接收 (发射点, 接收点, 频率, 时刻) 四元组，并回归相对 VOACAP 基线的 SNR 残差。用户面对的却是一张 （波段 × 小时） 二维网格，需要横向、纵向比较后才会判断何时哪个波段可用。逐链路误差与网格可读性对应不同的评价对象。

梯度提升树给出分段常数预测；相邻小时或波段一旦被划入不同叶节点，图上的数值便可能出现突变。该跳变来自拟合噪声而非真实日变化，使热力图中的稳定窗口难以辨认，而 RMSE 不直接衡量这种可读性损失。

3.5.1.2 抖动度量

为刻画这种跳变，文中定义**评分抖动**（score jitter）。“跳变”专指输出形态，“抖动”则指对该现象的量化。设 $S(b,h)$ 为波段 b 在 UTC 第 h 小时的 0–100 综合评分，时间维抖动定义为

$$J_h = \frac{1}{|\mathcal{V}|}\sum_{(b,h)\in\mathcal{V}} |\,S(b,h+1) - S(b,h)| \qquad (3\text{-}4)$$

可读单元集合规定为

$$\mathcal{V} = \{(b,h): 0 \le h < 23,\ \max(S_{\mathrm{V}}(b,h), S_{\mathrm{M}}(b,h)) > 10,\ \max(S_{\mathrm{V}}(b,h+1), S_{\mathrm{M}}(b,h+1)) > 10\} \qquad (3\text{-}5)$$

其中 S_{V} 和 S_{M} 分别为 VOACAP 与混合模型评分，计算某一方法的 J_h 时，式（3-4）中的 S 取该方法评分。统计只在两种方法共有的 $\mathcal{V}$ 内进行。完全闭合的波段评分恒为 0，将这些单元纳入平均会稀释指标。VOACAP 的抖动仅提供同一网格和指标下的参照；它不是传播真值，也不是抖动的理论下限。

3.5.1.3 实测结果

实验以北京 (39.9°N, 116.4°E) 为发射点，选取五个距离不同的目标，逐一计算完整网格（7 个波段 × 24 小时，月份 8，SSN 78，功率 100 W）。所得抖动及历史观测支撑列于表 3-3。

表 3-3 五条北京参考路径的评分抖动与历史观测支撑（月份 8、SSN 78、功率 100 W；抖动为无量纲评分）

路径	距离 (km)	该距离档历史观测	占历史观测池	VOACAP	混合模型
北京→东京	2 093	25 345	27.1 %	5.75	6.39
北京→悉尼	8 951	2 346	2.5 %	3.59	6.31
北京→伦敦	8 140	2 946	3.2 %	1.32	8.22
北京→纽约	10 991	646	0.7 %	0.20	8.20
北京→圣保罗	17 593	131	0.1 %	—（全闭合）	8.40

历史观测支撑定义为固定的 93 500 条历史观测池中，该路径长度所在距离档与相邻两档的样本数之和（档宽 500 km）；它不是某一折的实际拟合集规模。圣保罗一行没有 VOACAP 数值：7 × 24 个单元中的最高评分仅为 3.4，没有单元超过阈值，可读单元集合为空。物理模型据此判定该路径在当前条件和评分阈值下没有可读单元。

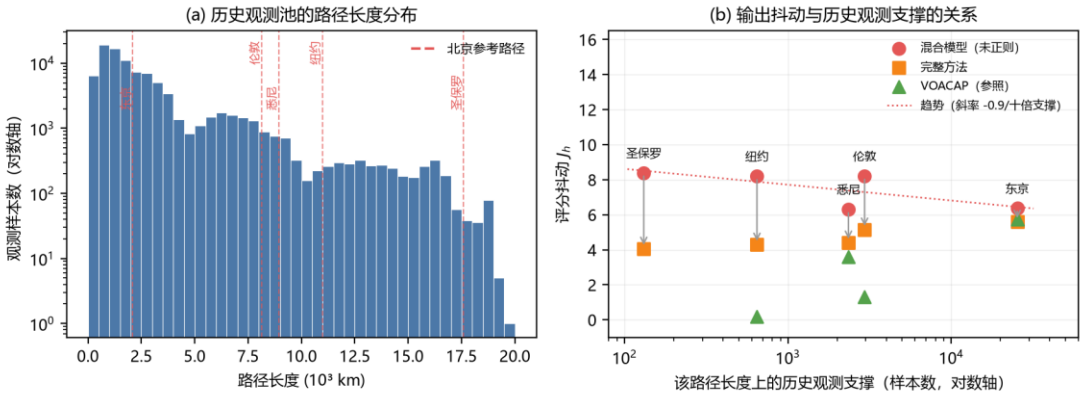


图 3-3 路径长度与输出抖动的关系（固定历史观测池；支撑为样本数，抖动为 J_h）：(a) 路径长度分布（横轴：距离，10^3 km；纵轴：历史观测数，对数轴），红色虚线为五条北京参考路径；(b) 混合模型未正则化、完整方法与 VOACAP 参照的抖动随历史观测支撑变化（横轴：历史观测支撑，样本数，对数轴；纵轴：评分抖动 J_h，无量纲），灰色箭头表示正则化后的变化方向，点线为未正则化趋势

表 3-3 与图 3-3(b) 给出了历史观测支撑与输出形态之间的有限样本联系。

五条参考路径的输出抖动与历史观测支撑总体呈负向关系，但中间路径并不严格单调。 东京属于支撑充分的短路径，占 27.1 %；其混合模型抖动为 6.39，与 VOACAP 的 5.75 接近。两个低支撑长路径的抖动为 8.20 和 8.40；纽约达到同路径 VOACAP 参照的 41 倍。圣保罗路径上，VOACAP 在当前条件和评分阈值下没有可读单元，混合模型却仍给出起伏评分。

总体 **RMSE 容易掩盖这种局部失效**。留出集延续了历史观测的距离分布，长路径在测试集中合计不足 4 %，对应误差很容易被占样本 87 % 的中短路径稀释。文中选取的跨洲 DX 场景恰有多条落在低支撑区，表明总体精度可能掩盖预设场景中的局部失效；没有完整查询日志时，不能把这些参考路径进一步解释为总体用户的查询热点。

3.6 历史观测覆盖与代表性场景的错配

表 3-4 的短路径占优结构与机会式采样、台站地理集中、活跃时段及采集策略共同相关。全球业余无线电人口分布可能参与其中，但现有数据不能把这一结构归因于单一人口因素。

表 3-4 历史观测池路径长度分布与 VOACAP 残差偏差（距离：km；残差中位数：dB）

路径长度 (km)	样本数	占比	残差中位数 (dB)
0 – 2 000	53 484	57.2 %	−30.9
2 000 – 6 000	27 576	29.5 %	−25.6
6 000 – 10 000	8 758	9.4 %	−10.7
10 000 – 14 000	2 093	2.2 %	−0.3
14 000 – 20 100	1 589	1.7 %	+18.3

残差定义为 $r = SNR_{\text{实测}} - SNR_{\text{VOACAP}}$。此处选用中位数而非均值，以免 VOACAP 在闭合链路上给出的极端负值（可达 −1 000 dB 量级）支配统计量。

历史观测以短路径为主，文中预先选择的 DX 参考场景却包含北京→伦敦、纽约和圣保罗等跨洲链路，它们所在距离区间的观测占比不足 4 %。历史覆盖与预设场景存在错配，3.5.1.3 节的失稳涉及这些代表性场景。

表 3-4 还暴露出距离相关的系统偏差。残差中位数从短程的 −30.9 dB 持续变化至超长程的 +18.3 dB，跨越 49 dB，并在约 12 000 km 处改变符号。VOACAP 偏差随距离变化，不能用统一常数表示；3.8 节据此检验回退目标的选择。

对图 3-3(b) 的五个点拟合线性关系后，支撑的对数每增加一个数量级，抖动约下降 0.9 分；在 131 至 25 345 的支撑范围内，整体方向为负。局部次序并不严格单调。悉尼路径的支撑为 2 346，抖动（6.31）反而低于支撑为 2 946 的伦敦路径（8.22），提示路径长度之外仍有其他变量参与作用。这里只考察了 5 条路径，尚不足以建立统计显著性。方法是否有效，应由 3.10 节的前后对比和 4.2.2 节的交叉验证共同判断，不能仅依赖这条趋势线。

3.7 支撑度自适应的邻域正则化

3.7.1 方法

单元预测不再只依赖一个输入点，而是在 (时刻, 相对频率) 邻域内汇集多个估计，并作加权平均：

$$\hat{r}(b,h) = \sum_i \sum_j \kappa_{ij}\, f\big(\mathbf{x}(b,h;\, \delta h_i,\, \delta f_j)\big), \qquad \kappa_{ij} \propto \exp\left(-\frac{\delta h_i^2}{2\sigma_h^2}\right) \exp\left(-\frac{\delta f_j^2}{2\sigma_f^2}\right) \tag{3-6}$$

式中，$f(\cdot)$ 为第 3 章的残差回归模型，δh 表示小时偏移，δf 表示相对频率偏移。核宽并非固定常数，而是随路径长度 d 对应的可用观测池支撑 $n(d)$ 变化：

$$\sigma_h(n) = \sigma_h^{\max} \cdot \frac{K_\sigma}{K_\sigma + n}, \qquad \sigma_f(n) = \sigma_f^{\max} \cdot \frac{K_\sigma}{K_\sigma + n} \tag{3-7}$$

根据可用观测池的支撑分布，参数量级确定为 $\sigma_h^{\max} = 8\ h$、$\sigma_f^{\max} = 0.9$、$K_\sigma = 2\,000$。在密集观测区，$\sigma \to 0$ 时邻域计算退化为单点预测，系统直接跳过其余求值。支撑变薄后，$\sigma \to \sigma^{\max}$，预测开始从相邻时刻与波段借取信息。$n(d)$ 由可用观测池的路径长度直方图计算，并在每轮重训后更新。

图 3-4 绘出 $\sigma_h(n)$ 以及 3.8 节将定义的混合权重 $w(n)$，同时标记五条参考路径在支撑轴上的位置。

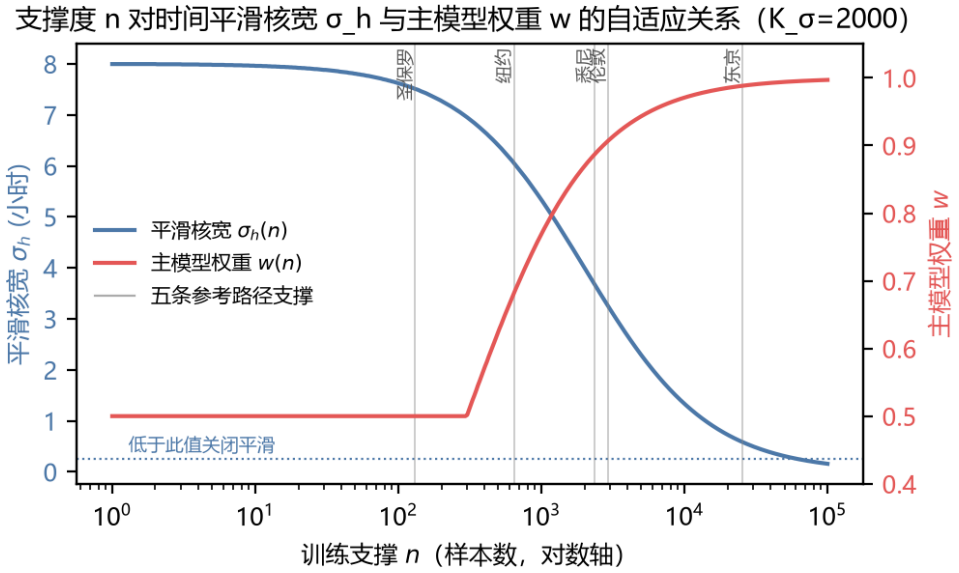


图 3-4 历史观测支撑驱动的正则化参数曲线（固定历史观测池；K_σ=2 000）：横轴为路径观测支撑 n（样本数，对数轴），左轴为时间平滑核宽 σ_h（h），右轴为主模型权重 w（无量纲）；灰色竖线标出五条北京参考路径

3.7.2 两个必要的实现约束

邻域正则化的计算还受以下两项约束。

（1）频率与 MUF 须等比例同步扰动。 f/f_{MUF} 描述工作频率相对最高可用频率的位置，残差对该变量也较敏感。若只改变 f_{mhz}，保持 f_{MUF} 不变，邻域采样便会跨入**不同的电离层工作区间**。此时求平均虽可抑制拟合噪声，也可能抹去真实传播差异。

表 3-5 对照了两种频率扰动方式在 12 折交叉验证中的配对表现。

表 3-5 频率邻域扰动方式的配对比较（12 折交叉验证；σ_f 无量纲；正值表示 RMSE 改善）

σ_f	同步缩放 MUF	仅扰动频率	同步的优势	优势折数	p
0.10	−0.157 %	−0.161 %	+0.003 pp	7 / 12	0.939
0.20	−0.508 %	−0.654 %	+0.145 pp	9 / 12	0.152
0.35	−0.653 %	−0.889 %	+0.237 pp	10 / 12	0.068

p 取配对 t 检验的双侧显著性。

同步缩放主要依据传播机理，当前实验尚未检出显著优势。 三个核宽下，同步方式都未达到显著水平（$p = 0.939/0.152/0.068$）；0.003–0.237 个百分点的优势，也远小于两种方式各自相对不平滑基准的差距。可观察到的方向性变化是：核宽增大时优势同步扩大，优势折数由 7 增至 10。这一趋势与机理预期一致：邻域越宽，采样点越偏离原频率，不同步缩放引起的工作区间错置也越明显。

（2）平滑对象只能是 ML 校正量，不能是校正后的 SNR。 若对后者操作，VOACAP 基线中的日变化也会被一并削弱，而基线日变化应予保留。本文因此未对输出网格直接施加二维滤波。

3.7.3 精度代价评估

精度代价选用**留一（年，月）交叉验证**评估。每折留出一个（年份，月份）组合作为测试集，其余数据再按 90 : 10 划分训练集与早停验证集。4.1 节将详细说明这一安排的必要性。

本研究使用这 12 个已采样时间块比较并选择邻域核宽及相关配置，随后也报告同一折集合上的结果。因此，表 3-5 至表 4-4 的折间比较属于开发性评估；所列检验概率和折间方向只描述当前折集合，不作为独立确认性证据。

表 3-6 时间邻域正则化的精度影响（12 折交叉验证；σ_h 单位：h；正值表示 RMSE 改善）

核宽	RMSE 变化均值	标准差	改善的折数
$\sigma_h = 1\ h$	+0.409 %	0.090	12 / 12
$\sigma_h = 2\ h$	+0.532 %	0.111	12 / 12
$\sigma_h = 3\ h$	+0.597 %	0.139	12 / 12
$\sigma_h = 4\ h$	+0.614 %	0.172	12 / 12
$\sigma_h = 6\ h$	+0.581 %	0.231	12 / 12
$\sigma_f = 0.10$	−0.157 %	0.349	4 / 12
$\sigma_f = 0.20$	−0.508 %	0.585	1 / 12

百分比的口径。 本表及表 3-5、表 4-1、表 4-3、表 4-4 均报告**各折相对变化的算术平均**。计算时先在每一折内求 $(RMSE_{\text{基准}} - RMSE_{\text{方法}})/RMSE_{\text{基准}}$，再对 12 折取平均；标准差也基于这组逐折数值。清洗后的折间难度比为 1.15（4.1.2 节）；若改用”两列均值相除”，困难折仍会获得更高权重，所得量不再等同于平均折上的相对效应。3.8.4 节的两张表需要同时列出分段 RMSE 绝对值，故改用均值口径，并在相应位置单独标注。

时间和频率扰动产生了方向相反的效应，不能合并解释。

时间维平滑在所测核宽下均改善了精度。 五个核宽的变化全部为正，12/12 折均无例外。平均提升为 0.41 %–0.61 %，跨折标准差只有 0.09 – 0.23，效应量达到离散度的数倍。这一结果与平滑削弱拟合噪声的解释相符：该成分可能同时损害逐链路精度与网格可读性。收益随核宽先升后降，在 $\sigma_h \approx 4$ h 附近达到峰值；继续扩大邻域后的收益下降，与真实日变化逐渐被平滑的解释相符。

频率维平滑确实付出精度代价。 $\sigma_f = 0.10$ 时变化为 −0.157 %，只有 4/12 折改善；增至 0.20 后，变化扩大到 −0.508 %，仅 1/12 折改善。传播机理可以解释这种差别。相邻小时的电离层状态通常高度相关，相邻波段却相隔数 MHz，传播条件可能截然不同；沿频率借取信息更容易越过真实结构边界。因此，频率方向采用远小于时间方向的核宽（$\sigma_f^{\max} = 0.9$ 相对频率），其实际生效值在密集路径上趋于零。

3.8 稀疏区的回退目标：为什么不能是物理基线

3.8.1 直觉与其反例

数据稀疏时，可考虑提高物理模型权重，即令校正量 $\hat{r} \to 0$，使输出逐步退回纯 VOACAP。这种向先验收缩的正则化原则，在本任务中未必适用。

表 3-4 提供了直接反例。多数距离档的 VOACAP 残差中位数明显偏离零，整体范围为 −30.9～+18.3 dB；10 000–14 000 km 档的中位数虽接近零，也不能据此证明该区间的条件误差无偏。把校正量压向零，可能放弃随距离变化、幅度可达数十 dB 的系统性修正。回退目标是否合适，仍需由表 3-7 的预测误差直接检验。

3.8.2 受控抽稀实验

受控抽稀实验用于检验向物理基线回退的策略。目标距离段内的 25 % 样本固定为测试集，剩余样本按 $s \in \{0.5\%, \ldots, 100\%\}$ 抽稀，再与**全部段外样本**合并训练。比较各策略在目标段的测试误差随 s 变化的情况。固定目标段测试样本，可在训练观测逐渐减少时保持评价条件不变。一般交叉验证中该类测试样本占比较低，局部变化容易被总体误差波动掩盖。

表 3-7 受控抽稀实验的分距离段 RMSE（目标段训练支撑为指定样本数；RMSE 单位：dB）

目标段	该段训练样本	纯 VOACAP	主模型	低容量模型
6 000–10 000 km	32	35.79	6.96	7.27
6 000–10 000 km	328	35.79	6.86	7.18
6 000–10 000 km	6 565	35.79	6.47	7.10
14 000–20 100 km	5	49.00	6.72	6.94
14 000–20 100 km	59	49.00	6.54	6.96
14 000–20 100 km	1 191	49.00	6.44	6.96

两个受控目标段均得到相同的比较结果：**纯 VOACAP 在所测六种稀疏设置下的 RMSE 均最高**。目标段仅保留 5 条训练样本时，数据驱动模型的 RMSE 仍为 6.72，而物理基线为 49.00，后者是前者的 7.3 倍。

在 14 000–20 100 km 段，训练记录由 1 191 条减至 5 条，主模型 RMSE 从 6.44 升为 6.72，劣化仅 4 %。该段抽稀后的误差变化较小，可由 3.8.3 节的邻段借用解释：目标段之外仍有九万余条记录，梯度提升树可沿连续距离特征借用邻段样本。由于超长路径位于距离上边界，这种统计支撑主要来自较短路径一侧，属于单侧外推。

3.8.3 成因分析

上述结果可从偏差结构与模型行为解释。

（1）物理模型偏差随距离系统变化。 向 VOACAP 收缩会把估计拉向该距离段已有方向和幅度偏差的基线。

（2）梯度提升树会在连续特征上自动借用邻域信息。 路径长度以连续变量进入模型，即使 6 000–10 000 km 段只剩 32 条样本，模型仍能借助相邻距离段的 84 384 条记录完成插值。“某距离段样本较少”与”该段无支撑”由此不能画等号，这一点与参数化模型或近邻方法的行为存在本质差别。

这些实验支持在所测稀疏区域限制模型容量，而非直接取消**数据驱动校正**。

3.8.4 低容量模型作为回退目标

回退实验最终选择容量受限的**低容量模型** $g(\cdot)$ 作为目标。该模型的树深为 2，设 4 个叶节点，最小叶样本数为 200；输入仅保留 5 个可用少量样本稳定估计的变量，即路径长度、频率、VOACAP 基线、f/f_{MUF} 和路径中点天顶角。

最终校正量由主模型和低容量模型按支撑度加权：

$$\hat{r}(\mathbf{x}) = w(n)\, f(\mathbf{x}) + (1 - w(n))\, g(\mathbf{x}), \qquad w(n) = max\left(w_{\min}, \frac{n}{n+K_w}\right) \quad (3\text{-}8)$$

$w_{\min} = 0.5$ 将权重限制在主模型一侧。表 3-7 已呈现，低容量模型单独使用时明显弱于主模型；低容量模型用于约束校正量，不单独替代主模型。

表 3-8 支撑加权混合模型的分距离段交叉验证结果（12 折；K_w=300；RMSE 单位：dB；改进为相对主模型的百分比）

距离段	平均 w	纯主模型	混合后	改进	改善折数
0 – 2 000 km	0.99	8.27	8.27	+0.02 %	12 / 12
2 000 – 6 000 km	0.97	7.52	7.52	+0.07 %	10 / 12
6 000 – 10 000 km	0.90	6.64	6.62	+0.29 %	11 / 12
10 000 – 14 000 km	0.69	6.29	6.21	+1.28 %	10 / 12
14 000 – 20 100 km	0.63	6.90	6.86	+0.66 %	8 / 12
全部	0.96	7.86	7.86	+0.07 %	12 / 12

本表与表 3-9 的”改进”列选用**两列均值之比**，即直接以表中相邻两列计算，口径不同于表 3-6。这样处理是为了同时保留各段 RMSE 绝对值，使段间难度差异可见。改用表 3-6 的逐折口径时，10 000–14 000 km 段改进为 $+6.50\%$，整体为 $+0.84\%$；方向和相对大小均不改变。

改进主要落在 10 000–14 000 km 段，幅度为 1.28 %；其他距离段的跨折汇总均值介于 0.02 %–0.66 %，均未出现负向变化。这一目标段对应文中预先选取的跨洲 DX 场景，但其实际查询权重尚需由使用日志验证，不能从 2.2 % 的样本占比反推。

表 3-9 比较了 K_w 的三个候选值。密集段在各设置下的跨折汇总均值均为正，当前口径未观察到平均精度代价；目标段收益随 K_w 增大而略有上升，改善折数却同步减少。两者权衡后取 $K_w = 300$。

表 3-9 支撑加权系数 K_w 的敏感性（12 折交叉验证；改进为 RMSE 相对主模型的百分比）

K_w	10–14k 段改进	改善折数	2–6k 段	整体
200	+1.09 %	12 / 12	+0.05 %	+0.06 %
300	+1.28 %	10 / 12	+0.07 %	+0.07 %
600	+1.38 %	9 / 12	+0.11 %	+0.10 %

整体 RMSE 的 +0.07 % 改进未达到生产准入所需的 0.2 %，该方法因而不能仅凭整体指标上线。**少数子群体的收益被整体指标稀释，全局门槛因而可能拒绝局部有效的改动**。本文据此将这项正则化与主模型准入解耦（5.4 节）；5.5.4 节讨论来源子群体中类似的均值稀释问题。

3.9 可靠度评分的尺度

式（3-3）的初始实现把训练集校正后 SNR 分布标准差的一半（4.29 dB）用作 σ_R。该标准差描述不同链路之间的差异，不等于单条链路的预测误差；尺度过窄还会放大评分对小幅 SNR 波动的响应。

作为工程替代，本文用在役模型在可信测试集上的 RMSE 设定评分曲线斜率，按正态累积分布的 logistic 近似取 $\sigma_R \approx \sigma_{\text{model}}/1.7$。表 3-10 固定使用历史留出集 RMSE 8.21 dB，得到 $\sigma_R = 4.83$ dB。线上数值随重训评估更新，但测试集的来源构成和难度也在变化，跨轮尺度变化不能直接解释为模型不确定度变化。

该映射没有失败接收事件作校准目标，评分大小只适合当前模型内部的相对比较；对外展示时不能将其称为已经验证的成功概率。

3.10 综合效果

同时启用 3.7、3.8、3.9 三项方法后，按 3.5.1.2 节的同一测量协议重新计算，所得数据见表 3-10。

表 3-10 正则化前后五条参考路径的评分抖动对比（月份 8、SSN 78、功率 100 W；σ_h：h；w：无量纲；抖动：无量纲）

路径	历史观测支撑	σ_h	w	VOACAP	未正则	完整方法	降幅
北京→东京	25 345	0.59 h	0.99	5.75	6.39	5.61	12.3 %
北京→悉尼	2 346	3.68 h	0.89	3.59	6.31	4.42	29.9 %
北京→伦敦	2 946	3.23 h	0.91	1.32	8.22	5.16	37.2 %
北京→纽约	646	6.05 h	0.68	0.20	8.20	4.30	47.5 %
北京→圣保罗	131	7.51 h	0.50	—	8.40	4.07	51.6 %

东京路径的观测支撑充足，正则化干预很弱（$\sigma_h = 0.59$ h，$w = 0.99$）；圣保罗路径支撑最少，干预最强（$\sigma_h = 7.51$ h，$w = 0.50$）。**五条路径的抖动均下降**，降幅从东京的 12.3 % 到圣保罗的 51.6 %。结果与自适应设定基本一致。

单个网格单元需要计算 9 个小时偏移和 5 个频率偏移的全部组合，邻域正则化因而包含 45 次求值。7 波段 × 24 小时网格的实测额外开销为 65–71 ms。在密集路径上，邻域求值直接跳过。预测结果另在服务端缓存 900 s，因此重复查询不会每次承担完整的新增计算。

3.11 评价协议与残差模型边界

RMSE 应与切分协议和测试样本构成一并报告。时间留出、月份交叉验证、地理留出、受控抽稀和特征置零对应不同问题，其结果不能直接合并或排序。

表 3-11 不同评价协议回答的问题及不可外推的内容

评价协议	主要比较对象	能够支持的判断	不能据此外推
单一时间留出	同一后期时间切片上的模型或参数	给出该切片的误差与效应量，暴露协议敏感性	不能在小效应条件下单独承担方法排序
12 折留一（年，月）	12 个时间块中的配对结果	检验平均效应、离散程度与改善折数	不能替代未来月份或新太阳活动阶段的长期验证
留一发射端经度区	6 个 60° 经度分区	诊断大洲尺度的空间误差结构	不能排除城市、台站或更细传播状态的记忆
抽稀、置零与收缩	样本支撑、输入组或输出校正量	识别失效条件及当前架构的扰动敏感性	不能分离物理基线的独立因果贡献
生产准入	同一轮、同一可信测试集上的候选与在役模型	判断候选是否满足整体门槛和分片护栏	不能横向比较不同轮次绝对 RMSE，也不能证明长期泛化

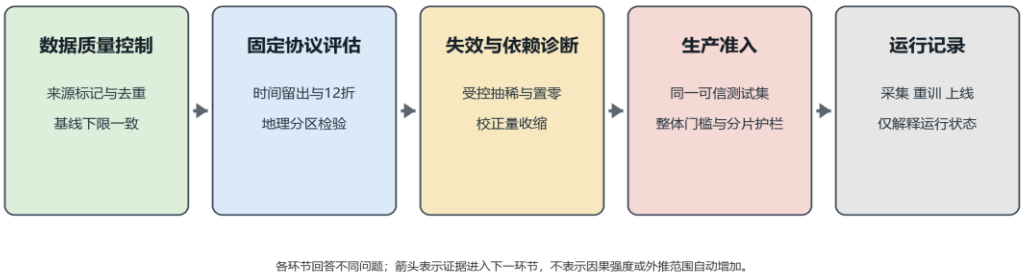


图 3-5 模型评价证据链：数据质量控制、固定协议评估、失效与依赖诊断、生产准入及运行记录；箭头表示证据传递，不表示因果强度或外推范围递增

图 3-5 同时列出方法实验与运行记录，解释时需分别采用各自的评价协议。生产准入检查候选是否在当轮共享测试集上达到门槛，重训日志记录采集是否连续以及产物何时替换。方法间的比较则由冻结数据与切分协议后的重复实验完成。运行测试集会随观测增长而改变来源构成和难度，因此跨轮 RMSE 上升或下降，都不能直接解释为模型退化或改进。

固定维度置零实验移除 VOACAP 派生特征后，RMSE 上升 131.61 %，说明残差架构依赖该组输入；该结果不能单独证明基线的因果贡献。来源判别器 AUC 为 1.000 表明现有特征可区分 WSPR 与新采 PSKReporter，但不证明模型已形成分来源策略。

为了明确混合模型到底学到了什么，可把数据生成过程写成一个条件期望问题。令 X 表示查询时可得的几何、时间、频率及太阳状态，Y 表示成功接收后上报的名义

SNR，$D = 1$ 表示该记录完成接收、解码与上报。历史训练实际最小化的是 $D = 1$ 条件下的平方损失。理想情况下，回归函数趋近于 $E[Y - B(X) \mid X, D = 1]$，其中 $B(X)$ 是经过统一下限处理的 VOACAP 基线。预测 $B(X) + f(X)$ 因而近似的是已记录样本分布中的条件均值，并非任意发射尝试的潜在接收结果。这个统计对象与第 1.9.7 节的目标区分一致，也解释了为什么缺少失败样本时不能从 f 推出接收概率。

当模型在新来源上使用时，误差至少有四个层次。首先，VOACAP 的气候学状态与实际电离层状态之间可能有偏差；其次，两端天线、发射功率和本地噪声与物理模型的工程假设不符；再次，WSPR 和 PSKReporter 等报告机制给出的名义 SNR 口径不同；最后，有限训练样本和模型容量带来估计误差。当前 19 维特征可以吸收部分可预测差异，但不能逐条分离四种来源。一个小的整体 RMSE 既可能来自有意义的传播校正，也可能来自对常见站点、模式或功率假设的统计补偿。本文用时间、空间和来源切分限制后一种解释，却没有开展能够完全识别物理贡献的干预实验。

平方损失的性质进一步决定错误检查的优先次序。RMSE 对大残差格外敏感，一条被编码为 −1 772 dB 的物理基线会使目标差达到千 dB 量级；即使这类行只占很小比例，也足以支配折内平方误差。中位数、MAE 和分距离 RMSE 能提供互补视角，但若目标编码本身错误，增加评价指标并不能修复学习问题。第 2.2.1 节把哨兵值统一截断，目的是使 $B(X)$ 的定义在训练和推理中具有同一意义。此后讨论的“长距离更难”才不至于主要由极端编码驱动。

混合模型中的常数偏差 b_{val} 与输入依赖的残差函数承担不同作用。前者在独立验证集上估计平均方向的剩余误差，对所有查询加同一 dB 修正；后者依据链路条件改变校正量。若验证集与测试集的来源比例不同，一个对验证集最优的常数可能使某一来源的 MAE 恶化。第 5.5.5 节观察到 RMSE 改善而 MAE 劣化，正说明单一常数校准只能服务于它被定义的损失与数据构成。将 b_{val} 包装在模型产物中并记录其验证来源，可以避免线上结果使用另一个隐藏常数；它仍不等于跨来源仪器校准。

残差架构还有一个易被忽略的依赖关系：监督目标含 $B(X)$，输入又含 $B(X)$ 及其派生值。置零输入中的 VOACAP 组，学习器必须在目标仍含该项的情况下，通过其余特征重建一个复杂的物理函数，再学习剩余偏差；性能大幅下降符合这个任务变化，不能把下降幅度直接视为物理模型的独立价值。一个严格的端到端对照应重新定义目标为 Y，重新训练相近容量的模型，并使两组模型共享样本、特征可得性和验证协议。当前结果确认残差实现对物理组的显著依赖；端到端对照留待上述协议检验。

3.12 支撑度定义与邻域算子边界

“稀疏”可以指训练样本总数少，也可以指某个具体查询附近缺少可比较记录。前者适用于整体学习曲线，后者才与单条路径的风险直接相关。本文采用一个低维、可复算的操作性代理：把历史观测按 500 km 路径长度分档，查询距离所在档及相邻两档的记录数之和定义为 $n(d)$。这种定义计算代价低，能给所有查询快速分配一个支撑强度；图 3-4 中五条参考路径也使用同一固定历史池，避免评估时因折内样本数变化而让横轴语义漂移。

$n(d)$ 统计的是距离邻域内的记录数。长度相同的链路仍可能分属不同半球、地磁纬度、本地时段和太阳活动阶段；活跃接收站也会在同一距离档反复贡献记录。因此，一维计数以“长度相近意味着部分传播结构可能相近”为工程近似，适合发现极端短缺。它可能高估缺少地理近邻的路径支撑，也可能低估分布广泛但处于稀有距离档的路径支撑。第 2.4.1 节的接收端集中度说明，还需区分记录条数与独立传播环境数。

这一定义仍有研究价值，因为它让正则化强度的来源透明。东京参考路径约有 25 345 条距离邻域记录，纽约只有 646 条，圣保罗只有 131 条。按式（3-7），前者的时间核宽接近零，后两者明显扩大；按式（3-8），主模型在极稀疏处仍保留至少一半权重。若不显式说明 n 的来源，同一算法在训练折、完整历史池和实时增长池上可能给出不同权重，结果难以复现。本文的离线图表使用固定池，运行系统在完成新一轮训练后更新直方图；两者服务的时间点不同，因此不能把一张离线热力图当作线上所有时刻的精确重现。

从统计角度，$n(d)$ 还没有估计有效样本量。若某段 1 000 条记录来自少数接收站和相近时刻，它们提供的独立信息可能远少于 1 000 个条件各异的记录；反过来，分散于不同季节和太阳状态的较少记录也可能覆盖更宽的条件空间。一个更精细的支撑量可以按地理距离、时间、频率和来源加权，同时限制单站点权重，但维度升高会使邻域定义更依赖任意尺度选择。本文先采用可审计的一维规则，报告其失败情形，并把多维支撑与接收端聚类重采样列为后续研究，而不假定复杂规则必然更好。

支撑计数与模型误差也不是因果上单向的关系。短距离样本多，可能同时意味着传播模式简单、站点设备相似和较容易解码；长距离样本少，可能同时意味着多跳模式、时段选择和上报门槛不同。图 3-3 的五个点不能把抖动增大唯一归因于样本少。受控抽稀提供了更接近干预的证据：在固定目标段和评价行集时人为降低训练支撑，

比较回退目标的行为。但它只干预训练数量，没有复制自然稀疏区的全部联合分布。两类证据应互相补充，不能相互替换。

式（3-6）可理解为对“残差校正函数”而非对“物理基线”作局部平均。这个选择很关键：VOACAP 的随时段和频率变化可能包含真实传播结构，若把最终 SNR 整体平滑，物理层的开闭边界会与树模型的估计噪声一起被抹平。本文让每个邻域点先构造一致的特征并求出残差，再把加权残差加回目标查询点的物理基线。由于权重经归一化，其和为一；当邻域核宽趋零时，除中心点外的权重趋小，算子连续回到单点校正。这种极限行为使方法能够在密集区近似不干预，而不需要两套完全不同的预测定义。

时间邻域将 23 时与次日 0 时视为相邻时刻，输入采用周期编码，邻域采样按日历跨越午夜。周期编码不代表不同日期的观测相同；空间天气仍可能在午夜附近突变。该方法平滑用户查询网格的输出，不能替代逐时实时同化，缺少即时特征时仍可能无法预测突发地磁暴影响的路径。

频率维更敏感。MUF 表示给定路径和条件下某传播模式的可用频率上界，工作频率与 MUF 的比值是具有物理含义的相对位置。仅扰动工作频率、不同步调整相关 MUF 特征，会让邻域点看似接近，却跨越了不同的相对传播区间。第 3.7.2 节报告的配对实验显示，保持特征物理一致性比机械地在数值轴上求平均更重要。即便同步扰动，频率平滑仍在所测核宽下造成 RMSE 劣化；频率间隔对应不同电离层路径和吸收状态，并非纯粹的测量噪声。最终实现将频率核宽限制得很小，主要从时间邻域获取稳定性收益。

平滑还面临典型的偏差与方差权衡。若原始树模型在相邻小时出现由有限样本造成的随机跳变，邻域平均可减少这种波动；若真实 SNR 在日出、日落或工作频率接近 MUF 时迅速变化，相同操作会引入偏差。本文用 12 折配对 RMSE 与五条路径的评分抖动同时检验这两面，而不是只展示更平滑的图。时间维在所测设置中获得小幅而一致的误差收益；频率维的负面结果说明“输出更连续”不能单独作为方法有效的标准。第 3.18 节保留这项代价，避免把正则化写成无条件改善。

若每格都执行 45 次邻域求值，7 个波段、24 个小时的完整网格共调用残差模型 7 560 次。核宽接近零的密集路径可省去多余邻域求值；额外计算主要落在稀疏路径上。第 4.4 节给出实测毫秒耗时，并将 VOACAP、机器学习和校准分别列出。缓存可以减少重复查询的平均响应时间，却不能改变首次查询的计算代价；因此性能报告必

须说明是否命中缓存。模型版本更新后，缓存键也应包含产物标识，否则用户可能在新模型上线后继续看到旧预测，掩盖方法比较的实际部署状态。

3.13 回退策略与评分解释

物理基线作为稀疏区回退目标，需要在局部误差上优于数据模型。表 3-4 的残差中位数从短路径的 −30.9 dB 变到超长路径的 +18.3 dB，固定偏置难以覆盖各距离段。表 3-7 的受控抽稀提供了直接比较：在两个目标段的六种训练支撑设置中，即使目标段仅保留 5 条训练记录，低容量数据模型的 RMSE 仍低于纯 VOACAP。在当前输入、目标和数据口径下，低容量模型因此是这些受测稀疏段更合适的单独回退预测器。

低容量模型的作用是提供一个更平稳、偏差可控的残差估计。树深 2、四个叶节点和较大的最小叶样本数限制了它记住复杂地理交互的能力；只保留距离、频率、物理基线、相对 MUF 及中点天顶角五项，避免在很少样本时估计过多条件分支。限制容量会引入偏差，故表 3-7 中它通常不如主模型；在低支撑处，它可能减少主模型不稳定叶节点造成的方差。式（3-8）以 $n/(n+K_w)$ 增加主模型权重，并设置 $w_{min}=0.5$，防止任何路径完全由弱模型接管。这样定义的混合是“主模型受低容量估计约束”，而不是把训练不足处判给一个更差的基线。

混合权重在主模型利用率与稀疏区响应之间作出可检验的取舍。当 n 远大于 K_w，w 接近一，混合几乎不改动主模型；当 n 很小时，权重触及 0.5 下限，保留主模型已经学到的跨区域结构，同时让低容量模型抑制极端校正。参数 K_w 的三个候选值在 10 000 至 14 000 km 段分别获得 1.09 %、1.28 % 和 1.38 % 的平均改进，但改善折数从 12/12 降至 9/12。选择 300 是在效应大小与跨折稳定性之间的折中，不是对任意距离或太阳条件的理论最优常数。若未来训练集规模显著改变，固定 K_w 对应的相对支撑强度也会变化，应按冻结协议重新扫描。

全局收缩实验为局部混合策略提供了另一面证据。把每条链路的校正量向全局均值收缩仅 5 %，所有 12 折都变差；收缩越强，误差劣化越明显。这说明“少校正一点就更稳”在整个历史分布上不是好策略。低容量混合只在支撑薄弱处施加强干预，在密集区尽量保留主模型，是对这一反例的回应。它仍可能在某些未测路径上伤害精度，尤其在 14 000 至 20 100 km 段只获得 8/12 折改善。论文因此报告分段结果和折数，而不把总体均值 +0.07 % 当成普遍保证。

若以决策角度解释，这种混合规则减少的是模型输出对少量局部样本的敏感性，而不是对所有不确定性的估计。低容量模型和主模型共享同一历史数据及 VOACAP 基线，二者误差可能高度相关；权重平均不必使误差方差按独立模型公式下降。未来

若考虑集成不确定度，必须测量模型间误差相关与条件覆盖，不能简单把两个模型的分歧当作可信区间。本文只把混合用于点预测和输出稳健化，不赋予其概率保证。

用户看到的可靠度数值容易被理解为“成功通联概率”，但当前方法实际只完成第一层：把预测 SNR 通过单调 logistic 函数变为便于排序的 0 至 1 评分。只要中心和尺度固定，较高 SNR 对应较高评分；这保证排序一致，却没有保证数值 0.8 意味着十次尝试中约八次成功。中心取训练集的预测中位数，尺度由群体 RMSE 近似，两者都是工程可解释的形状参数，不是根据成功与失败事件拟合出的概率校准参数。即使在已记录样本上改变 logistic 曲线使分数分布更均匀，也不会凭空产生缺失的失败样本。

第二层是给名义 SNR 点预测附上误差范围。若仅用全体 RMSE 构造“预测值 ± 某个倍数”的区间，它默认不同路径、模式和太阳条件具有相近误差尺度。第 3.8 节的距离分段、来源差异和稀疏区结果已经提示这种假设不稳。可以在独立验证集上按距离、波段或来源估计条件残差分布，再检查区间覆盖率；但细分后长距离组只有少量样本，分位数本身会不稳定。若未来使用保序或分位数方法构造区间，还必须明确覆盖保证对应何种交换性或固定测试分布。当前论文没有完成这类区间实验，因此图表只展示点估计及低支撑提示。

第三层才是“给定计划发射，某指定接收站能否成功解码”的事件概率。它要求定义发射功率、模式、接收机、带宽、时段与成功判据，并记录成功和失败两类尝试。WSPR 定时信标提供了可能的发射时隙来源，但仍要知道目标接收端当时是否在线、是否监听对应波段，以及网络上报是否正常。若这些状态不明，把数据库中没有出现的一行当作失败会混入大量假负样本。PSKReporter 的一般接收报告更难恢复每次潜在尝试的分母。本文因而不计算 Brier 分数或可靠度图，因为那会要求一个当前数据不具备的事件真值集合。

这三层输出的评价也不同。点预测用 RMSE、MAE 和偏差评价；预测区间要看目标覆盖率、区间宽度和分层覆盖；事件概率要看校准、分辨率及实际决策代价。一个点预测 RMSE 较低的模型未必给出校准概率，反之亦然。本文保留“可靠度评分”的用户名称，但在方法和界面说明中标出其含义。若将来获得配对的发射、在线守听与接收记录，首先应按模式和站点条件定义二元标签，再在独立时段比较评分的排序性和概率校准，而不是直接复用当前 logistic 参数并声称完成验证。

若未来把评分升级为概率，评价应使用与概率预报目标一致的严格适当评分规则，而不是继续只用 SNR 的 RMSE；相关评分规则的理论框架见 Gneiting 和 Raftery[26]。这条文献依据不改变本文当前评分未经校准的状态。

3.14 方法组件、平滑与混合条件

完整预测路径依次计算物理基线、构造在线可得特征、得到主模型残差、在需要时作邻域正则化与低容量混合，最后施加验证集常数偏差并映射评分。顺序不能任意互换。例如若在残差平滑前把名义 SNR 转成 logistic 评分，再对评分求平均，由于 logistic 为非线性函数，“平均评分”通常不等于“平均 SNR 后再评分”，会改变阈值附近的结果。若先施加偏差再以不同时间邻域取样，常数偏差本身虽在线性平均下保持不变，使用的模型版本和核参数却仍需一致。实现把同一产物版本、特征管道和参数用于整个网格，防止一张图内部混用不同模型。

每个组件的效果也应按自身目标解释。物理基线提供任务结构，特征组置零检验依赖；时间邻域正则化针对输出跳变，须同时观察误差是否变化；低容量混合针对低支撑区域的预测方差，须看分距离段效果；常数偏差针对整体验证残差，须看 RMSE、MAE 与来源分片；评分映射针对界面排序，当前不能用成功概率评价。把所有组件只放在一张“最终模型优于基线”的表里，会掩盖其不同的干预对象。论文在第 3、4、5 章分别报告诊断、离线效应和运行准入，并把不成立的更强解释留在讨论章。

方法组件的消融顺序须服从数据与评估修复的顺序。基线中的哨兵值会污染稀疏段目标；早停若读取测试集，参数比较便已接触测试答案；若来源切分让新增数据完全不进训练，闭环“无收益”也不能归因于新数据无用。本文先修正数据定义与评价协议，再比较方法组件。连续排错的过程暴露了另一项一般性风险：系统越复杂，负面结果越容易被归因于直觉上显眼的因素。可复核的实验日志、输入文件与代码版本，比事后编排一条顺畅的成功故事更能说明方法有效到什么程度。

邻域平均和模型混合都可能降低输出变化，但“更平滑”本身不构成误差改善的数学保证。设邻域中的残差估计为真实局部残差加误差，权重为非负且总和为一。如果各邻域误差相互独立、均值为零、方差相同，加权平均的方差与权重平方和有关，通常低于单点估计；但本文的邻域样本来自同一个已训练树模型，相邻时刻误差高度相关，这些前提不成立。更一般地，平均后误差方差取决于权重向量与误差协方差矩阵的乘积。若邻域点共享同一系统性偏差，平均不会把它消除。若真实残差随时间快速变化，平均还会引入平滑偏差。第 3.7 节的实测正效应因此是特定数据与核宽下的经验结果，而非由核函数形式自动推出的定理。

低容量模型混合有类似条件。设主模型与低容量模型的误差分别为 e_f 和 e_g，混合误差为 $we_f + (1-w)e_g$。其平方期望不仅包含两模型各自的误差平方，还包含 $2w(1-w)E[e_f e_g]$。二者共用 VOACAP 基线与历史数据，误差很可能相关；即使低容量模型输出较稳，也不保证任意 w 都比主模型具有较低 MSE。当前 $w(n)$ 根据支撑度而非逐路径验证误差确定，因为稀疏路径缺少足够样本来可靠估计最优权重。选择 $K_w = 300$ 依赖跨折配对实验，并通过 $w_{min} = 0.5$ 保留主模型贡献。这是一种受实验约束的规则，而不是由独立模型集成公式推导出的最优权重。

邻域平均用于减弱同一路径在时间和频率上的波动，低容量混合用于减少历史支撑不足时主模型的复杂响应。前者可能抹去日出附近的真实变化，后者可能无法表达部分高阶地理交互。为区分两者作用，本文先分别报告核宽与回退参数实验，再报告完整方法在五条路径上的表现。

物理基线的特殊性使误差相关更复杂。主模型和低容量模型都以同一被截断的 VOACAP SNR 为输入，且最终预测都将残差加回该基线。若 VOACAP 对某种传播模式存在相同方向的大偏差，两模型可能共同继承这项困难，混合不能像两个独立测量仪器那样相互抵消。图 2-2 和表 3-4 显示偏差随距离变化，因此回退策略不宜退到未校正的 VOACAP。将来若新增第二种物理模型作为对照，也须检验它与当前模型的误差相关，而不是只因“两个物理来源”就假设组合更稳。

3.15 多维支撑与稀疏区风险

每条查询都可得到距离支撑 $n(d)$，但同距离的不同传播条件在该计数中被合并。多维扩展可将距离、纬度、月份、频率和太阳活动划成网格，统计查询所在网格的行数。维度每增加一项，组合单元数便迅速增加；原本有几十万行的资料也可能在细网格中大面积为零。再按发射端、接收端或模式分层，零格点会更多；邻域划得过粗，又会合并不相似的条件。因此，支撑量设计需要同时权衡条件相似性、可复算性和计数稳定性。

距离与经纬度的尺度也不能随意混合。1 000 km 的大圆距离变化与 10° 纬度变化并无固定的物理等价关系；高纬和赤道附近的电离层结构不同，同样的经度差也可能对应截然不同的路径。可以先按照物理上有意义的因素分层，例如地磁纬度、路径是否跨越终止线、相对 MUF 和太阳状态，再在每层中用较粗距离邻域估计支撑。但这样做必须对每层报告行数、空白比例和模型效果。若只挑使五条参考路径看起来更符合直觉的分层规则，就会把诊断场景用于参数选择，失去独立性。

接收端集中度为多维支撑增加另一项约束。固定快照中，少数活跃接收呼号贡献大量记录；若一个查询附近的 500 条训练报告主要来自同一接收站，它们的噪声、天线和软件特征可能高度相似。一个改进方向是计算在距离邻域内的有效站点数，或对单站贡献设置上限，再与单纯行数比较。有效站点数也不等于独立传播状态：同一站点跨月记录可能很有价值，不同站点在同一次传播扰动下也可能相关。因而应把多个支撑代理作为可检验候选，而不是用一个看似精确的“有效样本量”掩盖相关结构。

评价多维支撑规则时，需要防止循环论证。若根据完整历史数据和所有测试路径的误差挑选规则，再用同一批路径声称支撑预测误差，就已把答案纳入设计。可采用嵌套方案：在训练块内部选取分层和核参数，用外层未参与设计的时间或地理块评价。若计算预算不足，也可预先固定一套基于物理知识的分层，在未来冻结测试窗中只做一次确认。无论采用哪一种，都应报告支撑评分与误差的关联、对稀疏路径的覆盖、对密集路径的误标率，以及最终模型是否真的改善预测。只有关联而没有干预收益的支撑量，可作为界面提示，尚不应自动控制混合权重。

本文分别用哨兵值下限处理基线极端值、用时间邻域正则化约束输出方差和网格跳变、用低容量混合抑制稀疏条件下的过度响应，并以来源分层检查条件变化。先区分原因再选择处理方法，避免用平滑掩盖基线错误，或用回退处理来源差异。

可用一个概念性的损失分解帮助设计诊断。对给定查询条件，预测误差可分为条件均值估计偏差、模型不稳定引起的变化以及不可由现有输入解释的报告噪声。这一分解不是从本文的有限样本中逐项识别出的实测量，因为没有在同一真实条件下重复观测完整设备状态；它只是提醒每项方法的干预目标不同。物理基线的系统偏差需要同条件对照或更准确的工程元数据；方差问题需要独立路径和时间的重复检验；报告噪声需要发射功率、天线、接收噪声等未提供字段。不能从一次整体 RMSE 下降反推所有三项同时改善。

低支撑标记只描述训练资料的局部覆盖。$n(d)$ 统计历史训练表中距离邻域的记录数，不使用当前预测误差，因此可在线计算；但它并未观察查询点的真实电离层状态。若某远距离路径处于常见而稳定的传播条件，低 $n(d)$ 仍可能提示过度谨慎；若一条近距离路径的接收端部署完全不同，高 $n(d)$ 也可能虚假乐观。一个理想的风险指示器要在独立测试块上同时考察两类错误：把困难点误标为可靠，以及把可预测点误标为困难。前者可能诱使用户过度相信结果，后者可能让系统过早退回低容量模型。当前论文没有提供完整的这类判别曲线，所以把支撑量用作保守规则而非经校准的不确定度。

平滑参数的选择还涉及决策损失。若用户只需要看一天内哪个波段总体较好，短暂锯齿可能比几十分之一 dB 的 RMSE 差异更妨碍阅读；若用户关心日出前后快速开通的时间点，过度平滑会把有用的边界推迟或提前。本文的 4 h 核宽在历史交叉验证和五条诊断路径上同时受到检查，但这仍不等于对所有用途都最优。不同应用可以预先指定不同损失，例如平均 SNR 误差、最佳波段排序错误、开通窗口时间偏移，随后在独立数据上选择参数。没有任务损失和真实开通时刻资料时，不应仅凭图像连续性继续加大核宽。

3.16 评分映射与物理基线贡献

模型先估计名义 SNR，再通过界面映射形成供排序的评分。若映射函数对 SNR 单调，固定条件下较高的预测 SNR 将有不低于较低预测 SNR 的评分；这有助于用户比较同一图内的候选格点。然而单调性只保证排序方向的数学一致，不保证排序与真实接收结果一致。模型误差在不同频率、时段和路径上异方差，两个预测分数相差很小时，其真实顺序可能颠倒。界面把连续数值编码成颜色，还会进一步隐藏相近值的差异。

评分映射会改变数值分布和色阶，但不会改变底层预测误差。压缩 SNR 中部或放大阈值附近会改变候选窗口的显示效果。跨版本比较须使用相同评分函数和物理基线下限；论文结果仍以未映射的 dB 误差为准。

概率校准要求更强的事件定义。假如把评分 0.8 解释为“80 % 的发射能收到”，就必须统计事先确认的发射、可用接收端和未成功事件，在未参与拟合的数据上检查这一分数段约有多少事件成功。当前资料只包含已成功上报的记录，无法构造上述比例。即使将成功报告中预测 SNR 高于某阈值的比例称为“命中率”，其分母依然是已成功样本，不是所有发射机会。因而本文保留评分作为相对提示，同时在界面低支撑和超过 MUF 的格点上显示条件性警示。

若未来转向预测区间，也需要区分覆盖对象。对已成功报告的 SNR，可以用时间和站点分块校准残差分位数，再在新块上检查名义 90 % 区间的实际覆盖；对“用户能否完成通信”，需要额外的失败事件和任务阈值。一个 90 % 覆盖的 SNR 区间仍可能在某些稀疏路径上失效，应分段报告实际覆盖和区间宽度。区间越宽越容易覆盖，单独报告覆盖率会鼓励无用的保守区间；同时报告宽度和分片偏差，才能看出表达不确定性的代价。

残差架构提供了明确的工程结构：在给定路径、频率和空间天气条件下先计算物理预测，再学习观测与预测的差。这个结构使物理模型的输出直接参与目标构造与最

终还原，也使模型在无观测位置至少有一个可计算起点。特征组置零造成大幅劣化，一部分是因为输入被删而目标仍定义为相对同一 VOACAP 的残差；这检验当前架构对该信息组的依赖，却不能与一个从头训练、直接预测 SNR 的公平对照画等号。

一个可比较的端到端实验应明确三种信息集合。第一种只用预测前可得的路径、频率、日期、太阳活动和功率假设，不给 VOACAP 派生量，直接拟合实测 SNR；第二种在相同直接目标下加入 VOACAP 输出；第三种维持本文残差目标与加回基线的结构。三组共享同一训练、验证和测试行集，同一哨兵值清洗决策、接近的模型容量和调参预算，避免某组因得到更多优化机会而占优。还应重复不同训练样本规模：如果物理结构主要改善样本效率，在小样本端可能更明显；如果它只是提供一个可由其他特征重构的函数，大样本端差异可能缩小。

当前模型在两个位置使用 VOACAP：一是将按路径、频率及太阳活动计算的输出作为输入特征，二是用该输出定义残差目标。前一变化增加特征信息，后一变化改变拟合函数及误差尺度；已有实验尚未把两者的效果拆开。若三组差异出现，还需检查早停、正则强度、下限截断比例和长路径分片，才能判断收益来自信息、模型归纳偏好还是异常值处理。本文未运行这一端到端三组对照，故结果部分不宣称残差法普遍优于所有直接回归。现有证据支持的是：在给定历史资料和实现协议下，这一结构得到已报告的误差，并为后续稀疏区处理提供统一入口。

评价物理基线时还应避免把 VOACAP 的绝对 RMSE 直接用作对物理理论本身的裁决。观测来自不同模式和设备，PSKReporter 功率以 50 W 代填；物理引擎调用还涉及天线、噪声和月份统计等工程设定。若这些设定与真实链路不一致，绝对差异包含任务口径差。合理的研究问题是“这组基线输出在当前观测目标上作为先验是否有用”，而不是从表中一个较大的 RMSE 推出短波物理模型无效。保留原始基线比较，是为说明校正任务的幅度；解释其原因需要更严格的同设备受控实验。

3.17 查询应用与频率边界

论文中的五条北京出发路径用于观察输出形态，每条路径都枚举波段和小时。格点越多，用户越容易在其中找到一个极高评分；即使每个格点的误差分布没有改变，取最大值本身也会放大乐观偏差。这是从预测图转向“推荐最佳时段”时新增的选择问题。若以热力图最高点直接评价系统，模型可能因为偶然高估而看似找到好机会。严格的推荐实验应先冻结允许选择的波段和时间窗，再让模型从中选一个或少数几个，最终用随后独立观测到的通信结果评价所选动作，同时与简单基线策略比较。

通信建议还涉及可执行条件。一个被预测为良好的波段，可能因用户执照、天线调谐、发射功率、当地干扰或比赛占用而不可用。系统当前没有完整采集这些约束；即使链路 SNR 回归准确，也不能直接给出“保证通联”的操作承诺。面向用户时，应把“预测较高的已报告 SNR 条件”与“建议实际发射”区分，并显示 VOACAP 原值、混合预测、更新时间及低支撑提示。若将来接入推荐功能，应先定义用户可用资源、失败成本和选择后反馈，再设计损失函数。

点预测误差与推荐价值需要不同指标。RMSE 衡量历史成功记录上的信噪比误差，推荐价值还可能取决于前几名波段排序、成功尝试次数及等待时间。一个模型可以略微改善平均 RMSE，却把少数关键格点排序颠倒；另一个模型可能 RMSE 稍差，但更稳定地避开明显不可用时段。本文没有受控的前瞻性推荐试验，因此结论停留在 SNR 预测和诊断性热力图。未来加入推荐指标时，要把选择策略与模型训练分开保存，避免事后从同一测试集挑选最有利的决策阈值。

时间邻域正则化取得正向结果，不能自然推广为沿所有输入维度平滑。频率改变时，短波链路可能跨越不同的电离层反射条件；在接近 MUF 的区域，传播可用性也可能出现比普通小时变化更陡的边界。一个频率核若把相邻波段的校正残差简单平均，可能跨过物理上并不相似的状态，把一侧有效的修正带到另一侧。第 4 章对频率核宽 0.2 的 12 折结果中，11 折劣化，平均改进为负。

MUF 也不能被用作绝对开关。某频率超过名义 MUF，常规链路模型会降低其可靠程度，但偶发传播、多跳路径、输入指数误差和模型近似都可能使真实接收发生。若系统在超过 MUF 时直接把预测 SNR 设为极低常数，它会把物理预测中的不确定边界变成确定性裁决，也会与历史中“物理判闭合而实际收到”的记录冲突。当前界面只对这类格点叠加低可靠度提示，不覆盖原始模型数值；这既保留模型输出供研究，又提醒用户此处不宜把数值当成可靠通联承诺。

对频率维设计新的约束，需要先决定约束的对象。若目的是减少色块视觉断裂，可在呈现层做插值，但须保留提示框中的未插值数值，并禁止把图像插值后的颜色读作新实验结果。若目的是改善预测误差，应在同一固定测试行上比较原模型与频率处理后的 SNR，并在相对 MUF 的不同区间分别报告结果。若目的是改善波段选择，应在有同期受控观测的候选波段之间评价排序，而不能在缺失候选上填入虚构的失败值。这三种目标使用不同标签与损失，不能因图像更连续而相互替代。

相对 MUF 的分层还涉及基线误差。MUF 是由同一物理引擎在给定空间天气和路径假设下输出；如果它在某些长链路或扰动条件下偏差较大，按其阈值划分的“安全

区”和“危险区”也会错位。未来可在已成功报告的样本上检查超过 MUF 的比例与误差分布，但成功记录只能证明少量例外存在，不能单独估计超过 MUF 后的总体失败率。更严格的边界实验需要已知发射与守听时隙，才能分辨“物理模型判弱但偶发接收”和“根本无人尝试”的情况。

当前配置采用时间维 4 h 邻域规则，其依据是 12 折实验和路径诊断；频率核缺少现有测试的支持，保持不启用。MUF 只作风险提示，不改变预测目标。后续频率方法若要替代这一配置，需要先明确物理边界的处理规则，再在独立时间块与地理块上验证误差和排序收益。

3.18 本章小结与局限

本章形成以下认识：

（1） 预设跨洲 DX 查询在稀疏区出现输出跳变，逐链路误差未显示该问题。因缺少完整日志，目前不能估计实际用户查询中的发生比例。

（2） 五条预设路径总体上表现为：历史观测支撑越弱，输出抖动通常越大。该结果可为定位局部失效提供量化线索，但样本有限，不能据此认定关系严格单调。

（3） 时间维支撑自适应邻域正则化在所测条件下同时改善**精度和稳定性**。12 折交叉验证中的精度提升为 0.41 %–0.61 %，各折均改善；五条参考路径的输出抖动降低 12.3 %–51.6 %。频率维平滑仍有代价（$\sigma_f = 0.2$ 时 −0.51 %），频率维实际核宽因而要设得远小于时间维。

（4） 在两个受控目标距离段及所测六种稀疏设置下，低容量数据驱动模型比物理基线更适合作为回退目标；后者的 RMSE 高 5.1–7.6 倍（表 3-7 六行的比值）。据此构造的混合策略在 10 000–14 000 km 段提高精度 1.28 %，各距离段的汇总均值均未出现劣化。

上述判断仍受以下条件限制：

（1） 抖动指标描述预测网格的形态，是否对应用户实际可读性仍缺少评价资料；评分阈值 10 目前由经验设定。将阈值改为 5、10、15、20 后，绝对抖动和中间三条路径的相对次序都会变化，不过支撑最充分的东京始终最低，最薄弱的圣保罗始终最高。阈值较大时，部分 VOACAP 参照已没有可读单元，本文据此只判断”抖动随支撑减少总体增大”，不排列任意两条路径的绝对优劣。

（2） 现用支撑度以路径长度计数，无法表示地理位置、季节及太阳活动水平上的覆盖差异。多维支撑估计有待研究。

（3） WSPR 与 PSKReporter 仅提供”成功接收”的正样本，缺少”未接收到”的负样本，现有数据无法直接检验 P(链路可用) 的校准度。无法直接验证标定结果，是可靠度输出最主要的不确定性来源。

（4） 表 3-8 中 14 000–20 100 km 段的改进（+0.66 %）只在 8/12 折成立，该段仅含 1 589 条样本，其证据强度低于 10 000–14 000 km 段。

（5） 支撑到核宽的映射采用全局经验规则，不能保证每条路径均达到局部最优。五条参考路径均未劣化，不足以证明该规则普遍最优。逐路径调优需要该路径自身的验证数据，恰是稀疏区所缺；若转用全局数据选择参数，又等同于在测试集上调参。本文只按数据量设定默认强度。

（6） 频率维平滑的收益为负（表 3-6），目前尚未找到既能降低抖动、又不损失精度的频率核宽。现有实现借助 σ_f 在密集路径上自动趋零来规避代价，稀疏路径仍需承担相应的精度代价。

第四章 离线实验与方法学检验

在本研究的数据条件下，单一留出集可能给出方向相反的改进结论。4.1 节先检验评估协议的敏感性，再据此解释模型性能、特征消融与负面实验结果。

4.1 评估协议

4.1.1 单一时间切分的失效

时间留出实验先以早期记录拟合，再用后期记录测试。所测方法的效应约为 0.5 %，与改变一次留出边界造成的波动接近；留出边界一旦改变，改进方向便可能翻转。

以第 3 章的邻域正则化为例，同一组参数分别在三种单一切分下受评如下：

（1） **切分 A**：全量数据按时间排序，末 20 % 作测试（测试集为 2024 年 9 月与 12 月，训练集横跨 2021–2024，包含一个完整的太阳活动上升段）；

（2） **切分 B**：随机 i.i.d. 划分（无分布漂移）；

（3） **切分 C**：仅取 2024 年数据按时间切分（同一太阳活动水平内的外推）。

表 4-1 汇总了各协议下的数值，图 4-1 则展示参数变化时的完整趋势。

表 4-1 时间平滑参数 σ_h 在不同评估协议下的 RMSE 相对改进（σ_h：h；改进：%；正值表示改善）

σ_h	切分 A	切分 B	切分 C	12 折交叉验证
1 h	+0.15 %	−0.07 %	+0.52 %	+0.409 % ± 0.09
2 h	+0.14 %	−0.24 %	+0.91 %	+0.532 % ± 0.11
4 h	−0.02 %	−0.53 %	+1.11 %	+0.614 % ± 0.17
6 h	−0.19 %	−0.77 %	+1.11 %	+0.581 % ± 0.23

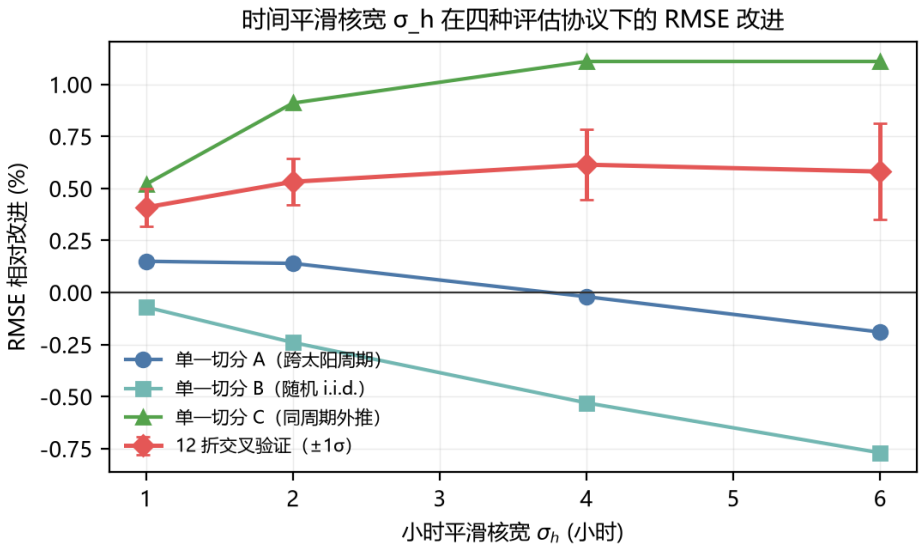


图 4-1 时间平滑核宽 σ_h 对 RMSE 相对改进的影响（清洗数据；四种评估协议；横轴：σ_h，h；纵轴：RMSE 相对改进，%）：蓝、青、绿曲线分别表示三种单一切分，红色菱形及误差棒表示 12 折交叉验证均值 $\pm 1\sigma$；0% 横线为无改进基准

当 $\sigma_h = 6$ h 时，三种切分分别得到 −0.19 %、−0.77 % 和 +1.11 %。**数值跨度达 1.9 个百分点，符号也相反。** 本次选取的三个切分中，有两个会把该方法判定为有害；12 折交叉验证则给出 +0.581 %，且各折方向一致。

4.1.2 分歧的背景：折间基准指标差异

图 4-2(a) 列出留一（年，月）交叉验证中未正则化混合模型的各折 RMSE：2022 年 6 月为 7.38 dB，2021 年 3 月为 8.50 dB，**二者相差 1.15 倍**。

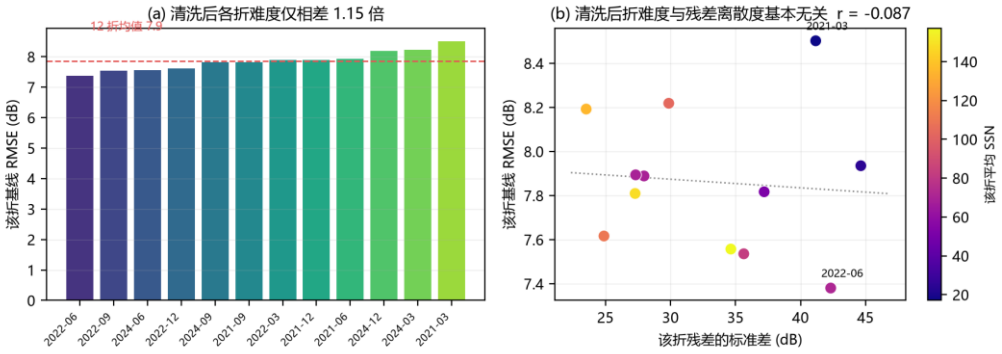


图 4-2 12 折留一（年，月）交叉验证的基准指标差异（统一施加 SNR_floor = −120 dB）：(a) 各折未正则化混合模型 RMSE（dB）；(b) 该 RMSE 与折内残差标准差（dB）的关系，点色表示折平均 SSN（颜色条）

依第 2.2.1 节统一物理基线下限后，折间难度比为 1.15。折 RMSE 与残差标准差、太阳活动的相关系数分别为 $r = -0.087$ 和 $r = -0.301$，仅凭这些相关性还无法解释各折误差为何不同。

第 4.1.1 节待检验方法的效应约为 0.5 %，与单次切分中的评估波动接近。移动留出边界会同时改变测试样本的时间和来源构成。对于这样的小效应，需要结合多个折次的变化方向及离散程度判断。

训练样本影响分析可以从模型预测反向定位高影响样本，为查找数据错误提供系统化工具[27]。

4.1.3 本文采用的协议

核心方法与参数以留一（年，月）交叉验证比较。单一留出实验检查协议敏感性，留一地理区域实验检查空间维度，两者分别标注。对具有时间或空间结构的数据，随机切分可能低估模型在新时段或新区域上的泛化误差，分块验证应尽可能与部署目标一致[20]。时间序列交叉验证的有效性仍取决于误差结构与切分方式是否满足相应假设[21]。执行时按（年份，月份）将数据划为 12 组，每轮留出一组作为测试集，其余数据再按 90 : 10 分成训练集和验证集，验证集只服务于早停。各折相对改进以均值、标准差及改善折数报告。

验证集必须与测试集独立。 早停只读取独立验证集，最终性能由未参与训练和调参的测试集给出。固定树数的对照模型 RMSE 为 8.10 dB，使用独立验证集早停后则为 7.86 dB；这组数据只说明固定轮数在该协议下产生了更高误差，没有提供跨种子方差的估计。各方法统一选用独立验证集早停，以保持比较条件一致。

交叉验证与生产路径还存在一处口径差异。 本章脚本通过**随机 i.i.d. 划分**从训练数据中取得早停验证集，该集合与训练数据同分布，验证损失因而长期缓慢改善，轮数可达 1 500 轮上限（12 折中 7 折）。生产路径则按来源分别取训练池的时间尾部作为验证集，2026-08-30 的在役产物快照收敛于 1 311 轮。两条路径内部的对照组共用设置，因此各自比较仍然有效；但**交叉验证的绝对 RMSE 不能与第 3 章单一留出集的数值直接比较**。

生产增量重训遵循同样的独立性要求：早停验证集不与准入测试集重合，候选模型和在役模型在同一测试集上比较。实现细节见 5.5 节。

4.1.4 该问题的普遍性

当方法效应与切分波动处于同一量级时，单一留出集不足以判断改进方向。时间、空间或来源构成只要随留出边界改变，单次估计就可能翻转符号。

4.1.5 发射端经度分区留出：空间诊断范围

4.1.3 节的协议只在**时间**维度（年、月）上留出，尚未检验空间记忆。由于数据集本身被欧美站点主导（2.1.1 节），低 RMSE 可能主要依赖高密度区域的样本，未必表明模型学到了距离、太阳天顶角与频率之间可跨区域迁移的物理关系。如果这一假设成立，模型在训练期间几乎未见的地理区域上，误差应明显升高。

为检验模型对发射端区域的依赖，本文采用留一地理区域交叉验证：按发射端经度以 60° 分带，共划分 6 个区域；每次整体留出一个区域，其余数据再按 90:10 切分训练与早停验证集，其他设置与 4.1.3 节一致。该分带约对应大洲量级。相较更细的经纬网格，此方案减少小折样本不足的问题；143 个 20°×20° 网格中，最大格有 21 899 条，许多网格远小于此。该协议只检验发射端经度分区，不能排除接收端、邻近区域或重复路径重叠。

表 4-2 发射端经度分区留出结果（6 个 60° 区间；RMSE 单位：dB）

区域（发射端经度）	测试样本数	混合模型 RMSE（dB）	VOACAP RMSE（dB）
[−180, −120)	4 629	7.81	36.62
[−120, −60)	37 766	8.27	35.82
[−60, 0)	11 968	8.00	39.40
[0, 60)	29 476	8.10	39.53
[60, 120)	2 948	7.05	35.95
[120, 180)	6 350	8.57	38.13

六个区域的 RMSE 位于 7.05 – 8.57 dB，相差 1.22 倍，与 4.1.2 节按时间分折得到的 1.15 倍处于同一量级。样本最少的区域（[60, 120)，2 948 条，主要为南亚/中亚站点）反而得到最低 RMSE，而样本最多的区域（[−120, −60)，37 766 条，北美）仅处在中位。折难度与该区域在训练集中的占比并无单调关系；这一结果仅说明本次发射端经度分区下未观察到稳定的区域性误差结构，不能排除接收站、相邻空间块或区域内站点在训练与留出间重叠所产生的记忆效应。

大洲尺度的分带无法排除城市或台站级的记忆效应。数据集地理覆盖不均，留出区域的样本量通常仍高于随机分布下的预期，不能将实验视为完全陌生区域的严格泛化测试。本次切分未检出稳定的区域性误差结构，结论限于当前数据允许的检验范围。

4.1.6 指标的可比性与解释顺序

RMSE 是测试样本分布上的加权汇总，不是脱离数据口径后仍保持不变的模型属性。第 3 章参与阈值选择的开发阶段时间留出得到 8.21 dB，第 4 章 12 折结果为 7.86 dB；两者的测试时段、样本覆盖和早停验证集切分并不相同，数值接近不表示后一个模型较前一个提高了 0.35 dB。地理留出的 7.05–8.57 dB 也只能在六个经度分区的共同协议内解释。

方法效应较小时，配对方向比单个汇总值更能说明结果是否稳定。时间平滑在三种单一切分上出现正负相反的结果，而 12 折均指向改善；这种差异要求同时查看效应幅度、折间离散和改善折数。子群体样本量同样影响判断：14 000–20 100 km 段只有 1 589 条样本，改善出现在 8/12 折，其证据强度低于样本更充分、方向更一致的距离段。

生产闭环沿用同样的比较纪律。候选与在役模型只有在同一轮、同一可信测试集上才可直接比较；下一轮加入新数据后，测试集及来源权重已经变化。运行记录中的 RMSE 轨迹用于发现异常和核对准入过程，不构成长时期性能曲线。要检验跨月份增益，仍需冻结训练、验证和测试时间窗，并在相同协议下重训。

4.2 主模型性能与特征分析

4.2.1 整体性能

12 折交叉验证下，混合模型的平均 RMSE 为 7.86 dB，纯 VOACAP 为 37.90 dB。这两个数值与第 3 章的 8.21 / 34.69 dB 较为接近，但不应视为同一口径。第 3 章使用参与阈值选择的单一时间留出集（末 20 %），交叉验证则覆盖全部 12 个（年，月）组合；两者对早停验证集的切分方式也不相同，见 4.1.3 节末。跨方法比较只能使用同一协议下的数值，后续因而以交叉验证结果为准。

4.2.2 特征重要性与特征组消融

表 4-3 列出整组置零的消融结果。各实验维持特征维度不变，避免维度变化干扰不同设置之间的超参数可比性。

表 4-3 固定维度特征组置零实验（12 折交叉验证；RMSE 单位：dB；相对变化为各折 RMSE 变化的平均值）

置零的特征组	RMSE 均值	相对完整模型	变差折数	名义 p 值（探索性）
（完整模型）	7.862	—	—	—
VOACAP 派生特征组（置零）	18.215	+131.61 %	12 / 12	< 0.0001
几何	8.155	+3.71 %	12 / 12	< 0.0001
发射功率	7.946	+1.07 %	12 / 12	< 0.0001
频率	7.917	+0.71 %	12 / 12	< 0.0001
季节	7.917	+0.70 %	11 / 12	0.019
太阳活动	7.879	+0.22 %	9 / 12	0.294
时刻	7.878	+0.21 %	9 / 12	0.058
日照几何	7.871	+0.11 %	9 / 12	0.317

表 4-3 的 p 值为与完整模型比较所得的逐折配对 t 检验名义结果，未经多重比较校正。折间评估并非独立，且该折集合参与方法选择；这些 p 值仅作探索性描述，不作确认性推断。VOACAP 基线组含 {SNRVOACAP,fMUF,f/fMUF}。“相对完整模型”列为各折相对变化的均值（口径见表 3-6 的说明），因此不等于左侧两个均值相除。

表 4-3 中，各特征组的敏感性差异明显：

（1）对 VOACAP 派生组高度敏感。在当前实现中，移除物理派生输入造成了明确的误差代价；由于残差目标本身由实测 SNR 与 VOACAP 之差定义，该置零结果说明架构依赖，不单独识别物理基线的因果贡献。

（2）辅助特征可分为两类。 几何、发射功率、频率和季节的效应幅度为 0.70 %–3.71 %；前三组在 12/12 折中均变差，p<0.0001。太阳活动、时刻与日照几何三组的变化幅度为 0.11 %–0.22 %。表中 p 值均为未经多重比较校正的探索性名义结果，不能作为确认性推断。一种尚未单独验证的解释是特征冗余：三组变量都在描述电离层光化学状态，某一组被置零后，余下变量仍可能吸收部分相关信息。

若按分裂次数排序，接收点纬度（7 140 次）、SNR_{VOACAP}（7 090 次）、工作频率（6 420 次）和路径中点经度（5 715 次）位列前四。**分裂次数不能等同于因果重要性**。SNR_{VOACAP} 和接收点纬度的分裂次数接近，前一特征所在组被置零后误差接近翻倍，后一特征所在的几何组被置零后误差只上升 3.71 %。这类统计只回答模型如何使用现有输入，不能据此推断变量的独立因果效应。

4.2.3 结果比较、成因与研究贡献

与现有研究的差异。 第 1.9.3 节所列方法包括电离层参数预测、端到端链路预测和物理引导残差学习。它们的绝对 RMSE 不能与本文直接排序，原因在于数据来源、频段、参考带宽、样本筛选和测试切分并不一致。比较因此限定在同一数据集、同一留出协议和同一指标内：参与截断阈值选择的历史时间留出中，混合模型与 VOACAP 的 RMSE 分别为 8.21 dB 和 34.69 dB，误差下降 76.3 %；12 折月份交叉验证中，两者为 7.86 dB 和 37.90 dB。与第 1.9.3 节的端到端路线不同，本项研究保留物理模型作为显式基线，只让学习器估计残差，并以参与阈值选择的历史时间留出、月份交叉验证、空间切分和生产来源分层检查不同的迁移边界。固定维度置零、稀疏样本与收缩实验进一步检验了架构的信息依赖和失效条件。

比较条件与解释范围。 观测样本、19 维输入、折内训练—验证—测试边界、早停规则和 12 个折次在模型比较中保持固定。改变的是模型条件，组内结果因而具有共同评价口径。VOACAP 输出在训练目标、特征构造和推理阶段均施加同一哨兵值下限-120 dB。表 4-3 中，将 VOACAP 派生组在输入维度不变时置零，模型 RMSE 上升 131.61 %，12/12 折同向，表明当前架构依赖这组输入，但不能分离其因果贡献。扩展特征使误差提高 0.42 %，12 折中有 11 折变差；在当前样本规模和观测偏倚下，增加变量未获净收益。共线性、测量噪声及分布不稳定性可能增加方差，抵消新增信息。完成统一质量控制后，时间交叉验证的折间难度比为 1.15；地理交叉验证的 RMSE 为 7.05–8.57 dB，跨度为 1.22 倍。两种切分分别检验时间与空间维度。

本章在指定的时间、空间和抽稀协议内比较模型，并用哨兵值处理与固定维度置零诊断数据和架构依赖。结果支持在所测数据分布中使用残差校正，但不估计 VOACAP 基线独立于残差定义的因果贡献。

4.3 负面结果

4.3.1 扩展特征的交叉验证结果

扩展特征共六项，均有明确的物理动机：路径最高纬度（极区吸收）、估计跳数、$log(f/f_{MUF})$、路径白昼比例（D 层吸收）、距晨昏线远近（灰线增强）和天顶角跨度。按 4.1 节确立的协议，清洗后数据用于执行 12 折交叉验证，数值列于表 4-4。

表 4-4 扩展物理特征的 12 折交叉验证结果（清洗数据；相对变化为 RMSE 变化；负值表示劣化）

数据	结论	相对变化	名义检验结果（探索性）
已清洗	劣化	−0.42 %	t：$p = 0.0014$；Wilcoxon：$p = 0.0010$；11 / 12 折变差

扩展特征使 RMSE 劣化 0.42 %，11/12 折变差。配对 t 检验与 Wilcoxon 检验所得 p 值均为探索性名义结果；折间相关且该折集参与方法选择，因此不作确认性推断。该组特征未显示稳定收益，未纳入最终模型。

4.3.2 残差校正量的全局收缩实验

第 3.8 节比较了稀疏区的回退目标。本节通过全局收缩实验，检验减弱逐链路校正对预测误差的影响。校正量写为

$$\hat{r}'(\mathbf{x}) = m + \alpha(\hat{r}(\mathbf{x}) - m), \qquad m = \text{该折校正量的均值} \tag{4-1}$$

$\alpha = 1$ 表示不收缩，$\alpha = 0$ 则将校正量压缩为常数。后一种情况等价于 VOACAP 加固定偏置，不再保留逐链路校正。收缩至均值而非零，可在保留**整体偏置修正**的条件下检验削弱个体校正的代价，避免混入表 3-2 所示 -23.22 dB 整体偏差的影响。该对照用于考察向物理模型回退的策略，结果见表 4-5。

表 4-5 校正量全局收缩的代价（12 折交叉验证；α 无量纲；劣化为 RMSE 增幅；正值表示劣化）

α	劣化均值	标准差	劣化折数
0.95	+2.39 %	1.32	12 / 12
0.90	+8.75 %	4.24	12 / 12
0.75	+44.44 %	18.16	12 / 12
0.50	+128.87 %	44.38	12 / 12
0.25	+223.38 %	69.99	12 / 12
0.00	+321.32 %	95.07	12 / 12

本表由既有收缩对照及交叉验证输出整理；折划分和早停设置与时间邻域交叉验证一致。统计口径为各折相对变化的均值，定义见表 3-6 注。此处不增加训练或重算指标。

收缩幅度即使只有 5 %（$\alpha = 0.95$），也已在**全部 12 折**造成劣化。当校正量被收缩到一半，误差增至 2.3 倍，仍然没有一折例外。随 α 减小，劣化单调加速。所测区间内未出现收缩改善误差的情况。

4.2.2 节的置零实验改变输入，这里的收缩实验削弱输出校正量。前者将 VOACAP 派生组置零后使 RMSE 增加约 130 %，后者重新引入已识别的系统偏差。两项负面结果从不同位置检验了架构依赖。

4.4 计算开销

服务端单次预测包含 7 波段 × 24 小时 = 168 个单元，其耗时按环节分解如下：

表 4-6 服务端单次预测的耗时分解（7 波段 × 24 小时；耗时单位：ms）

环节	耗时	说明
VOACAP 物理基线	160–235 ms	与路径长度相关，占主要部分
ML 残差校正 + 邻域正则化 + 低容量混合	164 ms	1 311 轮产物；每单元 45 次求值（9 时刻 × 5 频率），共 7 560 次
验证集常数偏差校准	< 0.1 ms	对批量输出加同一常数，已包含在上一行总耗时中

164 ms 为 2026-08-30 的 1 311 轮在役产物在北京—纽约稀疏链路上的机器学习校正耗时：先预热 20 次，再测试 20 次，中位数为 164.1 ms，范围为 154.5–198.6 ms。

密集路径在 $\sigma_h < 0.25$ h 时自动跳过邻域计算，不产生额外开销。服务端对预测结果缓存 900 s，因此用户实际感知的延迟，主要取决于缓存命中率。

本次独立工程快照包含 2 696 049 条可训练数据，其中实际拟合 1 004 330 条、验证 111 540 条、可信测试 539 001 条。一次完整试运行实测耗时 **96.2 s**，包括数据读取、特征整理、训练和分来源评估。完整试运行由后台学习循环承担，在线请求不等待该任务完成。

4.5 估计量、数据处理与评价选择

评价一个预测方法之前，应先确定要估计的量。本章最基本的单位是固定测试行集中的一条成功上报记录；在第 j 折上，RMSE 是该折所有测试记录平方误差平均值的平方根。若关注方法改动的相对效果，应在**同一折、同一测试行集**上同时求未改动和改动后的 RMSE，再计算该折的相对变化。把 12 个折的相对变化取平均，与先分别平均两组 RMSE 再相除并不等价，因为每折基准误差不同。

若把所有测试记录合并后计算一个 RMSE，则样本数较多的时间块会获得更大权重；若先计算各折 RMSE 再平均，则每个（年，月）块获得相同权重。两种量都可以有意义，但回答的问题不同：前者更接近“从现有记录池随机取一条”的误差，后者更接近“先随机取一个已采样时间块，再取一条记录”的误差。本文主要报告后者和配对折变化，是为了让不同太阳活动阶段都有机会影响方法判断。它仍不等于未来年份或未采样月份的平均误差，因为这些条件没有进入分母。

局部输出稳定性以另一单位计算。式（3-4）的分母是两种方法共同可读的相邻网格对，而不是测试记录条数；第 3 章五条参考路径每条构成一个预设场景。即使某方法在 12 折链路 RMSE 上稳定改善，也不能自动推出它在所有热力图上更符合用户认知。相反，某条路径的抖动明显下降，也不能覆盖在长路径段 RMSE 仅 8/12 折改

善的事实。把两个分母并列写出，有助于防止“精度”和“可读性”被一张数字互相替代。

生产准入的估计量又不同。系统在一轮重训中比较同一批可信测试记录上的候选与在役产物，因此当轮差值具有配对基础；该批记录随收集增长，下一轮的测试分布就已改变。即使两轮都报告候选 RMSE 和在役 RMSE，也不能把第一轮在役的绝对值与第二轮在役的绝对值直接相减推断模型变化。晋升门槛的 0.2 % 只说明“当轮候选相对当轮在役超过指定差值”，还须结合分距离和频率的 2 % 退化护栏。研究中的固定协议效应量与生产中的准入阈值因此属于不同估计任务。

统计显著性需要比一个 p 值更细的解释。表 4-3 的配对 t 检验以 12 个时间折的差值为样本，能够描述这些已采样折上平均差的方向，但折之间可能共享大量训练记录，未必完全独立。多组特征同时被检验时，未作统一的多重比较校正也会提高偶然显著的机会。因此本章始终把效应量、改善折数、折间离散和物理可解释性与 p 值并列，不把边缘显著或不显著等同于“有用”或“无用”的二元裁决。VOACAP 派生组的 131.61 % 劣化幅度远高于小组别效应，解释重点仍是目标定义造成的架构依赖，而不是仅凭很小的 p 值宣称物理因果性。

评价泄漏既可能由字段直接携带答案，也可能在参数选择与测试集复用时发生[28]。

本研究中的错误结论曾经从不同环节进入。第一类是标签构造污染：闭合链路的 VOACAP 极端负值在残差目标中变成巨大正值，随后进入训练和测试。若只在展示图表时截断坐标轴，而不改变目标与特征，学习器仍受污染；若只在训练时截断，测试和推理又不一致。第 2.2.1 节的修复把同一下限施加到入库、训练目标、特征和推理路径，随后重新计算离线结果。这样修复的是估计对象本身，不是为了选择较好看的图表。

第二类是验证集和测试集角色混淆。梯度提升树通过早停选择实际轮数，若早停监控的就是最终测试集，每一轮的测试误差已参与模型选择。即使没有显式搜索超参数，最终报告的测试分数也会乐观。修复方式是在每个训练折内部另切独立验证集供早停，再让留出的时间块或生产可信测试集只承担最终评价。这个改变会影响旧产物和新候选的相对公平性：如果旧在役产物由泄漏流程构造，而新候选已修复泄漏，那么后者在完全相同训练数据下可能看似退化。第 5.3.1 节报告了这种实际情况，并在比较新采收益之前重建基准产物。

实现来源与时间切分时，还须检查新记录是否真正进入了训练部分。早期新增观测远少于历史数据时，若先全局按时间排序再划训练集，新记录可能全部被划入验证

或测试尾部。若新来源全部进入验证或测试尾部，模型训练阶段便没有接触新来源；由此得到的重训结果失去检验新采学习效果的基础。生产切分因此改为按来源分别构造训练、验证和测试，并以新数据训练比例控制早期狭窄切片的纳入量。比例 0.5 来自当时兼顾新旧分布的受控扫描；新增观测跨月增长后，应在更新的覆盖条件下重新扫描。

三类问题的共同点，是它们可以在模型架构完全不变时改变结论。一个实验报告若只列模型名称和 RMSE，读者无法知道差异究竟来自数据、目标定义、早停泄漏还是算法。本文把输入文件、清洗规则、切分函数、早停数据、比较行集和产物版本作为实验协议的一部分。新增研究若无法给出这些要素，就只作假设或方法建议，而不会被写入结果表。相较于不断增加模型容量，先让估计对象和评价路径可复算，是本任务中更基础的研究贡献。

折间方差异常曾先后被归因于“新数据不够”和“时间覆盖太窄”。逐条核对物理输出、距离段及残差目标后，发现主要原因是哨兵值污染。新增数据的时间覆盖仍短，长期泛化仍待检验，但这不能解释当时的极端折间方差和超长路径误差。本文保留两次错误归因及其反证，供复核排错过程。

4.6 稀疏区对照与负面结果约束

稀疏区研究最容易犯的错误，是把“观察到样本少”和“减少样本后出现的问题”混为同一证据。前者是自然数据的相关性，受地理、时段、传播模式和台站行为共同影响；后者是受控干预，可在固定目标段和测试行集下改变训练支撑，却只能模拟所设计的稀疏形式。第 3 章先用五条预设路径观察输出形态，再用受控抽稀比较主模型、低容量模型和纯 VOACAP，最后以留一（年，月）交叉验证检验混合权重。三个步骤的顺序提供了由现象到机制再到方法效果的证据链，但每一步的适用范围都不同。

路径示例首先回答“用户可能看到什么”。北京到东京、悉尼、伦敦、纽约和圣保罗跨越不同长度，按统一月份、太阳指数、功率、七个波段和 24 小时构成可比网格。表 3-3 中悉尼与伦敦的支撑和抖动次序不一致，说明单一距离计数不足以解释全部局部变化。

受控抽稀实验回答另一个问题：“如果目标距离段的训练记录减少，哪种回退更稳？”它保留目标段的评价行集，并将目标段拟合样本压到若干预设规模。这样一来，模型间差异不必由测试集换人解释。纯 VOACAP 在所测设置中即使面对极少训练记录，误差仍明显大于低容量残差模型，说明“数据少所以必然回物理基线”在本任务中不成立。但抽稀只改变了记录数，没有让剩余记录同时变成另一地理区域、另一模

式或另一太阳活动阶段。它对自然稀疏区是一种有限的反事实近似，不能等价于完全陌生路径的部署试验。

混合权重的交叉验证最后检验“把低容量回退加入主模型是否有净收益”。这里需要分别看目标距离段、其他距离段和整体。10 000 至 14 000 km 段得到 1.28 % 的跨折汇总改进，并在 10/12 折改善；更长的 14 000 至 20 100 km 段仅在 8/12 折改善，证据明显弱于前者。整体均值 +0.07 % 很小，不足以越过生产门槛；如果只报告整体，会把局部干预的目标和代价同时隐藏。距离段本身也只是一个分组变量：即使同在 10 000 至 14 000 km，路径穿越的电离层区域、时段和模式仍可不同。论文因此用“所测距离段”而不使用“所有跨洲路径”的表述。

式（3-5）只纳入两种方法共同可读的相邻单元，以免大量零评分稀释平均值。这个定义使抖动结果依赖可读阈值。阈值从 5 改到 20 时，绝对抖动和中间路径排序发生变化；两端最密集和最稀疏路径的相对位置较稳定。这种敏感性意味着指标适合诊断明显不连续的展示效果，不宜单独作为优化目标。若只以最小抖动选择核宽，极端情况下把整张网格压成常数即可“获胜”，但传播时变信息已经被破坏。第 3.7 节把 RMSE 与抖动并列，正是为防止这一退化解。

下一轮稀疏区试验需预先冻结更大的路径集合，纳入不同发射点、纬度、季节和太阳活动状态，使现有选择接受可推翻的检验。应同时定义低支撑评分、相邻单元跳变、条件 RMSE 和真实用户决策任务。若在更广泛路径上时间平滑减少抖动但稳定增加误差，方法只能用于界面展示而不能作为预测值；若低容量回退在未见地理区域失效，权重规则也须重新标定。本论文没有把这些未来检验纳入当前结果，却把它们写成可以推翻现有选择的明确条件。

扩展特征、频率维平滑和全局校正量收缩都具有表面上合理的动机，却在实验中失败。扩展特征包括极区路径、估计跳数、灰线和日照相关变量，似乎能让模型更接近传播机理；但在清洗后的 12 折协议中，组合加入后 RMSE 劣化 0.42 %，11 折变差。可能的解释包括变量噪声、与已有特征高度相关或不同时间块中关系不稳定，现有数据不能把三者分开。正确做法是报告组合负效应，不把其中任一猜测当成确证原因，也不在没有新的配对实验时逐个删减变量直至出现“正结果”。

接近 MUF 时传播状态可能随频率快速变化。同步扰动 MUF 并保持相对频率后，所测频率核宽仍降低精度，因此时间邻域的收益不能直接外推至频率轴；当前规则压低频率核宽。

全局收缩实验直接检验减少数据驱动校正量是否提高稳健性，结果给出反证。向折内平均校正量收缩 5 % 已使全部 12 折劣化，收缩到一半的平均误差增幅达到 128.87 %。该实验没有说任何条件下都不能收缩；它说明对所有路径施加同一个收缩系数，会把已学到的距离、频率和日照依赖偏差一并抹去。若只看某些极端路径的平滑视觉效果，可能误以为整体方法改进；分折链路误差揭示了这种代价。低支撑混合之所以选择局部权重且保留主模型至少 0.5 的比例，正是受这个负面结果约束。

生产偏差校准再次展示优化目标的冲突。在固定可信测试集上，常数校准使 RMSE 有稳定的小幅改进；但三个随机种子的 MAE 均劣化 0.70 % 至 0.91 %。RMSE 对大误差平方加权，校准可能减少少量较大偏差而让较多普通样本的绝对误差略增。没有逐来源和逐距离的完整损失分布时，不能把这个解释写成唯一机制。至少可以确认“通过当前 RMSE 门槛”与“所有用户相关指标都改善”并不等价。准入护栏若只看整体 RMSE 及部分分片，仍可能遗漏 MAE 和来源子群体。

四项负面实验决定了当前配置中的几项取舍：限制输入复杂度、关闭频率核平滑、弃用全局收缩，并保留准入分片护栏。这些结果交代了参数和规则的来由，也留下了后续实验的比较基线。若重新引入类似特征或频率平滑，应先说明数据、目标或协议有何变化，再与这里的负面结果对照。

4.7 复现性、选择风险与折结果再分析

可复现性首先要求区分“可重算同一结果”与“可在另一时期得到相同结论”。前者依赖固定输入文件、数据清洗版本、训练代码、随机种子、折划分和软硬件环境；后者还依赖新时期的台站网络和传播条件。本文的历史离线实验以固定的 93 500 条数据为基础，脚本分别执行交叉验证、空间留区、受控抽稀、特征组置零及收缩实验。覆盖审计另保存文件 SHA-256，使读者能够确认描述性统计使用的输入版本。后台采集更新后的统计应与论文冻结快照分开记录。

训练和评价的顺序也属于复现协议。对于每个留出折，先确定测试行集，再从其余资料构造拟合与早停验证集；任何需要从数据估计的参数都应只读取被允许的部分。物理基线下限作为清洗规则，在所有折开始前以固定代码应用，不能针对某一测试折单独选阈值。邻域核宽和回退权重的候选值在章节中公开，结果要按同一测试行集配对计算。若以后增加搜索空间，应另留最终锁定测试集，否则反复查看 12 折并选择最优组合，也会使折平均结果对这些已见折过拟合。

第 3 章热力图和路径抖动使用特定发射点、五个接收点、月份 8、SSN 78、功率 100 W、七个波段和 24 小时；改变任一条件都可能改变可读单元集合。表 3-3 的支撑

计数来自固定历史池，不应误用某一交叉验证折的拟合集；第 5 章运行图剔除了明确时间段的受污染记录，图中上线数因而小于表中完整运行记录。保留输入条件后，后续版本的数值差异才能追溯到系统状态或统计口径。

同一部署环境承担后台重训与前台查询，并行能力受计算预算约束。一次完整生产试运行读取约 269.6 万条可训练记录，包含训练、验证和分来源评估耗时 96.2 s；服务端稀疏链路的一张 168 单元网格，物理基线占 160 至 235 ms，机器学习校正等环节约 164 ms。前者的耗时不构成用户请求延迟；后者须分别报告首次查询和缓存命中的成本。当前实现让训练在后台运行、模型产物通过原子替换并按文件修改时间热加载，旨在控制服务可用性。

外部有效性应沿时间、空间、通信模式及设备条件四个方向分别检验。时间轴上，历史资料只含三年中的四个月份，新采快照集中于 2026 年 8 至 9 月；空间轴上，成功报告受台站分布影响，长链路和偏远区域少；模式轴上，历史主要为 WSPR，新采以 FT8 为主；设备轴上，天线、功率和本地噪声大多未知。一个固定协议的交叉验证即使把所有已采样块都轮流留出，也无法模拟这四轴同时外推。

后续实验宜先建立足以解释结论的测试条件，再决定如何扩大训练样本。可以预先冻结一个完整昼夜、跨多个月份和多种太阳活动水平的测试窗，并按来源、距离、波段与接收端活动划分报告；同时保留一个完全未参与参数选择的最终时间窗。若要评价接收概率，还需另外建设发射与在线守听配对数据。若要评价用户决策，则需记录查询场景与实际选择，而不能只从热力图抖动推断体验。本文当前结果为这些下一步实验提供了清楚的起点和失败标准，却不冒充已经完成的外部验证。

为展示平均改进背后的折间差异，本文对既有时间邻域、消融和收缩对照的 12 折输出作只读汇总，核对折标识顺序并记录输入文件摘要，再计算均值、中位数、极值及改善方向折数。新增数字来自原实验逐折输出，属于描述性再分析；模型训练和显著性检验均未重做。

基础混合模型的 12 折 RMSE 均值为 7.862 dB，中位数为 7.853 dB，最小与最大分别为 7.380 和 8.502 dB。与只写“折间难度比 1.15”相比，这组数给出绝对范围：最难折比最容易折高约 1.12 dB。时间核宽 4 h 的相对改进在 12 折均为正，均值 0.614 %、中位数 0.586 %，最小 0.351 %、最大 1.078 %。因此“各折方向一致”并不意味着效应完全均匀；最大改进约为最小改进的三倍。正文仍以预设核宽扫描的完整结果为准，这里的极值只帮助读者理解一个平均值背后的变化范围。

频率核宽 0.2 的情况相反：12 折中 11 折变差，平均改进为 −0.508 %，中位数 −0.538 %；最差折为 −1.449 %，唯一改善折为 +0.741 %。若只说平均“略微劣化”，会忽略某个时间块存在明显反向结果；若只挑那一个改善折，则会错误地建议启用频率平滑。需要进一步检查该折的频段、MUF 和太阳条件，才可能提出对频率平滑何时有用的假设；现有逐折结果本身不足以将其归因于某个物理过程。

扩展六项物理特征的相对改进均值为 −0.415 %，中位数 −0.324 %，范围为 −0.949 % 至 +0.080 %，同样只有一折改善。特征组置零实验则有更大的量级：去除 VOACAP 派生输入的“改进”在全部 12 折为负，均值 −131.608 %，中位数 −132.764 %，范围为 −187.835 % 至 −72.023 %。这里的负号表示误差上升；极值说明依赖程度随时间块变化，却没有一折显示该组可以被简单置零。由于监督目标也含物理基线，仍不能把这些折间数字转写成物理模型的独立因果效应。

校正量向折内均值收缩 5 % 后，平均“改进”为 −2.387 %，中位数为 −2.259 %；12 折全部劣化，最轻一折为 −0.542 %，最重一折为 −4.230 %。折间分布在各收缩强度下同向，表明对当前历史样本统一减小逐链路校正量未获得稳定收益。

离线实验的结果不仅取决于训练和测试如何切开，还取决于研究者在看到结果后做了多少选择。时间核宽、频率核宽、回退权重、距离分段、评价指标和可视化路径若都在同一套折上反复试验，最终展示最好的组合会高估预期效果。12 折逐项结果可以揭示方向是否一致，却不能把已经用于挑参数的折重新称为完全独立的验证。本文同时报告时间 4 h、频率 0.2 等设置的正负结果，以及全局收缩和扩展特征的失败。同一数据上的迭代开发仍可能使效果估计偏乐观。

每项方法实验应区分三个阶段。探索阶段允许查看误差曲线和异常路径，用于提出机制假设；选择阶段在训练块内部比较有限候选，固定参数；确认阶段只在此前未参与选择的时间或地理块上评价预先确定的主要指标。若现有数据不足以分出第三阶段，可以诚实地把结果称为开发集上的交叉验证证据，并把未来冻结窗设为确认任务。当前论文中的 12 折方案具有跨已采样时间块的检验价值，但方法开发过程曾反复使用这些历史资料，故结论不应被写成一次未经任何开发接触的独立外部验证。

路径可视化也受选择偏差影响。五条北京出发路径在稀疏性上有差异，适合展示输出行为；它们不是从所有可能的用户查询中随机抽样。未来评价“用户看到的热力图是否更有用”，需要预先冻结路径抽样框，并纳入普通、边缘和极端路径，而非只选展示效果最明显的地图。

多重比较还有统计层面的代价。若检验许多波段、距离段、月份和核宽，即使每一项都没有真实优势，也可能偶然出现若干正数。本文没有把每个分片的微小百分比都标成显著发现；主要判断依赖预先关心的机制和跨折方向，且对 14 000–20 100 km 段只有 8/12 折改善明确保留不稳定结论。将来若要对某一小分片提出确认性效果，应预先指定主分片和主指标，提供区间或基于成簇重采样的不确定性，并说明未调整的其他探索性比较。不能把 12 个有相关性的时间折简单当成 12 次独立实验，对其正负号直接套用独立二项检验。

4.8 成对差值与稀疏压力测试

RMSE 对误差取平方，因而给极端链路误差较高权重。少数异常链路得到改善，就可能拉低 RMSE，即使更多链路的绝对误差略有增加。MAE 按线性方式计入每条记录，更容易反映这种变化，但也可能弱化对极端失败的警惕。生产偏差校准中，两项指标确实出现分歧：固定可信测试集的 RMSE 改善，三个随机种子的 MAE 却均劣化。报告上线结果时，若只列出准入目标，就会把这种分歧隐藏在“模型改进”之中。

严格比较两个模型时，每条测试记录应保存同一真实 SNR、同一条件下的两组预测及残差，而不只保存两个汇总 RMSE。这样可以绘制成对绝对误差差值的分布，计算改善记录比例、极端误差的变化和按来源、距离、波段的分片差异。若某项方法通过降低少数离群误差获得全部 RMSE 收益，报告应指明收益集中位置；若误差中位数和尾部方向相反，也应同时呈现。当前归档保存主要表格和逐折结果，部分历史试验缺少逐行残差。成对误差分布列为下一轮复评的必要输出。

配对条件还需约束数据处理。两个模型要在相同测试行、相同实测 SNR、相同哨兵值处理、相同功率假设下计算差值。若一个模型对闭合链路剔除、另一个保留，分母改变，RMSE 的差异不能归因于模型；若一个模型的 VOACAP 结果在更新后重算，另一个读旧缓存，也不能认为只改变了校正算法。实验脚本保存输入摘要和参数，是为复核这种配对。对不同切分协议，例如历史时间留出与空间留区，只能分别陈述各自估计对象，不能将两个 RMSE 相减当成同一次模型增益。

按分片报告时，样本量和基线误差必须同列。一个长距离段可能只有少量样本，其中一条极端记录改变就能使百分比大幅摆动。对可用折数不等的分片，报告应列出进入汇总的折、每折样本数和汇总权重；简单平均每折百分比与先汇总全部平方误差再求百分比一般不相等。第 4.7 节明确给出已保存逐折改进的均值、范围与改善折数，它是一种描述性再分析；原实验表中的总体百分比保持原计算口径。两个数值不同不必然是错误，但必须说明聚合方式。

整体时间交叉验证检验的是已出现月份与年份块之间的转移，但稀疏区风险往往由多个条件共同造成。一个压力测试矩阵可把训练支撑、地理新颖度、频率接近 MUF 程度、来源口径和时间外推跨度作为轴。每个轴至少给出常见与困难水平，再选择少量有科学意义的交叉条件，例如“长路径、低站点数、日出附近”和“常见距离、陌生地理区域、频率接近 MUF”。每个单元应在评估前确定纳入规则和最低样本量；不足的单元标为无证据，不能因没有负面数据而标为通过。

压力试验分别改变训练记录数量，以及训练和测试记录的地理位置。受控抽稀从目标距离段移走训练样本，空间留区把指定地区的链路留作测试。抽稀覆盖两个目标距离段和六种设置；空间留区仍受原始观测网的地区分布限制。未来叠加多个困难轴时，样本可能迅速稀薄，结果方差也会增大。应先通过冻结的覆盖审计确定可估计单元，将无支持区域列为使用边界，避免以插值生成缺少真实测试记录的“验证结果”。

压力测试需要与训练方法相互独立。若根据测试矩阵中某个稀疏单元调节 K_w 或核宽，那个单元就从测试转为开发资料。可以在内层训练块选择规则，再在外层固定困难单元上评价；或者保留当前规则，在新采的未来月份上直接复测。对每次复测，既看平均误差，也看超出某个事先定义阈值的失败比例、预测评分的单调性和推荐排序稳定性。阈值应由具体通信任务确定，不能事后从结果中挑出让模型看起来最好的 dB 线。

评估稀疏区方法时，低支撑区域的收益须与常见链路的代价并列报告。若新方法只在低支撑单元改善，却使常见链路明显退化，系统应结合用户分布和失败成本判断是否采用；若整体指标改善但极端单元持续失败，不能用平均值遮盖。第 3 章的方法设计以支撑量调节强度，目的正是尽量让密集区保持主模型、稀疏区增加约束；当前实验支持其中一部分距离段，另一些长距离折并不稳定。

4.9 复现链条、应用评价与工程稳定性

足以改变结论的失效条件也属于复现记录；最终产物和随机种子不足以解释版本差异。本研究遇到的失效包括：单一时间切分给出与分块协议不同的印象，粗模型早停曾接触测试集，来源切分曾使新采资料不进入训练，VOACAP 哨兵值曾污染目标与特征，锁失效曾使两个训练者并发。这些错误分别位于评价、训练、数据定义和运行层。若在论文中只保留修正后的漂亮数字，后续研究者很难理解为什么同一项目的旧报告和新报告不同。

一条完整的修复记录，应交代错误入口、受影响的行或模型、异常表现和修复规则，还要说明重算时固定了哪些对照条件。以哨兵值为例，入口是闭合链路编码；症

状是极端残差和折间难度畸变；修复要求训练目标、特征、推理和所有论文实验同时截断；对照应固定同一行集。若只在推理端截断，即使用户看到的图正常，训练目标仍被污染，复现链条并未闭合。AST 覆盖检查正是对这一类遗漏建立自动防线。

统一截断哨兵值后，数据编码与评价口径得到修正；按相同条件重算的 RMSE 下降。早期“数据不够”“时间覆盖窄”未能解释折间难度，决定性原因是哨兵值污染；时间覆盖窄仍限制早期新采收益的外推。论文按发生顺序保留这些错误归因和后续修正，使结论的改变可以追溯。

本文直接测量历史成功报告的 SNR 误差，用户则依据预测在波段和时段之间作选择。点预测误差因此只是选择质量的一个相关指标。若两个候选格点的真实 SNR 都远高于通信门限，模型颠倒其顺序会增加 RMSE，用户却可能仍能完成通信；若两格点分别位于门限两侧，同样大小的排序错误就可能导致失败尝试。评价实际使用价值还需要候选集合、设备条件、失败成本和替代方案，而当前成功报告表未完整记录这些信息。

因此，评价链应分层建设。第一层继续使用冻结成功报告测试集，比较 RMSE、MAE、偏差和极端误差；第二层在同一测试集上考察预先指定的波段排序或时段排序，但必须确认每个候选格点都存在可比的实际观测，不能用缺失记录假装低 SNR；第三层才是在受控发射或授权用户研究中评价按模型建议选择后的成功率、等待时间与重试次数。每上升一层，都需要额外的事件和决策资料。本文完成的是第一层及输出形态诊断，没有第二、三层的完整真实标签，因此不把平滑热力图直接称为改善通信成功率。

第二层的排序评价还须处理选择性观测。现有众包网络往往在某些波段活动多，另一些波段没有与之同期的报告；仅在有两条成功报告的格点比较排序，会倾向于容易接收的条件。可行的未来方案是在固定发射排程下轮换波段，并由同一组接收站守听，形成在时间、功率和设备上尽量可配对的候选集。若排程无法覆盖所有候选，应承认只评价已覆盖子集，不能把“未报告”自动排在末位。排序指标如前一名命中率或名次相关也应预先定义，避免从多种指标里选最有利的一项。

系统建议如果改变了用户的尝试选择，也会改变后续报告的来源。例如，用户集中尝试模型偏好的波段，新增观测便可能集中于此，其他波段则缺少可比记录。于是闭环可能出现“模型推荐—观测增多—模型更确信”的自增强过程。评价推荐对用户决策的影响，需要保存原建议、实际选择、未选候选和当时可用设备，并设置一部分不受推荐影响的参考发射或探索策略，用以区分传播变化和建议引起的行为变化。当

前模型没有自动发射或频段控制功能，上述反馈仍是未来推荐功能需要研究的实验条件。

12 个时间折的 RMSE 均有改善，但这些折共享训练资料和月份锚点，也可能受相同数据处理偏差影响。本文同时报告绝对 dB、百分比、改善折数和负面分片，以展示效果大小及方向。

工程稳定性由代码检查、故障注入和运行日志核验；固定协议下的预测误差另由交叉验证 RMSE 评价。

重采样单元应匹配外推目标：按日期成簇检验时间变化，按站点成簇检验设备与地理网络变化。复评应预设主单元，并报告其他单元的敏感性。

修复锁后，采集速率回到配置范围；加入共享熔断器后，上游请求恢复。常数偏差候选虽通过 0.2 % 的 RMSE 门槛，MAE 却劣化，说明现有准入规则未覆盖所有指标。采集、请求治理和模型准入分别评价。

4.10 本章小结

（1） 单一留出边界的调整足以反转改善方向，即使方法本身保持不变。同一参数在三种切分上分别为 −0.19 %、−0.77 %、+1.11 %，其中两种会将方法判定为有害；12 折交叉验证则给出 +0.581 %，且 12 折无一例外。当前数据的折间难度比为 1.15，方法效应量与单一切分评估波动处于同一量级，判断改进方向需要多折证据。

（2） VOACAP 派生组在固定维度置零实验中 RMSE 上升 131.61 %，12/12 折均劣化；这一方向性结果属于开发阶段描述，不作独立确认性推断。

（3） 扩展特征在清洗后数据上使 RMSE 劣化 0.42 %（11/12 折变差，$p \approx 0.001$）。这组特征未纳入最终模型。

（4） 补充的留一地理区域实验（4.1.5 节）将发射端划为六个大洲量级区域，RMSE 相差 1.22 倍，与时间分块的 1.15 倍接近。该切分未检出稳定的区域性误差，但仍不能排除台站或城市级记忆。

第五章 众包持续学习系统与运行验证

前文比较了静态历史资料上的模型，本章转向持续观测到达后的系统更新。观测经采集、入库后，系统定期重训并进行准入评估。本章重点检查：公网上报进入拟合过程后，评价资料能否保持独立。

修正数据与评估口径后的首次比较中，早期新采 PSKReporter 条件切片上，候选模型的 RMSE 比较值低 14.63 %，历史分布的 RMSE 则上升 0.08 %（5.5.2 节）。

5.1 总体流程

系统将运行中的数据流分为”采集—处理—学习”三段，其间的连接关系见下图。

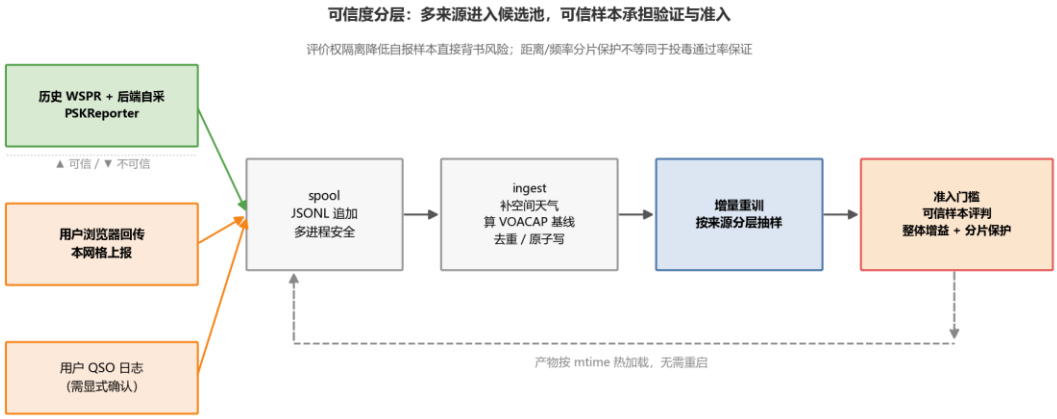


图 5-1 众包持续学习闭环与可信度分层：绿色表示可信来源（历史 WSPR 与后端自采 PSKReporter），橙色表示用户或浏览器上报，灰色表示缓冲与入库处理，蓝色表示按来源分层的增量重训，红色表示基于可信样本的整体增益与分片保护；虚线表示模型产物热加载回边

spool 缓冲用于承接并发记录，并缩短入口响应时间。IPv4 与 IPv6 分别由两个进程监听，若同时改写同一 parquet 文件，可能互相覆盖写入或损坏文件，JSONL 追加记录可避免这种整文件改写。逐条计算 VOACAP 基线也不适合放在需毫秒级响应的上报入口，因此计算移至批量 ingest 阶段，与请求响应分离。

ingest 批处理先补录观测时刻的空间天气 SSN/F10.7/Kp，再逐条计算 VOACAP 基线与残差。按时刻、双方呼号及频率去重之后，处理结果并入主数据文件。

两类入库观测均可进入训练候选池，评估权则仅授予可信来源。

5.2 观测来源与空间覆盖

后端每隔 15 分钟采集 PSKReporter 全球流，并默认从每批数据中选取 1 200 条。后端直接取得的记录在入库时获得**可信**来源标记。

采集速度与样本构成分别受请求配额和选取策略约束。

（1）上游约束的是请求次数，不是单次返回的数据量。 该接口的限流较严，实测中，本机在短时间内发出十余次请求后就会遭到全面拒绝，因此每轮只允许发起一次请求。但是，单次返回的链路数量远超早期采集额度。一次请求约可获得 1 450 条通过校验的链路，而额度曾长期停留在 120 条，相当于**丢弃了 92 % 的可用数据**。这一截断并非计算开销所必需：入库时逐条计算 VOACAP 基线实测为 5.4 ms/条，取满一批只占轮期的 0.4 %，一次完整重训另需 4 s。将额度提至 1 200 条，并把轮期缩短至 15 分钟后，请求频率仍远低于上游可承受水平；轮期也未短于全球流 10 分钟的回溯窗口，不会因此重复取数。调整后，日采集量由 5 760 条升至 115 200 条，积累到历史数据集规模所需的时间也由 16 天缩短到不足 1 天。

回溯窗口从 10 分钟增至 30 分钟后，返回量分别为 1 494 条和 1 493 条，未见增加。这与”规模基本固定的近实时数据流”的解释一致。**扩大窗口未增加样本量，却增大了时间戳误差上界。** 分组响应中没有时间字段，所有记录只能以取样时刻作为时间戳，窗口长度因而成为误差上界。这一偏差会继续传入模型，因为太阳天顶角正是根据时刻计算的特征之一。

（2）额度受限时，应先检查入选样本的构成。 早期策略按波段轮流保留前 120 条，目的是避免数据全部被 20 m 占据；该波段的上报量通常比 160 m 高两个数量级。波段轮转未考虑路径距离。某批数据中，>10 000 km 的链路共 99 条，>14 000 km 共 18 条；经过轮转截断后，却只留下 9 条和 2 条。**长链路主要损失于批次筛选阶段。** 第 3 章的五条参考路径呈现，超长路径位于输出较不稳定的一端，而固定历史观测池中该段支撑仅 0.1 %；这类截断会继续削弱目标场景的观测覆盖。

采集策略因而改为按稀缺程度分层。落在关注网格内的链路优先保留，长链路再按距离由远及近纳入；为防止采集分布完全受单一批次支配，长链路占额度的比例仍设有上限。剩余额度继续通过波段轮转补齐，以保留波段多样性。整个调整不增加上游请求。额度为 120 时，改动后连续两批分别收录 62 条与 47 条长链路，改动前只有 9 条。额度升至 1 200 后，这一层已很少触发截断：实测选中的 1 200 条中含有 121 条长链路，批内长链路全部保留。分层机制仍保留，以便额度再次收紧时优先纳入稀缺链路。

定向采集曾经尝试利用上游接口的 senderLocator 参数。这个参数在实测中**不生效**：以某南半球网格作为条件发起请求，返回的仍是未过滤的全球流；1 518 条记录中，发射网格符合请求条件的为 0 条。“关注网格”只能改在本地实现筛选。

用户浏览器回传。 为绘制传播弧线，前端本来就会查询本地用户所在网格的 PSKReporter 上报。用户启用贡献后，浏览器只是将这批**已经获取**的数据回传后端，不会额外请求外部服务。回传内容限于 PSKReporter 公开的接收报告，包括呼号、网格和信噪比；用户输入的位置、日志以及其他本机私有信息都不在上传范围内。

欧美密集区主导 WSPR 与 PSKReporter 的覆盖；用户回传则集中于贡献者所在网格及其进出链路。只有贡献者位于薄弱区、且其记录通过质量控制，回传才可能补足该区域。覆盖与精度变化须按所在区域及有效记录量核验；参与人数本身不能说明补足程度。

用户还可以在日志面板中主动贡献个人通联记录。这类数据可补充 SSB，以及公开流中稀少或字段不完整的模式；PSKReporter 已包含部分 CW 解码记录，因而 CW 不能笼统归为”未覆盖”。日志还可记录 PSKReporter 缺失的**实际发射功率**。日志能补充更详细的信息，也涉及更强的隐私属性，必须经用户逐次确认，不随”贡献数据”开关自动上传。

5.2.1 持续运行中的两类耦合故障与防护

持续学习除训练逻辑外，还依赖各运行环节的协调。定时任务、双服务进程与共享上游接口相互影响，曾引发两类静默故障：程序仍在运行，采样率和重训节奏却已偏离配置。

（1）锁误过期后两个进程均执行学习任务。锁过期阈值为 900 s，心跳每 1 800 s 刷新；两次心跳间另一进程误删锁，原持锁进程未退出，导致双进程并行。实测采集速率达到配置上限的 197 %，并有并发改写模型产物的风险。

修订后的执行资格，要结合锁的过期状态、原进程存活状态以及当前所有权判断。过期阈值设为 max(900 s, 3 × 任务周期)，高于正常轮期。每次心跳核对锁内进程号：所有权丢失即结束本轮；原进程确认退出后，接管方以原子创建方式竞争锁。

故障复现暴露了进程活性探测的缺口。后端终止后，单纯依赖过期计时会使新进程空等 45 min，采集与重训在此期间全部停摆。周期性学习任务的文件锁因此还要定义**所有权验证、活性判断与故障接管时限**。

（2）前台查询与后台采集共享上游配额，失败重试反而延长封禁。 PSKReporter 的网格明细、活跃度展示和后台全球流采集共用同一上游。上游返回 503 后，失败结果原先只缓存 60–90 s；两个前端组件随后持续重试。一次 40 min 的观测中，前端共触发 **107 次**上游请求，而后台采集器按设计每 15 min 才请求一次。失败请求本身会继续触发限流，结果是展示功能把后台采集任务“饿死”，连续多轮入库为零。

为使退避约束覆盖全部调用者，前台与后台请求统一经过同一 HTTP 出口及共享熔断器：首次失败暂停 5 min，连续失败按倍数延长，最长 30 min；熔断期间，前台与后台均不得发出真实请求，一次成功响应即可清空失败状态。封禁由此自然结束，恢复首轮从 1 473 条可选链路中按分层策略取满 1 200 条。交互查询与学习任务共享外部配额时，局部限速没有全局约束力，限流状态必须跨调用方传播并在出口处强制执行。

5.3 开放上报的风险与可信度分层

公网上报接口无法预先限定调用者身份，格式校验也不能排除**数据投毒**。

伪造报告可与真实报告具有相同格式，内容核验又需要系统尚不具备的独立观测源，因此无法逐条判定真伪。

本文通过分离**训练权与评价权控制这一风险：**

训练候选池接纳多来源记录；验证与准入使用可信样本。

在增量重训中，trusted 来源标记界定记录的用途。历史 WSPR 和后端自采 PSKReporter 记录属于可信资料；用户提交的 contrib-psk、contrib-qso 只能用于相应的候选流程，不能充当可信准入样本：

（1） **训练候选池**可以接收上述各类数据，但实际拟合仍受离群筛选、来源切分、新数据纳入比例和早停验证留出的共同约束；

（2） **测试集仅取可信样本**，具体包括历史 WSPR 与后端自采 PSKReporter，用户上报不直接充当同一候选模型的准入依据；

（3） **早停验证集**从可信样本中另行切出，并与测试集保持不相交。

来源分层隔离了准入评价，但用户记录仍参与候选拟合，投毒风险因而没有消失。准入阶段另用保留的可信样本配对评估候选与在役；同批用户提交记录不进入这项裁决。这条评价边界的有效性仍取决于可信来源与测试覆盖；分布外攻击需要单独检验。

系统还从接口校验、离群筛选和产物替换三个环节控制异常与滥用风险：

（1）上报先经过接口字段校验。 接口仅接收近 24 小时的时间戳、符合 Maidenhead 格式的网格和位于 HF 业余波段的频率。大圆距离限于 200–20 100 km，信噪比限于 $[-40, +40]$ dB。来源标签接口仅接受 psk/qso 两个值，并在服务端映射为 contrib-*，**调用方无法自称可信来源**。单次请求上限为 200 条，每 IP 每 10 分钟最多接收 3 000 条。

中位数绝对偏差（MAD）筛选用于用户上报残差，超过 6σ 的记录被剔除。这项处理**只施加于用户数据**。自采数据中的极端残差可能对应 Sporadic-E 突增等真实传

播现象，一概剔除反而会丢失信息。样本量少于 50 条时，MAD 估计自身即不稳定，因此不执行剔除。

（3）候选与在役模型在同轮共享可信测试行。上线要求整体 RMSE 改善超过默认的 0.2 %，且样本充足的距离段和频率段不得劣化超过 2 %。通过准入后先备份旧版本，再替换产物。历史 WSPR 的固定 18 700 条留出记录在多轮准入中反复使用；同轮候选—在役配对可支持当轮工程决策，但重复查看使该集合不再是独立的确认性测试集，35 次上线也不是 35 次独立验证。

5.3.1 切分方式：一处使闭环无法学习的缺陷

训练许可与实际入模是两个独立环节。早期流程虽正常运行，切分方式却将新增观测排除在训练集之外，模型因而没有接触新分布。

早期流程对全表按时间排序后作 80 : 20 切分。93 500 条历史 WSPR 记录排在最前；新增观测未达到历史数据的四分之一时，切分点始终位于历史记录**内部**。当时的构成如下：

训练集 100 % 是历史数据，而可信测试集 93 % 是新采集的数据。

新增众包数据主要进入测试集，训练集未接触这些数据，两侧的分布差距随新增观测积累而总体扩大。运行记录表明，每次重训的训练集都不含新增观测，候选相对在役的劣化幅度又随累计样本量呈总体扩大趋势，相关系数为 $r = +0.425$，斜率为每千条 $+0.097$ 个百分点。**只看持续劣化的指标，容易把问题归为数据不足；检查训练集构成，才能识别新增数据未参与训练**的切分缺陷。

修正时改用**来源分层**切分。可信来源分别取其最新 20 % 作为测试集，不可信来源不进入测试集；其余记录构成训练候选池，非历史来源再受 0.5 的阶段性纳入比例约束。早停验证集从各来源候选池的尾部另行留出，实际早停只使用其中的可信样本。分层前后的构成差异见表 5-1。

表 5-1 不同来源分层策略对训练候选池与可信测试集构成的影响（同一数据集）

	训练候选池（含后续早停验证）	可信测试集
全局时间切分（原）	历史 91 940（100%）； 新增 0	历史 1 560（6.8%）； 新增 21 347（93.2%）
按来源分层（本文）	历史 74 800； 新增 8 538；上报 39	历史 18 700（81.4%）； 新增 4 270（18.6%）

若直接取训练池时间尾部的 10 %，较晚采集的新观测会几乎占满验证集，使模型按新分布选择轮数，却由历史数据主导的测试集评价；这使得候选实测劣化 6.2 %。

5.4 与模型准入门槛解耦的标定量

第 3 章的自适应正则化需要两项标定量：可用观测池的路径长度直方图用于估计支撑 n，在役模型的实测 RMSE 用于确定可靠度尺度。路径长度直方图取自可用观测池，不等于某轮实际拟合集。它刻画**数据的形态**，在役 RMSE 则刻画**在役模型的表现**；两者用于标定正则化参数，随每轮重训更新，不充当候选准入证据。

标定量若与产物替换绑定，候选模型未通过准入时，正则化与可靠度标定也会停止更新。第 3.8.4 节的低容量模型面临同样的问题。它的收益集中于 10 000–14 000 km 段，该区间只占样本的 2.2 %，整体 RMSE 改进也只有 +0.07%，低于准入门槛。若仍以全局门槛决定它是否生效，这个预设目标距离段的局部收益可能长期无法独立触发上线，而其实际查询权重仍待日志验证。低容量模型由容量上限约束，并配有一条硬规则：其误差超过在役模型 3 倍时，拒绝启用。

5.5 运行状态与实际效果

系统部署后的运行状态与快照统计量见表 5-2。

表 5-2 从产物重建后开始计数。 确认 5.5.1 节的两处缺陷后，文中废弃并重建全部模型产物，同时重置重训历史。原记录仍归档保留，用于核对 5.5.1 节的论断。表中的”自动重训次数”不包含缺陷期间的数十次运行；这些记录对应重建前的系统，不应与重建后记录拼接作纵向比较。表内观测量为全部存量观测，和重训次数的计数起点不同。**采集到的观测数据未作任何删改**，所以观测量和站点数仍是连续的。

表 5-2 持续学习闭环运行状态（数据截止 2026-09-12 08:17 UTC）

项目	数值
累积观测	2 889 356 条
后端自采（可信）	2 888 307 条
用户贡献	1 049 条
覆盖接收站点	34 177 个
自动重训次数	1 174
通过门槛上线次数	35
候选模型 RMSE 范围	8.28 – 9.06 dB
在役模型 RMSE（实测）	8.25 – 9.01 dB

本表记录截至 2026-09-12 08:17 UTC 的冻结历史快照。表格与图注均以该截止时点为准，不代表当前在线状态；本次修订未将无法由本地历史记录核验的后续运行数字写入论文。

闭环已产生 35 次模型更替。 1 174 次自动重训中，35 次通过准入门槛并替换了在役产物，其余 1 139 次被拒绝。修正前后的对照见 5.5.2 节。清理后的可比重训记录见图 5-2。截至数据截止时刻，新观测已达历史数据的 3090.2 %。

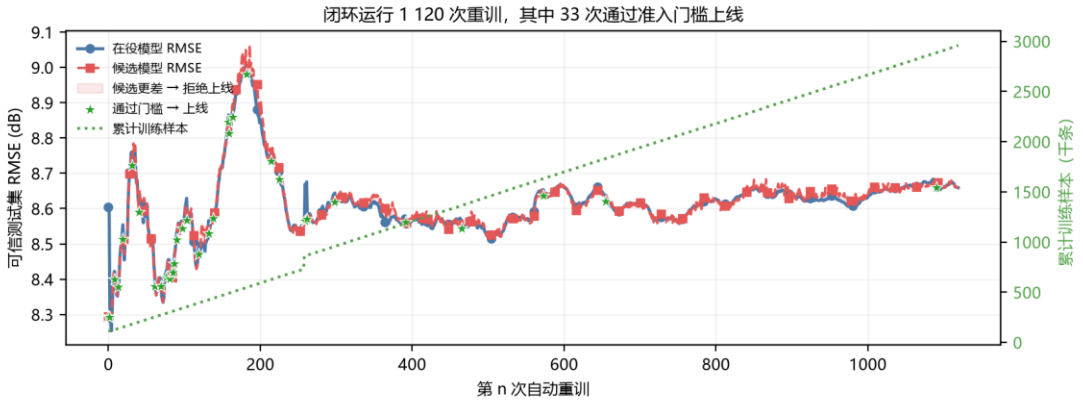


图 5-2 闭环重训与准入记录（排除 2026-08-11 08:48:59 至 2026-08-12 13:30:00 UTC 的受污染记录后，图中包含 1 120 次自动重训和 33 次上线；可信测试集；RMSE 单位：dB）。蓝色圆线表示在役模型，红色方虚线表示候选模型，浅红阴影表示候选较差，绿色星标表示通过准入并上线，绿色点虚线表示累计训练样本数（千条）；横轴为重训序号。各点对应当轮评估，可信测试集逐轮增长，因此 RMSE 不宜跨轮直接比较。截止时测试集共 591 877 条，其中 573 177 条（97 %）来自新采集数据。

5.5.1 闭环评估的实现约束

候选与在役模型的比较受切分和测试独立性约束。

（1）切分时要保留来源分层。 全局时间切分曾使训练集的新观测数为 0，可信测试集却以新观测为主，未接触目标分布的候选模型因而被系统性低估。训练、验证和测试现均按来源分层构造（5.3.1 节）。

（2）验证集和测试集必须独立。 早停不允许读取准入测试集，受评估泄漏影响的模型产物也不能继续担任比较基线。文中因而重建在役产物，并在后续重训中固定验证集、测试集与产物来源之间的独立关系。

在训练数据完全相同时，通过独立验证集训练的候选模型在同一测试集上的 RMSE 比受泄漏影响的历史产物高 4.58 %，即相对表现更差。旧产物受测试集信息泄漏影响，具有后续候选无法复现的比较优势，必须随训练代码修正一并重建。下节在重建基线上加入新采数据进行对照。

5.5.2 早期来源切片的同轮误差变化

修正数据切分、训练流程并重建基线产物后，检验新增观测的性能收益。

针对已发现的三处缺陷，重训先按来源切分数据，按阶段性比例纳入新增观测，并另留早停验证样本；VOACAP 输出统一施加第 2.2.1 节的哨兵值下限。全部模型产

物随后按当前代码重建，闭环开始正常更替在役产物；表 5-2 中的上线次数会随运行继续增长。下表取自修正后的首次重训，其对照设置为：在役模型只用历史数据冷启动，候选模型在此基础上按 0.5 的纳入比例使用众包观测。

表 5-3 修正后首次重训的性能比较（同一可信测试集；n=23 041；RMSE 单位：dB）

评估范围	在役模型	候选模型	变化
整体	8.596	8.293	+3.53 %（通过 0.2 % 门槛，已上线）
新采 PSKReporter（4 341 条，19 %）	10.097	8.619	+14.63 %
历史数据（18 700 条，81 %）	8.209	8.215	−0.08%

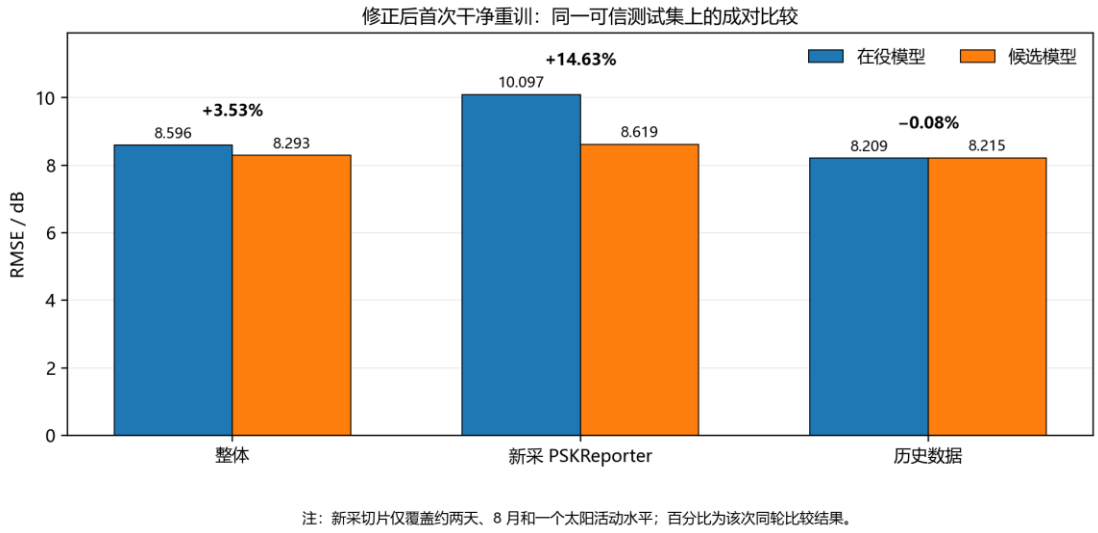


图 5-3 修正后首次干净重训的分来源 RMSE 成对比较（同一可信测试集）：整体 RMSE 改善 3.53 %，新采 PSKReporter 条件切片的 RMSE 比较值低 14.63 %，历史数据切片劣化 0.08 %。新采切片仅覆盖约两天、8 月和一个太阳活动水平，因此图中差值只表示该早期条件切片，不支持跨昼夜、跨月份或跨太阳活动阶段的长期泛化结论

在役产物只用历史数据冷启动，候选则按 0.5 的比例增加新采 PSKReporter 观测。两者比较时，新采条件切片的 RMSE 比较值低 14.63 %，历史分布 RMSE 上升 0.08 %。这一差值出现在后端新采观测进入候选拟合后的条件切片上，不能外推为普遍传播收益，也不能归于用户上报。

施加物理基线下限后，独立时间分块协议与生产来源分层协议分别得到 +11.35% 和 +14.63%，改善方向一致；两者使用的测试行集并不相同。两套数据均仅覆盖约两天、8 月及同一太阳活动水平，结论限于这一早期条件切片。两套协议的测试样本不同，不能将独立时间切分的昼夜构成用于解释表 5-3。

5.5.3 早期新增数据的时间覆盖审计

表 5-3 的 14.63 % 的误差差值来自修正后的首次干净对照，其新增来源只覆盖约两天、8 月和一个太阳活动水平。为检查这一结果的时间外推范围，另行对早期新增观测作独立时间切分；该切分与生产准入的按来源分层测试集并非同一行集。

表 5-4 早期新增观测独立时间切分后的 UTC 小时覆盖（3 h 分箱；样本数：条；跨度：h）

子集	样本数	每 3 小时一档的样本数（0→24 时）	实际时间跨度
训练	15 525	1425, 1423, 1725, 2643, 2640, 2764, 1483, 1422	33.7 h
早停验证	1 726	0, 1, 7, 0, 0, 0, 1377, 341	—
测试	4 294	1420, 1426, 359, 0, 0, 0, 0, 1089	9.1 h

本表是对早期新增观测的时间覆盖审计；表 5-3 使用生产环境的按来源分层可信测试集。两者的新增来源测试样本分别为 4 294 条和 4 341 条，不能把本表当作表 5-3 的样本分解。

测试部分只覆盖 21:45–06:51 UTC，白天时段没有样本；历史测试集则在全天各档均有观测。因而现有的 14.63 % 只表示这一早期条件切片中的误差差值，不支持跨昼夜、跨月份或跨太阳活动阶段的长期泛化判断。后续运行量的增长也不能代替冻结协议后的复评。

5.5.4 全局门槛看不见子群体上的收益

表 5-3 说明分来源收益进入整体指标时会被来源权重稀释。可信测试集中历史数据占八成，整体 RMSE 因而主要由历史数据的 RMSE 决定。PSKReporter 条件切片的 RMSE 比较值低 14.63 %，被稀释到 19 % 权重后仍留下 3.53 % 的整体增益，候选模型才越过门槛。若局部改进只有几个百分点，历史部分持平也可能使整体增益低于门槛，候选模型仍会被拒绝。

低容量模型仍受整体准入门槛约束。**整体增益可能掩盖局部劣化，局部改善也未必足以使整体增益达标；重训报告应保留 by_source 字段，便于检查各来源对整体结果的影响。**

来源判别器的 AUC 为= 1.000。新采 PSKReporter 统一采用 46.99 dBm（50 W）功率假设，历史数据包含 19 个真实功率值；新采记录仅来自 8 月，太阳黑子数也只

有一个取值。删除来源相关列后，历史分布劣化由-5.4%扩大至-8.1%。结果与模型利用相关变量区分来源分布的解释一致，但不能证明其内部形成了明确的分来源策略。

5.5.5 后续生产优化：RMSE 改善不等于所有指标都改善

后续生产试验单独处理树模型的常数偏差，不将结果归因于新增数据。独立验证集上估计的偏差约为 0.7 dB。据此，系统按 3.2 节公式，只使用验证集估计加性偏移，再将该偏移与 $\lambda = 5$ 的 L2 设置打包为一个候选整体，交由原有准入门槛评估。候选模型在 **2026-08-08 00:52 UTC** 自动通过门槛：同一可信测试集上，RMSE 从 8.5010 降到 8.4705 dB，改善 **0.360 %**，在役产物中保存的偏移量为 **0.697 dB**。

复核分别针对偏移校准和 L2 设置展开。实验沿用固定生产切分的 83 842 条可信测试样本，在三个随机种子下重复。只加入验证集偏移时，RMSE 稳定改善 0.381 %–0.425 %。L2 单独作用时的变化为 -0.083%、$+0.003\%$和 $+0.053\%$，方向并不一致。将两者组合后，RMSE 改善 0.337 %–0.481 %，MAE 却同时劣化 0.70 %–0.91 %。在这组对照中，**基于验证集的常数偏差校准，稳定改善了当前准入目标 RMSE**。L2 的独立收益不稳定，其他误差指标也未同步改善。

5.6 面向用户的透明度

（1）并列热力图可选择对齐显示。 VOACAP 原始输出与混合模型的差距可达数十 dB，且这是系统性偏移，不是随机噪声，见 2.2 节图 2-2。若两张热力图使用同一套绝对量程着色，VOACAP 面板会整体落在色阶一端，几乎只剩一种颜色，波段与时段之间的相对差异也随之消失。界面为此提供默认关闭的「对齐呈现」。它把两个模型在当前全部（波段，小时）格点上的差值中位数作为偏移量，只平移 VOACAP 面板的呈现值。平移仅用于比较**相对格局**，例如两个模型是否都认为某一时段或波段较好，不构成对 VOACAP 的重新校准。面板标题旁会标出所用偏移量，提示框同时保留对齐前的原始值。两侧面板仍依据各自数据自适应色阶，互不影响。对齐平移不会拉宽未对齐面板的色阶，也不会压缩其自身数值差异的可辨识度。

（2）低置信度格点单独标记。 热力图的（波段，小时）格点各对应一次预测。若工作频率超过当时路径的 MUF（最高可用频率），链路便超出名义高可靠传播区间；偶发传播虽仍可能发生，常规模型在此给出的却是低置信度外推。当前可逐格点变化且有明确物理依据的提示只有这一项。5.4 节的可靠度尺度由整条链路共用，不能表示格点差异，界面也不另行估计尚未验证的逐点不确定度。超出 MUF 的格点以叠加标记和悬浮警示显示；没有此类格点时，相关提示及图注均隐藏。

5.7 闭环状态机与必须维持的不变量

持续学习系统不能仅用“每 30 分钟训练一次”概括。一个正常周期至少包含等待、竞争唯一执行权、向上游请求、校验与入库、判断新增样本阈值、构造来源分层样本、训练候选、在可信测试集上比较、备份旧产物、原子替换以及释放执行权。任何中间阶段都可能失败，下一轮必须知道上一次究竟完成到哪里。若采集成功而训练失败，观测可以保留等待下一轮；若训练成功但准入不通过，候选不得覆盖在役产物；若替换成功而服务还在内存中使用旧模型，在线输出就与准入记录不一致。状态记录和产物版本因此是模型行为证据的一部分。

锁文件存在并不充分，还须能确认其所有者仍活着、心跳没有失效、执行者仍拥有同一把锁。早期故障中，过期时间短于任务周期，导致正常锁被误删；持锁进程又吞掉心跳异常，最终形成两个执行者。这类错误可能不立即使 API 失败，却会让采集率达到配置值的近两倍，并使模型产物面临并发写入。所有权检查与原子抢锁使单训练者约束能够在运行中验证。

训练、准入评估和在线推理共用特征定义、物理基线下限及偏差校准字段。候选通过后备份旧产物并原子替换；服务按产物时间热加载新版本。回滚后仍需核对实际加载版本和影响范围。

第三个不变量是比较的同轮性。每轮的候选和在役模型必须在完全相同的可信测试行集上求误差，并在评估后记录分母、来源构成和护栏结果。若在役使用上一轮测试集、候选使用本轮测试集，任何 0.2 % 门槛都会失去统计意义。第 5.5 节的 1 174 次重训、35 次上线描述的是状态机按规则运行的次数，后续纵向效果仍需另设冻结测试协议。

前台网格、活跃度查询与后台采集都占用 PSKReporter 配额，因此上游请求需要统一约束。若各调用者只在自身函数内做短暂缓存，失败请求仍会从其他路径持续触发。共享熔断器把上游失败状态提升为所有调用者共同遵守的限制；一次 503 后先暂停 5 分钟，再按连续失败退避，成功时清零。这个设计牺牲封禁期间前台信息的新鲜度，以换取后台采集恢复的机会。页面必须如实显示暂不可用或旧数据时间，不能把熔断期间没有新观测解释为“传播活动归零”。

这些不变量具有不同的验证方式。锁的测试应复现心跳间隔、进程退出和遗留锁接管；产物测试应覆盖替换与热加载；准入测试应验证同轮行集与来源排除；熔断器测试应模拟连续失败和恢复。单个 API 成功返回只说明接口路径可用，不能证明后台循环没有停摆。运行面板因此需要显示上次采集、下一轮时间、最近重训和在役版本，

使静默故障至少能被发现。该可观察性本身不改善 RMSE，却决定论文中的“系统已运行”能否被独立核对。

5.8 来源可信、记录可信与模型可信的区别

系统直接从公开上游获取原始报告，并由后端赋予自采记录可信标记；开放上报接口不能自行指定该标签。标签所能证明的是采集路径受后端控制。至于传播事件是否真实，还需要独立核验。上游若含客户端错误、重复、接收站假报或异常设备，后端仍可能采入不准确记录。用户回传的公开 PSKReporter 记录经过开放接口，来源权限仍低于后端自采记录；内容真实性需另行核验。来源分层规定哪些记录有资格参与模型上线裁决。

时间、网格、频率、距离和 SNR 的格式及范围检查无法识别所有伪造记录。MAD 筛选可减弱极端残差影响，却难以识别接近正常分布的伪造样本；目前也缺少独立观测逐条核验。真实异常传播同样可能表现为离群值，盲目删除会丢失极端条件。因此，本文只筛选用户上报，并在样本过少时停用；拦截效果仍需系统实验测量。

记录经过来源和内容检查后，仍需检查模型预测是否可靠。即使所有入库记录都来自后端自采，模型仍可能因来源分布狭窄、物理基线错误、时间切分泄漏或门槛遗漏某个子群而产生不可靠预测。准入规则的整体 RMSE 门槛与分距离、频率护栏能防止部分明显退化，却不约束所有来源和 MAE。第 5.5.5 节的偏差校准就是一个已观察到的反例：整体 RMSE 改善并通过上线，三个种子的 MAE 却变差。把“通过门槛”写成“各项能力全面提高”会抹去规则本身的盲区。

用户记录不带 trusted 标记，也不进入准入测试。若上游 PSKReporter 或大量接收节点遭操纵，后端自采测试也可能失去可信前提，局部攻击还可能被总体指标掩盖。来源/站点分层、贡献限额、异常监测和哨兵观测可供后续研究，目前尚未实现。

5.9 运行数字的解释与样本独立性

表 5-2 同时出现观测总数、重训次数、上线次数和 RMSE 范围，四项数字没有共同的分母。观测总数包括重建产物前保留下来的全部数据；重训历史从修复切分和泄漏问题后开始计数；上线次数是这些重训中通过当前门槛的子集；RMSE 范围由不同轮的可信测试集产生。把它们排在一张表里便于描述系统规模，却不意味着可以用“35/1 174”估计未来任一候选被接受的概率，也不意味着把 RMSE 曲线前后端点相减就得到长期改进量。每轮新增数据改变测试集合，使单个点的绝对误差与前一轮不可直接比较。

图 5-2 和表 5-2 采用不同的记录范围，计数因此不相同。图像剔除了特定时间段中受污染的重训记录，仅展示 1 120 次可比自动重训及其中 33 次上线；表 5-2 汇总重建以来全部 1 174 次与 35 次。若不说明排除窗口，读者会把两组数的不一致当成统计错误，或误以为图像遗漏了不利结果。论文在图注中列明时间段、过滤条件和单位，同时保留原始归档以供复核。这种处理只能清除已识别污染记录，不能保证剩余每轮的测试集分布固定。

观测规模的增长与独立信息量的增长不是同一件事。第 2.4.1 节的冻结审计显示，约 1 % 的活跃接收呼号贡献 34.339 % 的记录；FT8 占运行快照约 96.4 %。若最活跃接收端持续上线，系统可在几天内收集大量相似链路，而某些地理区域与模式依然缺样本。相关报告对树模型仍可能有用，因为它们提供了不同传播时刻的条件，但它们不是彼此完全独立的随机抽样。以每条记录为独立单位计算极窄的置信区间，会低估站点和时间簇造成的不确定性。新的效果实验应尝试按站点、路径和日期分组重采样，以观察结论是否依赖少数贡献者。

运行表记录量已超过历史 93 500 条的 30 倍，但数据集中于 2026 年 8—9 月，覆盖并未相应扩展。近月样本占比可能影响稀有月份；早期选定的新数据纳入比例 0.5 仍需结合来源、月份、太阳活动和距离分布复核。

在役产物用于服务用户，被拒候选主要留在评估日志中。如果只分析在役模型，就会漏掉所有未过门槛的候选及其试验条件，得到的只是经过选择的样本。本文保留重训历史、拒绝次数和原因，供准入流程审计使用。研究长期在线效果时，还须将每轮候选、在役模型、测试集快照和产物版本连成完整的决策序列；没有被拒候选这一部分分母，就无法检验“越训越好”的说法。

5.10 预先冻结的纵向评价方案

当前运行记录证明系统能够采集、重训和按门槛替换，却不能证明跨月份的累计预测收益。要检验后者，应在观察新结果之前写定评价协议。一个可执行的方案是先冻结未来若干完整昼夜的测试窗，再覆盖多个连续月份与至少不同太阳活动水平；每个测试窗只允许在时间上更早的数据进入训练。模型版本可以沿生产时间线更新，但最终比较必须让不同版本在同一冻结测试窗上接受评价，或按明确的滚动起点与预测跨度逐次配对。若训练和测试窗混合、甚至使用了测试窗之后的记录，得到的“未来效果”不再具有预报意义。

评价结果应按来源、距离、波段、月份和接收端活跃度列出样本数、RMSE、MAE 与偏差，并预先设定最小样本量和容忍带。

跨时点比较需要一并保存模型产物版本和数据定义。若某轮改动了 VOACAP 计算、功率假设或 SNR 截断下限，模型前后的差异就不只来自训练数据；此时应在同一代码版本下另做反事实重训，或者明确将差异归为系统版本改动。上游 PSKReporter 的返回格式、限流策略若发生变化，采集密度及测试集构成也会受影响。因此，外部服务状态、熔断事件和入口延迟应与模型日志共同归档，供复核数据管道变化对评价的影响。

纵向实验应预先规定哪些结果将推翻当前解释。若固定测试窗中新采来源继续改善而历史来源持续变差，应讨论权衡而非只报告加权平均；若跨月后 14.63 % 的早期优势消失，应把它解释为早期切片的条件收益；若低支撑路径在更多地理区域上并未稳定受益，应缩小正则化和回退的适用范围。

5.11 模型版本、缓存与用户所见结果

预测接口默认缓存网格 900 s；缓存条目由模型及请求参数确定。缓存能降低重复查询的物理基线计算和邻域求值成本，但在模型上线后若键只包含请求参数，同一请求可能继续返回旧模型的预测。当前混合模型的缓存键还包含产物修改时间签名；新产物通过原子替换进入固定路径后，签名变化使相同请求转向新键。产物签名进入缓存键后，模型上线与下一次请求所用版本便可以对应检查。它不要求立即删除所有旧缓存条目，却要求旧条目不再命中当前模型版本。

版本感知缓存仍有边界。物理基线模型、空间天气数据或请求参数的语义若改变，而相应版本没有进入缓存键，旧值仍可能在有效期内返回；前端页面自身也可能持有上一次请求结果。因而一个完整的运行检查不能只看模型文件的时间戳，还应对一个固定请求记录 API 返回的版本、结果时间和缓存状态。若前端同时展示 VOACAP 与混合模型，两个面板应说明各自的更新来源和时间，不让用户把旧的物理基线与新的校正结果误当作同一时点的严格比较。本文已在后端对混合模型产物变化设置缓存键分离，其他缓存路径的版本语义仍需逐项维护。

论文报告的运行数字应能追溯到具体模型版本。某一次自动晋升被记为“上线”，应能对应候选报告、在役前版本、测试集构成、门槛结果和替换后产物。如果其中任一链接缺失，后续即使有一条 RMSE 数值，也难以复核它对应的实际用户输出。旧产物 .bak 提供手动回滚路径，但回滚是新的状态变化，应留有原因、时间和验证结果；简单把文件覆盖回去而不检查热加载和缓存，不足以确认用户已恢复到旧模型。对一个持续学习系统，产物的可追溯性与离线模型的可复算性同样重要。

用户界面中的“对齐呈现”尤其需要区分数值和视觉处理。该功能以当前两张网格差值的中位数对 VOACAP 面板作平移，帮助观察波段与时段的相对格局；原始数值保留在提示框中，平移量在标题附近显示。若用户仅看颜色，可能把对齐后的图误解为 VOACAP 本身的绝对 SNR 已改善。界面说明必须让人随时回到原始量值，论文在结果比较中也一律使用未对齐的模型输出。视觉上的并列比较服务于理解，不能成为改变实验数值或重新校准物理模型的隐蔽步骤。

5.12 用户贡献的价值与约束

浏览器绘制传播弧线时已经获取公开 PSKReporter 报告，回传可以复用这些记录，无须增加上游请求。回传是否增加训练信息，仍要看贡献者的位置和记录覆盖的链路。参与者如果仍集中于欧洲、北美和东亚，回传总量增加也可能让原有地区偏斜更明显。若参与者位于历史较薄弱的南半球或远洋附近，其报告可能补充稀少链路，但仍需要独立评价来证明是否改善模型。第 2.4.1 节的接收端集中度说明，把回传条数作为唯一贡献指标，会高估少数持续在线台站的覆盖作用。

用户主动日志则具有不同的价值和风险。公开 PSKReporter 记录通常缺少真实发射功率，而个人通联日志可以记录功率、模式和主观结果；这些信息若可靠，可帮助研究来源偏差和不同通信模式。但日志可能包含未公开的位置、联络对象或时间模式，不能因为用户已打开“贡献数据”开关就自动纳入。系统应让用户逐次确认具体上传内容，并把日志来源与浏览器回传分开标记。论文当前的可信测试集不接受用户上报，即使日志含更多字段也不改变这条权限规则；字段丰富性不等于来源可用于自我评价。

记录被接收、通过校验和最终入训是不同状态，界面反馈应逐项对应。系统可以展示某次贡献被接收、被格式校验拒绝或进入训练候选池，但不能承诺它一定被当前模型用于拟合，更不能说它直接导致某次上线。样本可能在来源分层、离群检查、验证留出或阶段性比例控制中没有进入最终拟合集。一组贡献的效果应在预先定义的区域和时间测试集上对照；累计观测数只记录规模，不估计个体贡献的因果效应。界面只陈述系统已完成的动作，不把每条贡献直接归为模型改进。

激励用户补充稀疏路径，可能同时改变重复或伪造报告的动机。若贡献数量与可见奖励挂钩，来源核验便须随激励设计一同考虑。未来若设计激励，应同时提高来源核验和独立评估能力，并保留真实异常传播不被简单清洗掉的空间。参与者激励与相应的伦理、隐私评审属于后续平台研究。

5.13 上线决策的证据账本

持续学习把论文中的一次性实验变成连续决策。每一轮训练都可能产生候选，但只有通过准入规则的候选进入在役路径。若要解释某一次上线，至少要能回答：这轮新增了哪些来源的记录，训练、早停和可信测试分别用了哪些行，候选与在役模型是否在完全相同的测试行上评价，分来源和护栏指标是什么，哪条规则触发通过，产物何时被替换，线上服务何时重新加载。缺少其中任意一环，单独的“改善 0.269 %”只能说明日志里记录了一个数字，不能说明用户看到的模型确实是那次通过测试的产物。

证据账本应把不可变的试验身份和会变化的运行状态分开。训练输入摘要、代码提交或版本、特征定义、切分种子、候选模型摘要与测试行标识属于一次决策的身份；当前在役路径、缓存命中、前端显示的更新时间属于运行状态。前者便于日后重算和审计，后者便于发现热加载、缓存或服务实例不同步。只记录文件修改时间虽然能触发重载，却不是足够稳固的学术追溯标识：不同内容可能因文件复制获得相近时间，同一内容也可能因复制变更时间。将来若扩展账本，应保存产物内容摘要，并在 API 状态中暴露与之相连的短版本标识。

评估账本应记录被拒候选及原因，包括增益不足 0.2 %、分片退化、测试样本不足或运行故障。第 5.5 节的次数只反映当时的运行频率，未验证门槛最优性。

每轮账本的可比性限于同轮配对。即使两轮都报告“在役 RMSE”，其测试样本、来源比例、模式及季节可能已经不同。将这些点画成时间曲线可以监测异常，却不能对斜率作模型改善或退化结论。若确需跨轮评估，必须另建冻结哨兵集，让每个版本都在同一行上重算；哨兵集若长期公开用于调参，又会逐渐成为开发集，因此应定期设新的前瞻性封存窗口，并清楚标记旧窗口的开发接触程度。运行准入与研究确认应各有数据权限。

5.14 故障恢复与性能结论之间的隔离

采集、训练和服务的可靠性会影响可用于研究的数据分布。PSKReporter 上游返回 503 时，前台查询与后台采集若各自短暂重试，可能延长封禁；恢复后先收集到的报告又不一定代表封禁期间遗漏的时段。共享熔断器保证失败期间停止真实请求，并允许服务自然恢复，但它不能补回所有错过的传播事件。因此熔断修复证明请求管理改善，不直接证明模型精度改善；若把修复前后模型误差比较作为因果证据，需处理采集窗口和台站活动的变化。

双进程锁故障改变了单位时间内的采集密度。两名训练者同时运行会使采集速率超过配置上限，并可能竞争写入模型产物。修复锁以后，单位时间内新增条数下降到预期水平，并不表示观测网络变弱；相反，异常高吞吐在旧日志中也不是“系统进步”的证据。对故障窗口的研究数据应保留原始记录和标记，能确定重复时按预定键去重；若难以判定影响范围，可从固定性能分析中排除并在图注说明。图 5-2 的过滤做法遵守这一原则，但过滤后仍要接受测试集逐轮变化的限制。

失败恢复应遵守幂等性。一次请求失败后重试，可能返回与上一轮相同的报告；若入库以稳定键去重，则重复请求不应使训练样本无界增长。一次训练完成后服务进程崩溃，下一次启动不应在没有新样本的情况下把同一候选再次记录为独立上线。未来可以对采集前、入库后、训练后、替换前后分别注入故障，检查记录、产物和用户输出是否收敛到一致状态。

故障期间漏掉的观测，有可能更多地来自网络繁忙时段。上游拥塞可能与全网活动高峰同现，服务停摆可能更容易漏掉某些繁忙时段；若缺失恰好集中于困难传播条件，事后只看成功入库的记录会高估系统表现。不能把服务可用性百分比与预测 RMSE 合并成一个未经定义的“可靠性分数”。应分别报告采集请求成功率、可用观测时段覆盖、模型服务可用率和冻结测试误差，再分析它们的关联。只有这样，工程故障才能作为误差解释的候选，而不会被混同为算法效果。

5.15 数据贡献、准入权与评估权的分离

候选训练允许用户贡献数据；早停验证和模型准入均使用可信来源样本。

客户端传来的 trusted=true 即使形式合法，也不应成为可信测试资格；服务器必须根据采集路径赋值并在入库时保持来源字段不可由用户覆盖。格式校验和离群筛选只能降低简单异常的影响，不能证明不存在有策略的投毒。若未来对用户贡献设置权重或每站上限，应在独立攻击模拟与自然异常传播的对照下评价。尤其应避免误删真实的稀有极端接收记录。

用户报告参与训练后，若再用同批报告评价收益，会形成自我评价。后端自采测试仍可能与训练贡献共享接收站或传播事件；后续应采用站点和时间均隔离的前瞻测试窗，并预先划分调参、准入和独立确认样本。

贡献反馈应停留在记录实际达到的处理阶段，不能越过现有权限边界作出承诺。界面可以如实告知“数据已接收”“通过基本校验”“进入候选训练池”，而不能承诺该条记录一定参与本轮训练、使模型改善或改变一次上线决定。贡献的边际价值需要对照实验；对一个高度重复的常见链路，即使记录真实，新增信息可能很少。对一

个未覆盖区域，单条记录也可能因噪声过大或缺少同类支持而无法显著改变预测。透明反馈应告诉用户系统真实完成的动作，而不是把参与行为转换成无法核实的模型功劳。

第六章 讨论与后续研究

本章结合数据覆盖、模型假设与系统运行条件，界定研究结论的适用范围，并据此提出后续工作。

6.1 数据层面的局限

（1）采样地点由实际通信活动决定。 这些记录由实际通信活动产生，采样地点主要落在欧洲、北美和东亚；海洋、非洲、南美及极区缺少同等密度的观测，也没有科学抽样布设。短于 2 000 km 的链路占 57.2 %，超过 14 000 km 的仅占 1.7 %。第 3 章的正则化约束稀疏区输出波动；该区域的预测精度仍取决于实际观测覆盖。

（2）模式覆盖集中于窄带弱信号通信。 历史训练全部来自 WSPR，持续采集以 FT8 为主。SSB、CW 等通信方式解调门限、占用带宽与操作习惯不同，链路可用性的判定口径也可能改变。

个人通联日志上传前设有逐次确认，但完整的数据治理规则尚未制定：保留期限、删除请求流程、访问权限和二次用途均未明确。因此，本文只能报告现有上传确认和训练/准入分离设计，不能据此认定用户数据已受到完整制度保障。该缺口需要在开展相应数据处理前由负责方制定并落实规则。

（3）历史特征缺少地磁活动。 2.3.1 节所述数据无法可靠回填 Kp 指数，当前模型因而不能区分相应状态。地磁暴对高纬传播路径的显著扰动未得到表达。

6.2 建模与评估层面的局限

（1）可靠度缺少可验证的校准目标。 可靠度评分的概率解释尚缺少实测验证。WSPR 与 PSKReporter 只记录成功接收事件，数据中没有”已经发射但未被接收”的负样本；若把评分 R 解释为链路可用概率，其可靠度图和 Brier 分数因此无法由现有样本计算。3.3 节以模型自身的群体 RMSE 设定评分尺度，给出的是工程映射，而非逐链路不确定度或经验校准。

本次随稿补充材料整理了研究代码、实验脚本、适用配置、软件依赖说明和源文件校验清单，不包含用户日志或原始观测数据。折级行分配清单和可公开下载的输入数据尚未提供，因此第三方仍不能逐行重建全部折间比较或完整复算运行准入历史。补充材料可用于公开代码审查；当前本地文件尚未发布到外部仓库。

负样本可尝试从 WSPR 定时发射记录中构造。发射端按 2 分钟周期工作，接收站在对应周期未上报目标站时，可将该记录作为候选”未接收”事件，但必须确认接

收站当时在线且守听该波段。用户主动提交的”呼叫未成功”也可作为另一来源，只是报告可信度和自选择偏倚仍需考虑。

（2）抖动只是可读性的代理量。 第 3 章以相邻单元评分差的平均绝对值描述输出稳定性，尚未通过用户主观评价检验它与实际可读感受的对应关系。评分阈值 10 也缺少独立依据。阈值取 5/10/15/20 时，北京→纽约的抖动由 10.76 降至 8.58，中间三条路径在阈值 20 处还会交换相对次序；稳定保留的只有两端分层，即东京始终最低、圣保罗始终最高（见 3.18 节）。现有证据仅支持抖动随支撑减弱而总体上升；引用绝对值或路径排序时，须同时说明当前指标定义。

（3）超长路径段的样本不足以给出稳定收益估计。 表 3-8 中，14 000–20 100 km 距离段的改进为 +0.66%，仅在 8/12 折出现，该段共 1 589 条样本。该距离段的收益估计仍受样本量和折间变化限制。

（4）所测频率核宽带来了误差代价。 表 3-6 中，沿频率方向借用邻域信息会使精度下降；$\sigma_f = 0.2$ 时变化为 -0.508%，仅 1/12 折改善。现有实验没有找到兼顾抖动抑制与精度维持的频率核宽，当前实现只能让密集路径上的核宽趋近于零，以限制精度代价。

6.3 系统层面的局限

（1）早期闭环收益尚未经过跨期验证。 第 5.5.2 节的两种协议均有正向结果，但对应新增观测只有约两天，限于一个月份和一个太阳活动水平。14.63 % 指生产来源分层协议下新增来源子集与在役模型的 RMSE 差值，不能解释为跨月份或跨太阳活动水平的泛化收益。

表 5-2 中的观测量虽已超过历史集数倍、跨越多个昼夜，轮次之间的样本构成和来源占比仍在变化。晋升次数与 RMSE 曲线据此只能说明系统发生了什么，无法代替固定测试集上的长期性能比较。若要复评，应预先冻结训练、验证和测试时间窗，覆盖完整昼夜及多个月份，再标定新数据训练比例，以检验跨期增益。

（2）可信度分层以自采数据可信为前提。 PSKReporter 若被大规模污染，或攻击者控制大量真实上报站点，训练样本和评价依据便可能同时失效。本文没有办法检验这类更强的攻击模型。

（3）现行准入规则未直接限制来源分片与 MAE。 当前规则要求整体 RMSE 越过既定阈值，并限制样本充足的距离或频率分片劣化不超过 2 %。5.5.4 节显示，来源分片的变化仍可能被总体均值稀释；5.5.5 节的偏差校准虽稳定改善 RMSE 并通过准

入，MAE 却在三个随机种子上劣化 0.70 %–0.91 %。后续应为分来源 RMSE 和 MAE 设定容忍带。

6.3.1 三种证据不能互相替代

离线实验、受控消融和运行日志分别用于评价误差、诊断机制和核查系统是否执行。固定折改善 0.5 % 或多次上线，都不能单独证明长期用户收益。

它们的分母尤其不同。历史离线测试由预先整理的 WSPR 成功接收记录构成，早期新采比较只有约两天的 PSKReporter 切片，运行 RMSE 则来自不断增长的可信来源测试池。这些集合的模式、功率口径、月份和站点构成都不同。若把各表中相近的 8 dB 数字排成一条时间线，会误将测试集更换当作模型进步或退化。只有同一轮候选与在役共享测试行集，或两个版本在预先冻结的相同未来测试窗上重算，才能直接比较模型质量。论文摘要对 14.63 % 的误差差值明确限定“早期新采切片”，正是为了避免读者把它推广到表 5-2 的长期运行范围。

方法开发应先确认估计对象和评价协议。VOACAP 哨兵值改变了残差目标的数值意义；早停泄漏改变了测试集的角色；全局时间切分改变了新数据实际进入训练的数量。在识别这些问题前，各环节都曾产生貌似合理的误差曲线。本文据此记录失效条件与修复过程：使用外部基线和持续上报的学习系统，需要核查特殊编码、同轮评价和来源权限，然后再调整数据量、模型容量或平滑强度。

6.3.2 早期收益与长期外推之间的距离

首次修正后同轮比较显示，早期新采 PSKReporter 条件子集的 RMSE 比较值下降 14.63 %，历史分布 RMSE 上升 0.08 %。WSPR 与 PSKReporter 在模式、功率、参考带宽和上报机制上不同，且来源判别器 AUC 为 1.000；现有比较不能区分传播信息增益与来源口径适配。在修正后的同轮比较中，候选模型在该来源切片上的 RMSE 更低；这一差异尚不能归因于可迁移的传播规律；整体通过门槛的同时，历史来源出现轻微劣化。独立时间审计显示，新增切片只覆盖很窄的时间范围，测试部分集中于夜间若干小时。太阳活动、台站网络和传播模式在后续月份变化后，这一改进可能缩小、消失，甚至反向。现有证据没有给出这种外推的置信区间。

运行快照含 2 889 356 条记录，主要来自 2026 年 8—9 月且以 FT8 为主。约 1 % 最活跃接收呼号贡献了三分之一以上报告，新增数据主要提高已有条件下的密度，不能据此判断少见区域表现。后续需开展站点或路径分组测试，并结合跨月冻结窗口。

新数据训练比例应与新增记录的时间覆盖一起解释。new_train_frac=0.5 是在早期狭窄时间覆盖下，为避免新数据完全压制历史分布而选择的档位。随着新增数据的月份和太阳活动范围扩大，比例 0.5 的含义会改变：同一百分比可能对应成百上千倍的绝对新增行数，也可能继续重复同一接收站的相似记录。重扫应使用新的冻结测试窗和分来源护栏，而不是依据生产曲线中跨轮不可比较的绝对 RMSE 做直觉调整。

6.3.3 预测可靠性与界面解释的未完成部分

本文将可靠度称为评分而非概率，是一项实质限制。成功接收报告缺少“发射但未收到”的可靠分母，因而不能对评分计算严格的二元校准曲线。热力图中的低支撑提示和超过 MUF 的标记，能提醒用户某些格点依赖较强外推，却没有给出逐点误差条或成功概率。若用户把颜色强弱读成可直接指导关键通信的确定性保证，系统的解释会超过数据的支撑范围。界面把 VOACAP 原始值、混合模型值、对齐呈现偏移和模型版本区分显示，是为了让数值的来源与处理可见；真正的决策有效性仍需用户研究或前瞻性任务评价。

预测区间可能比单一评分更适合表达点估计的不确定性，但也不能在当前数据上随意附加。历史时间块、地理区域和来源的误差分布不同，一个全局 RMSE 倍数构造的区间可能在密集区过宽、在稀疏长路径上过窄。若要报告 90 % 覆盖区间，就应在未用于拟合的固定数据上检验覆盖率，并按距离和来源报告分层结果；样本太少的长路径分片必须保留“不足以检验”的状态。区间覆盖只对应已记录成功接收的名义 SNR，还不等同于信号能否被接收的概率。这条边界与第 3.13 节的三层输出区分一致。

6.3.4 竞争解释与能够区分它们的实验

第一组竞争解释围绕物理基线的作用。参与 −120 dB 截断阈值选择的历史时间留出数据上，混合模型 RMSE 低于 VOACAP（8.21 dB 与 34.69 dB）；该比较属于开发阶段结果，不是独立泛化估计。差异可能来自物理模型提供了可学习结构，也可能主要来自 WSPR 与 VOACAP 工程假设之间较大、且可由频率、距离和站点特征补偿的系统偏移。现有置零实验显示当前预测目标与 VOACAP 派生特征存在依赖，但不能在上述解释之间作因果判别。要区分两种解释，需在相同训练样本、容量预算和预测时可用信息下，以实测 SNR 重新训练端到端模型，并在时间及地理留出集上配对比较。即使端到端模型达到相近误差，物理基线对样本效率的独立贡献仍需通过学习曲线评估，单次 RMSE 不足以判断。

第二组解释围绕稀疏路径的跳变。树模型在少样本处的分段常数输出可能产生伪不连续；真实电离层在日出、日落或频率接近 MUF 时也可能快速变化。五条路径的评分抖动无法直接区分两者，因为它没有同时测得每个网格的真实连续轨迹。未来可设置固定发射和多站点守听的连续观测，在已知发射时隙下比较模型、物理基线和实测变化；也可在高密度区域人为抽稀，对照抽稀前的观测趋势。若平滑抹去被独立观测确认的真实变化，方法的可读性收益便不能视为预测质量收益。当前频率维的负面结果已经提示这种风险并非纯理论可能。

第三组解释围绕新增数据收益。早期新采子集上的 14.63 % 的条件差异可能来自模型学到新的传播规律，也可能主要来自 WSPR 与 FT8 的功率、带宽和上报机制差异被条件化补偿。来源判别器 AUC 为 1.000，使第二种解释尤其需要认真对待；但来源可辨不等于模型已显式学会分来源规则。一个区分实验应在同一来源内部跨时间验证，并在两个来源拥有相近时空和频率条件的重叠子集上比较，同时控制发射功率信息。若收益只存在于可以直接识别来源的特征组合中，而未在同源未来测试窗保留，就不能把它概括为传播预测能力的普遍提升。

运行期 RMSE 上升可由模型、测试集难度、来源占比或数据管道变化造成，归因前须区分这些来源。当前运行规则只允许同轮候选与在役比较；跨轮解释需要冻结测试行集，或记录足够完整的分片构成并把各版本在共同样本上重算。若某次异常与 PSKReporter 503、熔断、锁失效或 VOACAP 代码变更同现，应先排查输入和执行状态。

配对误差差异是当前协议下的实验观察；竞争解释指向机制归因和跨期外推所需的额外对照。把每一项结论后面可能推翻它的实验写清楚，可使后续工作从“继续优化”变成有判断标准的研究计划，也使本文的正面与负面发现都具备可累积性。

6.4 后续工作

后续工作主要针对以下尚未解决的问题：

（1） **补充地磁活动特征的独立验证。** 现有历史数据没有地磁活动状态维度；Kp 标注观测达到独立验证覆盖要求后，方可评估其作用。

（2） Reverse Beacon Network 的 CW 记录和功率信息可用于检验模型迁移到其他模式的条件。

后续工作的优先顺序应由当前证据缺口决定。第一项是建立**前瞻性、冻结的跨期测试窗**，而不是立即更换更复杂的模型。预先选定覆盖完整昼夜的多个月份，记录每条测试记录的来源、模式、波段、距离和接收站；训练只能使用测试窗开始之前的数

据，早停验证也须独立。每个预先定义的分片同时报告 RMSE、MAE、偏差与样本数，并以站点或日期为重采样单位估计不确定性。主要失败条件应事先写明，例如新采来源改善不能以历史来源持续明显劣化为代价，长距离分片的效果不得仅由少数活跃站点支撑。这个设计才能检验早期 14.63 % 的条件收益能否跨季节复现。

第二项是建立**可校准的接收事件资料**。以 WSPR 公开排程或志愿台站受控发射为起点，先记录每次确实发生的发射、频率、功率和时隙，再记录目标接收站是否在线、是否守听同一波段、是否成功解码及网络上报是否正常。只有当失败事件的观测机会能够确认，未上报才可能成为有意义的负样本。完成数据协议后，可比较现有评分对成功事件的排序能力，并用独立时段检验概率校准；若要给出不同模式的成功概率，需分别定义模式和设备条件。正样本与未标记样本的学习方法可以提供处理思路[29]，但不能替代真实的接收机会记录。

第三项是把**空间天气状态与信息发布时间**纳入研究。历史 Kp 无法可靠回填，新采表中的非空 Kp 又可能包含回退填充值。应保存每一项空间天气值的来源、有效时间、获取时间和是否为填补值，并区分回顾性诊断与真正的未来预报。只有当训练、验证和测试都能在预测时获得同一类信息，才能公平比较加入 Kp 或其他扰动指标后的增益。对地磁暴和高纬路径可预先设定单独分片，但样本不足时不应以个别极端事例给出总体效果。

距离是当前 $n(d)$ 的唯一输入，地理区域、频率、时间及接收端集中度尚未纳入。可尝试以距离、地磁纬度、相对 MUF、月份和站点簇构造分层支持量，并在空间留区与跨月留出中比较其与实际误差的关联。新增维度可能使邻域更稀，因此复杂支撑量的评价必须同时报告覆盖范围和不稳定分片，不可只展示相关性提高的部分。若支撑指标与误差没有稳定关系，应保留现有简单规则或把它降格为描述性提示，而不是作为自动调权的依据。

整体 RMSE 及部分距离、频率护栏构成现行门槛，分来源 RMSE 和 MAE 目前仅作报告指标。未来可以在固定可信测试集上预设每个来源的最低样本量与容忍带，并为 MAE 增加独立监测；样本量不足时延迟自动准入或转入人工复核。增加护栏会提高偶然波动导致拒绝的机会；历史重放可检验规则稳定性，各指标的门槛应依用途分别设定。候选产物的收益、护栏违反和拒绝原因均应归档，便于日后检验新规则是否真正减少有害上线，而不是只降低上线次数。

第六项才是**扩展模式与物理模型对照**。WSPR、FT8 与 CW 的发射功率和解码门槛不同，若把模式加入模型，需要新的元数据或分模式训练；否则模型可能只学到不

同报告网络的平均差。RBN 可为 CW 提供更多记录，但要核实其 SNR、功率和时刻定义后才能与现有数据合并。另一条路线是在相同链路、相同基线假设下对比 VOACAP、ITU-R P.533 或其他电离层输入，明确物理模型差异是否落在当前残差模型可以补偿的范围。所有新对照都应共享冻结测试行集，避免把数据源或工程假设变化归因于算法。

上述研究方向依赖评价资料与数据协议的先行建设。没有冻结的未来测试窗，复杂模型的新收益难以证明；没有失败事件，就不能证明概率校准；没有字段来源和发布时间，就不能证明空间天气特征在真实预报时可用。因此，本文建议先建设评价和数据协议，再扩展特征及模型。这一顺序使新实验能够分别检验长期误差、概率校准和空间天气特征的实际效用。

6.5 后续验证的优先级与终止条件

下一阶段研究容易陷入无限增加特征和模型复杂度的循环。本文的结果提示，应先给每一项后续实验设定“什么结果会改变现有结论”。最高优先级是冻结未来测试窗，因为它同时检验早期众包收益、长期遗忘和在线准入的实际价值。测试窗应覆盖完整昼夜、多个连续月份及不同太阳活动条件；在窗口开始前确定主要指标、主要来源分片和最小样本量。若某一关键分片样本不足，结论应推迟，不以其他分片的有利数字替代。若新采来源仍改善但历史来源稳定劣化，需重新讨论训练比例和准入权重；若两者均无改善，继续单纯扩大采集量没有充分依据。

第二优先级是低支撑路径的独立确认。现有受控抽稀支持“未校正物理基线不是稳妥回退目标”，而 14 000–20 100 km 段仅在 8/12 折改善。未来应在不同出发地、接收地和月份上预先选择足量长路径，不在观察结果后更换分段边界。时间核平滑既要检查 RMSE，也要检查日出、日落附近是否抹去真实变化；频率核平滑已有负面结果，应在提出新的物理机制或独立数据之前保持关闭。若新增路径中平滑持续提高表面连续性却损伤误差或窗口识别，方法应缩小到展示层，不能作为默认预测校正。

第三优先级是接收概率问题的数据协议，而非直接把现有评分重新命名。只有保存确认发射、确认守听和未成功解码事件，才有可检验的失败分母。若受控台站无法稳定记录在线状态，概率任务应暂停；可以继续改进条件 SNR 回归，但不能以没有标签的校准图充当概率证据。收集到完整事件后，还应在一个时间窗训练或校准，在另一个未来窗口检查分模式、分功率和分接收设备的可靠性。总体校准良好而稀疏路径严重失准时，不宜向所有用户显示同一个概率值。

早期收益可能来自传播变化，也可能来自测量口径差异：新采 FT8 采用统一功率假设，历史 WSPR 记录报告功率，来源 AUC 为 1.000。若收益未保留在同源未来测试，或匹配功率、模式和时空条件后明显缩小，应主要解释为来源适配；同源样本增加本身不足以证明机制可迁移。

第五优先级是审视准入规则的效用。当前门槛用整体 RMSE 和部分分段退化上限裁决，在一次后续上线中 MAE 仍出现 0.70 %–0.91 % 劣化。若增加来源与 MAE 护栏，需先用历史候选记录重放：新规则会阻止哪些已知有害候选，又会误拒哪些在未来冻结窗有效的候选。仅因规则更复杂、上线更少，不能认定用户受益。若重放显示新增护栏在相同测试规模下波动很大，应优先改进测试窗、分组和样本量，而不是连续调阈值直至得到理想的历史结果。

每项后续主张都需要相应的证据门槛。缺乏实际发射和守听记录时，不推进接收概率宣称；缺乏跨月冻结窗时，不推进长期泛化宣称；缺乏足量独立长路径时，不扩大低支撑方法的适用范围；缺乏相同测试行时，不比较不同轮次 RMSE 的高低。这些停止条件约束论文从运行记录中提取学术结论的范围。把终止条件预先写出，有助于下一次数据增长时决定是继续采集、修改协议，还是提出新的模型假设。

第七章 结论

本文围绕第 1.4 节的四个研究问题，评价成功接收报告条件下的名义 SNR 残差模型、稀疏查询网格和运行期模型准入。

研究问题一：混合模型改善了哪些链路误差。 参与截断阈值选择的历史时间留出数据（n = 18 700）上，混合模型与 VOACAP 的 RMSE 分别为 8.21 dB 和 34.69 dB，系统偏差由 −23.22 dB 收窄至 +1.16 dB；这些数值是开发阶段比较，不是独立测试估计。可还原子集（n = 93 137）的 12 折特征组置零实验使 RMSE 上升 131.6 %，12 折均劣化。

研究问题二：平均误差遗漏了什么？ 历史观测按距离高度不均，短于 2 000 km 的链路占 57.2 %，超过 14 000 km 的仅占 1.7 %。在五条预设北京出发路径上，低支撑长路径的波段—时刻网格出现更大的相邻单元评分抖动；东京路径混合模型抖动为 6.39，纽约和圣保罗分别为 8.20 和 8.40。VOACAP 评分只提供同条件参照，不能充当真实日变化的下限。

研究问题三：稀疏查询条件下的误差和网格变化。开发阶段 12 折交叉验证中，支撑自适应时间邻域正则化的 RMSE 改善为 0.41 %–0.61 %；五条预设路径的相邻评分变化指标下降 12.3 %–51.6 %。这些交叉验证结果属于开发阶段证据，指标定义及验证边界见第 4.7 节；网格变化指标尚未验证用户决策效用。受控抽稀覆盖两个目标距离段和六种设置：即使目标段只留 5 条训练记录，数据驱动模型 RMSE 为 6.72 dB，纯物理基线为 49.00 dB。10 000–14 000 km 段低容量回退的汇总 RMSE 改善 1.28 %；14 000–20 100 km 段仅 8/12 折改善，频率维平滑在所测核宽下劣化 0.51 %。

研究问题四：开放上报进入训练后如何执行运行期准入。用户上报不进入准入测试；候选与在役模型按当轮共享可信样本比较。历史 WSPR 固定留出集在多轮运行中被重复使用，因此当轮配对仅支持工程准入。早期 PSKReporter 条件切片的 RMSE 比较值降低 14.63 %，历史子集上升 0.08 %，其覆盖范围和来源口径见第 5.5.2—5.5.3 节。2026-09-12 快照记录 1 174 次自动重训、35 次上线；由于测试集逐轮变化，该计数反映运行过程，不表示跨轮模型质量趋势。后续校准使门槛 RMSE 改善 0.360 %，但三个随机种子的 MAE 劣化 0.70 %–0.91 %。

参考文献：

[1] TETERS L R, LLOYD J L, HAYDON G W, et al. Estimating the performance of telecommunication systems using the ionospheric transmission channel: Ionospheric Communications Analysis and Prediction Program (IONCAP) user's manual [R]. Boulder: U.S. Department of Commerce, National Telecommunications and Information Administration, 1983. (NTIA TR-83-127). DOI: 10.70220/31pdtxnb.

[2] ITU-R. Recommendation ITU-R P.533-14: Method for the prediction of the performance of HF circuits[S]. Geneva: International Telecommunication Union, 2019.

[3] TAYLOR J H, WALKER B. WSPRing around the world[J]. QST, 2010, 94(11): 30-32.

[4] GLADSTONE P. PSK Reporter[EB/OL]. [2026-08-10]. https://pskreporter.info/.

[5] ITU-R. Recommendation ITU-R P.372-17: Radio noise[S]. Geneva: International Telecommunication Union, 2024.

[6] BILITZA D, ALTADILL D, TRUHLIK V, et al. International Reference Ionosphere 2016: From ionospheric climate to real-time weather predictions[J]. Space Weather, 2017, 15(2): 418-429. DOI: 10.1002/2016SW001593.

[7] GLAHN H R, LOWRY D A. The use of model output statistics (MOS) in objective weather forecasting[J]. Journal of Applied Meteorology, 1972, 11(8): 1203-1211. DOI: 10.1175/1520-0450(1972)011<1203:TUOMOS>2.0.CO;2.

[8] KARNIADAKIS G E, KEVREKIDIS I G, LU L, et al. Physics-informed machine learning[J]. Nature Reviews Physics, 2021, 3: 422-440. DOI: 10.1038/s42254-021-00314-5.

[9] TAYLOR J M. A Novel Path Loss Forecast Model to Support Digital Twins for High Frequency Communications Networks[D]. Lincoln: University of Nebraska–Lincoln, 2020.

[10] BUCKLEY R, FURMAN W N. Application of Machine Learning Techniques to HF Propagation Prediction[C]//2021 IEEE Military Communications Conference (MILCOM). 2021: 623-628. DOI: 10.1109/MILCOM52596.2021.9653108.

[11] ZHU Z, YU Q, SHI Y, et al. Exploring the applicability of three popular models for predicting the received field strength of HF sky-wave propagation and communication[J]. Space Weather, 2026, 24(9): e2025SW004907. DOI: 10.1029/2025SW004907.

[12] WANG J, YANG C, AN W. Regional refined long-term predictions method of usable frequency for HF communication based on machine learning over Asia[J]. IEEE Transactions on Antennas and Propagation, 2022, 70(6): 4040-4055. DOI: 10.1109/TAP.2021.3111634.

[13] YU Q, WANG J, SHI Y, et al. A transferable real-time MUF forecasting model for HF communication in China[J]. Space Weather, 2026, 24(4): e2025SW004842. DOI: 10.1029/2025SW004842.

[14] ZHANG Z, YU Q, WANG J, et al. Maximum usable frequency forecast model based on real-time oblique sounding data[J]. Space Weather, 2025, 23(6): e2025SW004346. DOI: 10.1029/2025SW004346.

[15] FRIEDMAN J H. Greedy function approximation: A gradient boosting machine[J]. The Annals of Statistics, 2001, 29(5): 1189-1232. DOI: 10.1214/aos/1013203451.

[16] CHEN T, GUESTRIN C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2016: 785-794. DOI: 10.1145/2939672.2939785.

[17] KE G, MENG Q, FINLEY T, et al. LightGBM: A highly efficient gradient boosting decision tree[C]//Advances in Neural Information Processing Systems. 2017, 30.

[18] GAMA J, ŽLIOBAITĖ I, BIFET A, et al. A survey on concept drift adaptation[J]. ACM Computing Surveys, 2014, 46(4): 44:1-44:37. DOI: 10.1145/2523813.

[19] PARISI G I, KEMKER R, PART J L, et al. Continual lifelong learning with neural networks: A review[J]. Neural Networks, 2019, 113: 54-71. DOI: 10.1016/j.neunet.2019.01.012.

[20] ROBERTS D R, BAHN V, CIUTI S, et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure[J]. Ecography, 2017, 40(8): 913-929. DOI: 10.1111/ecog.02881.

[21] BERGMEIR C, HYNDMAN R J, KOO B. A note on the validity of cross-validation for evaluating autoregressive time series prediction[J]. Computational Statistics & Data Analysis, 2018, 120: 70-83. DOI: 10.1016/j.csda.2017.11.003.

[22] BIGGIO B, NELSON B, LASKOV P. Poisoning attacks against support vector machines[C]//Proceedings of the 29th International Conference on Machine Learning. Edinburgh: Omnipress, 2012: 1467-1474.

[23] ZADROZNY B. Learning and evaluating classifiers under sample selection bias[C]//Proceedings of the Twenty-first International Conference on Machine Learning. New York: ACM, 2004: 114. DOI: 10.1145/1015330.1015425.

[24] VALAVI R, ELITH J, LAHOZ-MONFORT J J, et al. blockCV: An R package for generating spatially or environmentally separated folds for k-fold cross-validation of species distribution models[J]. Methods in Ecology and Evolution, 2019, 10(2): 225-232. DOI: 10.1111/2041-210X.13107.

[25] wspr.live[EB/OL]. [2026-08-10]. https://wspr.live/.

[26] GNEITING T, RAFTERY A E. Strictly proper scoring rules, prediction, and estimation[J]. Journal of the American Statistical Association, 2007, 102(477): 359-378. DOI: 10.1198/016214506000001437.

[27] KOH P W, LIANG P. Understanding black-box predictions via influence functions[C]//Proceedings of the 34th International Conference on Machine Learning. PMLR, 2017, 70: 1885-1894.

[28] KAUFMAN S, ROSSET S, PERLICH C, et al. Leakage in data mining: Formulation, detection, and avoidance[J]. ACM Transactions on Knowledge Discovery from Data, 2012, 6(4): 15:1-15:21. DOI: 10.1145/2382577.2382579.

[29] ELKAN C, NOTO K. Learning classifiers from only positive and unlabeled data[C]//Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2008: 213-220. DOI: 10.1145/1401890.1401920.

谢辞

感谢指导教师在论文选题、研究方法、实验设计以及论证和文字修改方面给予的指导。

感谢 BI4AVZ 吴道清先生试阅论文全文并提出具体修改意见。模型训练与实验验证得到上海市全体业余无线电爱好者的数据支持，在此致谢。老师、同学在讨论和系统测试中帮助查找评估、实现及表述的疏漏，开源软件与公开数据社区为研究提供了工具和数据。

感谢家人在学习与研究期间给予的理解、鼓励和陪伴。

英文论文大摘要

RESIDUAL PREDICTION OF REPORTED HF LINK SNR AND A CONTINUAL LEARNING SYSTEM USING CROWDSOURCED DIGITAL-MODE OBSERVATIONS

HF propagation forecasts can support communication planning where terrestrial or satellite relays are unavailable. This study combines a physical baseline, residual learning, support-dependent constraints, and a running model-admission process for predicting reported link conditions.

The target is nominal SNR conditional on a successful reception report, not the probability that an arbitrary transmission will be received. “Continual learning” describes the system-level update process here, not a new continual-learning algorithm.

The fixed historical dataset contains 93,500 WSPR records from selected months in 2021, 2022, and 2024, not a continuous monthly series. A time-ordered hold-out of 18,700 records informed selection of the −120 dB VOACAP floor; the other 74,800 records formed the initial training pool. Because the hold-out informed this choice, the reported hybrid-versus-VOACAP comparison is development evidence rather than an independent test estimate. A read-only reconstruction audit found 93,137 records passed the existing longitude and solar-zenith checks; 363 had no real inverse-cosine solution and did not reach the zenith check.

VOACAP can return extremely negative sentinel values for closed links. Treating them as ordinary SNR contaminates residual targets and model inputs. A common −120 dB floor is therefore applied in training, evaluation, and online inference, while the residual remains measured SNR minus the consistently processed baseline. Record-level checks identified sentinel contamination as the principal cause of the earlier extreme long-path errors.

The predictor adds a learned residual to the physical estimate. Its main regression model uses gradient-boosted trees and 19 query-available features describing path geometry, frequency, time, solar activity, and physical-model outputs; measured SNR is excluded from prediction inputs. A constant bias adjustment is estimated on a separate validation set.

Tree predictions can change abruptly across nearby query points, especially where observations are sparse. Support-adaptive temporal neighbourhood regularisation averages

residual corrections while retaining the physical baseline at the query. Frequency perturbations preserve the operating-frequency-to-MUF ratio. A lower-capacity residual model provides a constrained fallback for sparse conditions, but remains mixed with the main model.

Evaluation includes the development hold-out, 12 leave-one-year-month-out folds, transmitter-longitude region hold-outs, and controlled thinning in two distance segments under six settings. These protocols use different samples and answer different questions; the sampled temporal folds were also used to compare smoothing settings, so their results and p-values are exploratory rather than confirmatory.

The selected temporal regularisation improved cross-validation RMSE by 0.41%–0.61%, with the same direction across folds. A grid-adjacency score fell by 12.3%–51.6% on five predefined paths, but this numerical roughness measure has not been validated against continuous measurements or user decisions. Low-capacity fallback improved aggregated RMSE by 1.28% in the 10,000–14,000 km segment; in the 14,000–20,100 km segment, improvement occurred in 8 of 12 folds. Frequency smoothing, extended features, and global correction shrinkage did not deliver their intended gains.

The service connects collection, ingestion, retraining, evaluation, and artifact replacement. Collection runs every 15 minutes and normally selects up to 1,200 records per batch. User submissions may enter candidate fitting, while early-stopping validation and admission evaluation use trusted-source records. Candidate and incumbent models share the same test rows in each round. The historical 18,700-record hold-out is reused across admission rounds; paired comparisons support each operational decision, but repeated reuse makes it unsuitable as an untouched confirmatory test. The frozen runtime snapshot through 2026-09-12 08:17 UTC records 1,174 automatic retraining attempts and 35 promotions.

Reliability incidents exposed dependencies beyond the learning algorithm. A lock-expiry defect allowed concurrent learning processes and was corrected with ownership and process-liveness checks. Repeated frontend requests during upstream failures prolonged rate limiting and disrupted collection; a shared circuit breaker now suppresses requests and extends back-off after repeated failures. These are documented recovery changes, not a quantified availability evaluation.

An early PSKReporter condition-specific slice showed a 14.63% lower RMSE while the historical subset worsened by 0.08%. The slice spans about two days, one month, and one solar-activity level, so it cannot distinguish propagation information gain from source adaptation. Test pools grow and change composition between runtime rounds; successive RMSE values therefore do not directly indicate model improvement or deterioration.

The findings support residual correction and temporal support constraints only within the evaluated distributions. Future assessment requires frozen prospective test windows across more months, station- or path-grouped separation, better characterisation of mode and power differences, and independent observations of failed reception. The grid score remains an engineering proxy. Code, scripts, configuration notes, and source checksums accompany this manuscript as a local supplement; raw observations and personal logs are excluded, and row-level fold assignments are not available. Policies for log retention, deletion, access, and secondary use have not been established. Accordingly, full independent reproduction and a complete assessment of data governance remain outstanding.